



IT-Empfehlungen für den nachhaltigen Umgang mit digitalen Daten in den Altertumswissenschaften

Herausgeber:
IANUS

Version 0.95
5. Februar 2015

Koordination



Förderung



Autoren: siehe Autorenverzeichnis

Titel: IT-Empfehlungen für den nachhaltigen Umgang mit digitalen Daten in den Altertumswissenschaften

Sprache: Deutsch

Zitierhinweis:

IT-Empfehlungen V0.95. IANUS – Forschungsdatenzentrum Archäologie & Altertumswissenschaften (2013) [Version 0.95] Hrsg. von IANUS.

Kontakt:

ianus-fdz@dainst.de
www.ianus-fdz.de

Lizenz:



Dieses Werk bzw. Inhalt ist lizenziert unter einer Creative Commons Namensnennung - Weitergabe unter gleichen Bedingungen 4.0 International Lizenz.

<http://creativecommons.org/licenses/by-sa/4.0/>

Version	Autor	Datum	Beschreibung
0.9	IANUS	18.02.2014	Erste veröffentlichte Fassung.
0.9	IANUS	11.03.2014	Änderung der Lizenzbedingungen.
0.95	IANUS	05.02.2015	Kapitel „3D und Virtual Reality“ und „Textdokumente“ neu. Anpassungen im Layout und kleinere Korrekturen.

Inhaltsverzeichnis

1 Einleitung	5
1.1 Benutzung der IT-Empfehlungen	7
1.2 Der Lebenszyklus von Forschungsdaten	9
1.3 Archivierung von Forschungsdaten in IANUS	12
2 Projektphasen	13
2.1 Vorlauf und Planung	14
2.1.1 Antragsstellung	14
2.1.2 Vor der Datenerhebung	14
2.2 Durchführung	14
2.2.1 Dokumentation	14
2.2.1.1 Dokumentation und Metadaten	15
2.2.1.2 Arten von Metadaten	17
2.2.1.3 Kontrollierte Vokabulare	18
2.2.1.4 Struktur von Metadaten	19
2.2.1.5 Speicherung von Metadaten	20
2.2.1.6 Weiterführende Informationen	22
2.2.1.7 Metadaten in der Anwendung	24
2.2.2 Dateiverwaltung	27
2.2.2.1 Dateiablage	28
2.2.2.2 Dateibenennung	30
2.2.2.3 Versionskontrolle	31
2.2.3 Dateispeicherung und -sicherung	32
2.2.3.1 Kurzfristige Speicherung	33
2.2.3.2 Mittelfristige Sicherung	33
2.2.4 Qualitätssicherung	35
2.3 Nachbereitung	35
2.3.1 Projektabschluss	35
2.3.2 Vorbereitung zur Archivierung	36
2.3.2.1 Auswahl	36
2.3.2.2 Dokumentation	36
2.3.3 Bereitstellung von Daten	36
2.3.3.1 Zugriffs- und Nutzungsrechte	36
2.3.3.2 Präsentationsform	36
2.4 Publikation	36
3 Dateiformate	37
3.1 PDF-Dokumente	37
3.2 Textdokumente	49
3.3 Rastergrafiken	61
3.4 Vektorgrafiken	72
3.5 Tabellen	72
3.6 Datenbanken	72
3.7 GIS	83
3.8 Statistische Daten	88
3.9 Bewegte Bilder, Videos	88

3.10	Audio	88
3.11	3D und Virtual Reality	88
3.12	Präsentationen	101
3.13	Webseiten	101
3.14	Eigene Programme und Skripte	101
4	Forschungsmethoden	102
4.1	Anthropologie	102
4.1.1	Genetik (Genotyp)	102
4.1.2	Morphologie und Metrik (Phänotyp)	102
4.1.3	Physiologie (Ökotyp)	102
4.1.4	Verhaltensforschung (Ethotyp)	102
4.2	Archäobotanik	102
4.2.1	Makroreste	102
4.2.2	Pollenanalyse (Palynologie)	102
4.3	Archäozoologie	102
4.4	Bauforschung	102
4.4.1	Bauaufnahme	102
4.4.2	Rekonstruktion	102
4.5	Datierung	107
4.5.1	Andere Methoden	107
4.5.2	C14-Datierung	107
4.5.3	Dendrochronologie	107
4.5.4	OSL/TL-Datierung	107
4.5.5	Uran-Ungleichgewichtsmethoden	107
4.6	Geoarchäologie	107
4.6.1	Biomarker	107
4.6.2	Bodenuntersuchungen	107
4.6.3	Geologische Untersuchungen	107
4.6.4	Geomorphologie	107
4.6.5	Sedimentuntersuchungen (Bohrkerne)	107
4.7	Geodäsie	107
4.7.1	Terrestrische Messungen	112
4.7.1.1	GPS/GNSS	112
4.7.1.2	Photogrammetrie	112
4.7.1.3	Tachymetrie	112
4.7.1.4	Terrestrisches Laserscanning	112
4.7.2	Fernerkundung	112
4.7.2.1	LIDAR-Geländescans	112
4.7.2.2	Luftbild	112
4.7.2.3	Luftbildphotogrammetrie	112
4.7.2.4	Satellitenmessungen	112
4.8	Geodatenanalyse	116
4.8.1	Geocodierung und Geoparsing	116
4.8.2	Geomorphometrie	116
4.8.3	Georeferenzierung	116
4.8.4	Oberflächen- (DOM) und Geländemodellierung (DGM) .	117
4.8.5	Visualisierung und Kartierung	122
4.9	Geophysik	122
4.9.1	Geoelektrik	122

4.9.2	Geomagnetik	122
4.9.3	Georadar	122
4.10	Materialaufnahme	122
4.10.1	3D-Scanning	122
4.10.2	Nahbereichsphotogrammetrie	122
4.10.3	RTI	122
4.11	Materialwissenschaftliche Archäometrie	122
4.11.1	Anorganische Materialien	122
4.11.1.1	Gesteine	122
4.11.1.2	Metalle	123
4.11.1.3	Silikatische Materialien	123
4.11.2	Methoden	123
4.11.2.1	Bildgebende Verfahren	123
4.11.2.2	Chemische Verfahren	123
4.11.2.3	Isotopenuntersuchung	123
4.11.2.4	Physikalische Verfahren	123
4.11.3	Organische Materialien	123
4.12	Numismatik	123
4.13	Oberflächenbegehung (Survey)	123
4.14	Textwissenschaften und Schriftzeugnisse	123
4.14.1	Sprachen und Zeichensysteme	123
4.14.1.1	Ägyptisch	123
4.14.1.2	Akkadisch	123
4.14.1.3	Aramäisch	123
4.14.1.4	Griechisch	123
4.14.1.5	Hebräisch	123
4.14.1.6	Hethitisch	123
4.14.1.7	Latein	123
4.14.1.8	Sumerisch	123
4.14.2	Antike Objekte mit Texten	123
4.14.2.1	Gefäße	123
4.14.2.2	Inchriften	123
4.14.2.3	Manuskripte	123
4.14.2.4	Papyri	123
4.14.2.5	Siegel	123
4.14.2.6	Tontafeln	123
4.14.3	Literarische Schriftquellen	123
4.14.4	Veröffentlichung und Archivierung	123
4.14.4.1	Wissenschaftliche Editionen	123
4.14.4.2	Schnittstellen zu Textsammlungen	123
4.14.4.3	Kollaborative Arbeitsumgebungen	123
4.14.4.4	Publikation	123
4.14.4.5	Lizenzierung	123
A	Versionshistorie	124
B	Autorenverzeichnis	125
C	Glossar	126

1 | Einleitung

F. Schäfer, M. Trognotz

Für die Durchführung archäologischer und altertumswissenschaftlicher Forschungsprojekte ist die Anwendung von Informationstechnologien verschiedener Art geläufig und unverzichtbar. Dennoch fehlt es bislang an etablierten Strukturen, Standards und Verfahrensweisen, die allen Projekten den erprobten und effizienten Einsatz von IT ermöglichen, Vergleichbarkeit gewonnener Datenbestände zu ermöglichen, übergreifend gleichwertige Qualität digitalen Materials sicherstellen und die langfristige Les- und Nutzbarkeit von Forschungsergebnissen in digitaler Form garantieren. Durch die Einhaltung von Standards können nicht nur redundante Entwicklungsarbeiten mit den verbundenen Finanzierungs-, Zeit- und Arbeitsaufwänden vermieden werden.

In zunehmendem Maße fordern auch wissenschaftspolitische Gremien (DFG¹, Wissenschaftsrat², Schwerpunktinitiative "Digitale Informationen"³) die Nachhaltigkeit und die Vernetzbarkeit digitaler wissenschaftlicher Informationen ein, was eine Auseinandersetzung mit Dateiformaten, Datenmanagement, Normen, Mindeststandards, semantischen Referenzmodellen, Dokumentations- und Austauschverfahren erforderlich macht — sowohl bei kleineren Projekten eines Individuums als auch bei größeren disziplinen- und institutionenübergreifenden Forschungen. Einheitlichere und in den jeweiligen Fachcommunities abgestimmte Vorgehen eröffnen für die aktuelle und zukünftige Forschung neue Möglichkeiten, bspw. um auf einer größeren, qualitätvoller und homogeneren Datengrundlage komplexe Fragestellungen besser als bisher beantworten zu können.

Mit diesen IT-Empfehlungen wird das Ziel verbunden, die langfristige Erhaltung und Benutzbarkeit des wissenschaftlichen Quellenmaterials zu gewährleisten sowie die Interoperabilität von Daten unterschiedlichen Ursprungs zu verbessern. Ferner wird angestrebt, die Grenzen von separaten Teildokumentationen eines Projektes aufzuheben und alle relevanten Materialien digital zu integrieren. Derartige Datensammlungen werden den Prozess der traditionellen Publikation als Veröffentlichung der Forschungsergebnisse befördern, aber auch ergänzen können, bspw. durch die zusätzliche online-Bereitstellung von nicht in Druckform publizierten Katalogen, Analyseserien, Rekonstruktionen, o.ä.m.

Die hier zusammengetragenen IT-Empfehlungen adressieren vor allem die Frage, wie digitale Daten besser ausgetauscht und für die Zukunft langfristig aufbewahrt werden können, fokussieren also auf technische Formate und die inhaltliche Beschreibung von Daten und Methoden, die für die langfristige Archivierung, Bereitstellung und Nutzbarkeit von Daten von zentraler Bedeutung sind. Spezifische Vorgaben zu fachlichen Methoden, Fragestellungen, Workflows oder Anwendungen sind dagegen nicht Gegenstand der Empfehlungen.

Weitere Informationen zur Relevanz des Forschungsdatenmanagements und der digitalen Kuratierung und Archivierung von Forschungsdaten in den Altertumswissenschaften sind mit Verweisen auf einige Publikationen in den "Guides to Good Practice"⁴ des Archaeology Data Service zu finden.

¹http://www.dfg.de/foerderung/rechtliche_rahmenbedingungen/gwp/index.html

²<http://www.wissenschaftsrat.de/download/archiv/2359-12.pdf>

³<http://www.allianzinitiative.de/de/handlungsfelder/forschungsdaten/grundsaezze>

⁴<http://guides.archaeologydataservice.ac.uk/g2gp/GuideAim>

Umsetzung

In der Regel ist es in bestimmten Phasen eines Projektes oder aufgrund institutioneller Rahmenbedingungen sinnvoll, notwendig und möglich, von diesen IT-Empfehlungen abzuweichen, vor allem während der Generierung und Auswertung von Daten. Da im Folgenden nur minimale Standards beschrieben werden, ist es in der Regel notwendig, darüber hinausgehende Spezifizierungen festzulegen, z. B. Wege zur konkreten Umsetzung von Vorgaben zu definieren, Zuständigkeiten beim Forschungsdatenmanagement zu verteilen oder zusätzliche forschungs- bzw. organisationsspezifische Informationen zu diskutieren. Diese Spezifizierungen sowie Abweichungen von Standards (nicht nur den hier präsentierten) sollten immer sorgfältig abgewogen, hinsichtlich der digitalen Nachhaltigkeit und Austauschbarkeit hinterfragt und ausreichend dokumentiert werden. Zudem gilt es jeweils zu prüfen, ob dadurch ggf. zusätzliche Arbeitsschritte erforderlich werden.

Da Forschungsdaten in hohem Maße von einem zyklischen Charakter geprägt werden, wie beim Lebenszyklus von Daten auf Seite 9 beschrieben, ist die Archivierung von Daten keine Aufgabe, die erst am Ende eines Projektes zu behandeln ist, sondern bereits vor bzw. bei der Erhebung der ersten digitalen Dateien berücksichtigt werden sollte.

Wird z. B. bei Photographien nicht von Anfang an festgehalten, wer an welchem Ort und zu welchem Zeitpunkt ein Bild gemacht hat, oder bei Messungen gerätespezifische Eigenschaften, die die Qualität von Daten bestimmen, nicht dokumentiert, so können diese wichtigen Angaben nach dem Projektende fehlen oder mangels Personal, Gelder oder Möglichkeiten nachträglich nicht mehr erhoben werden. Dateien sind dadurch potentiell in ihrem Wert für eine wissenschaftliche Nachnutzung durch Dritte stark eingeschränkt. Ähnlich kann es sich bei der Verwendung proprietärer Formate verhalten, bei denen einerseits eine Migration auf neuere Programmversionen nur mit inhaltlichen und/oder funktionalen Verlusten einhergeht und andererseits kein Export der Inhalte in anwendungsunabhängige Formate unterstützt wird. In diesem Fall ist ein realer Datenverlust vorhersehbar.

Zur Verwirklichung der hier aufgeführten IT-Empfehlungen sollten Einrichtungen entsprechende Strukturen aufbauen, die IT-Konzepte von Forschungsprojekten begutachten, diese bei der Implementierung eines Forschungsdatenmanagements unterstützen sowie die Qualitätskontrolle, Langzeitverfügbarkeit und -archivierung von Daten ermöglichen.

Für laufende Projekte und „Altdaten“ gilt Bestandsschutz; im Sinne des Langzeiterhalts ist jedoch im Einzelfall zu prüfen, ob die Migration auf die hier festgelegten Standards gerechtfertigt oder zu fordern ist. Der Einsatz von IT und die Verwaltung der Daten ist weiterhin an die Berücksichtigung des Urheberrechts und des Datenschutzes gebunden.

Wann sollten Sie diese Empfehlungen berücksichtigen?

- In der Antrags- und Planungsphase eines neuen Projektes, um frühzeitig technische, personelle und finanzielle Anforderungen und Lösungen berücksichtigen zu können
- Während der Durchführung von Forschungsprojekten als Referenz für spezifische Fragen und Probleme

- Vor der Übergabe von Daten an ein institutionelles Archiv oder Datenrepositorium

Autoren und Quellen der Empfehlungen

Die hier präsentierten Empfehlungen und Hintergrundinformationen beruhen im Wesentlichen auf drei Quellen.

1. **Texte von Fachspezialisten**, die aus unterschiedlichen Institutionen, Disziplinen und Projekten stammen und Vorschläge für die jeweiligen Fachcommunities formuliert haben. Entsprechend werden am Ende der einzelnen Kapitel die maßgeblichen Autoren genannt. Dieser Prozess wurde seit 2007 von der Deutschen Forschungsgemeinschaft angestoßen und unterstützt (u.a. durch die Finanzierung vorbereitender Arbeitstreffen) sowie durch das Deutsche Archäologische Institut in seiner Gesamtheit koordiniert. IANUS hat für die Ergebnisse die technische Plattform bereitgestellt und die redaktionelle Qualitätssicherung übernommen. Ferner verpflichtet es sich, die weitere Pflege und Aktualisierung der IT-Empfehlung durch entsprechende Mitarbeiter und Workflows zu übernehmen sowie ihre Umsetzung durch entsprechende Angebote zu unterstützen.

2. Der auf der Homepage des DAI veröffentlichte "Leitfaden zur Anwendung von Informationstechnik in der archäologischen Forschung"⁵. Ein Teil beschreibt verbindliche Vorgaben, die archäologische Forschungstätigkeiten von der Projektkonzeption, über die Antragstellung, Durchführung, Publikation/Präsentation und langfristige Datenvorhaltung im Zusammenhang mit dem Einsatz von Informationstechniken einhalten müssen. Der begleitende Praxisratgeber gibt einführende Hintergrundinformationen und beschreibt mögliche Verfahrensabläufe zur Umsetzung der Vorgaben in die Praxis. Die Inhalte dieses IT-Leitfadens sind vollumfänglich in die hier formulierten Mindeststandards eingeflossen und wo notwendig aktualisiert bzw. ergänzt worden. Er wird vollständig durch die von IANUS betreuten IT-Empfehlungen abgelöst.

3. **Standards und Veröffentlichungen anderer Einrichtungen**, um die hier formulierten Mindeststandards in den nationalen und internationalen Kontext zu stellen und länderübergreifende Übereinstimmung in Kernfragen zu erreichen. Hervorzuheben sind in diesem Kontext besonders die "Guides to Good Practice"⁶ des Archaeology Data Service in York, England und der Digital Antiquity in Tempe, Arizona, USA, die "How-to Guides"⁷ des Digital Curation Center in London, England und der noch nicht finalisierte "Ratgeber zur Archivierung Digitaler Daten"⁸ des Verbandes der Landesarchäologen in Deutschland.

1.1 Benutzung der IT-Empfehlungen

F. Schäfer, M. Trognitz

Die IT-Empfehlungen für den nachhaltigen Umgang mit digitalen Daten in

⁵<http://www.dainst.org/de/project/it-leitfaden?ft=all>

⁶<http://guides.archaeologydataservice.ac.uk/g2gp/Main>

⁷<http://www.dcc.ac.uk/resources/how-guides>

⁸http://www.landesarcheologen.de/fileadmin/Dokumente/Dokumente_Kommissionen/Dokumente_Archaeologie-Informationssysteme/Dokumente_AIS_Archivierung/Ratgeber-Archivierung_Vorab-V0.07.pdf

den Altertumswissenschaften liegen sowohl in statischer Form als verschiedene PDF-Dateien als auch in dynamischer Form auf <http://www.ianus-fdz.de/it-empfehlungen> vor. Beide Formen sind inhaltlich identisch und können unabhängig voneinander verwendet werden. Die Webseite bietet neben vielfältigen Verlinkungen und Downloads weitere Funktionalitäten, zu denen auch eine Suchfunktion und ein integriertes Glossar gehören. Die PDF-Dokumente eignen sich dagegen z. B. als Hilfsmittel im Feld, das individuell ausgedruckt werden.

Die IT-Empfehlungen umfassen neben diesem Einleitungskapitel die drei Kapitel **Projektphasen**, **Datenformate** und **Forschungsmethoden**.

Aufbau der einzelnen Kapitel

In dem Kapitel **Projektphasen** sind allgemeine Hinweise hinterlegt, die sich mit den konkreten Arbeitweisen und Phasen in Forschungsprojekten befassen. Es enthält Hinweise darauf, was bei der Planung und dem Beginn eines Projektes zu beachten ist, welche Aspekte während der Projektdurchführung, also vor allem bei der Erhebung und Verwaltung von Forschungsdaten, wichtig sind und welche Fragen beim Abschluss eines Forschungsvorhabens beantwortet werden sollten.

Das Kapitel **Dateiformate** beinhaltet einerseits konkrete Hinweise zu den technischen Dateiformaten, die nach heutigem Wissen für die Langzeitarchivierung geeignet sind. Andererseits werden die minimalen Anforderungen an die Dokumentation von Forschungsdaten genannt, damit diese nicht nur heute, sondern auch in Zukunft von Dritten verstanden und nachgenutzt werden können. Diese Abschnitte sind weiter unterteilt in: **Übersicht**, **Vertiefung**, **Praxis** und **Quellen**. Sie verfolgen unterschiedliche Zwecke.

Der Unterabschnitt **Übersicht** bietet eine Zusammenfassung über die jeweils geeigneten technischen Formate, die erforderlichen Metadaten und eventuelle Fehlerquellen. Er richtet sich sowohl an den erfahrenen Anwender als auch an Nutzer mit konkreten, schnell zu beantwortenden Fragen. Die Informationen aus allen Übersichts-Abschnitten werden in einer eigenen PDF-Datei als Kurzfassung der IT-Empfehlung zusammengefasst und zum Download bereit gestellt. Zu beachten ist, dass die angegebenen Metadaten nur ein Minimum darstellen und gegebenenfalls abhängig vom Projektkontext und der verwendeten Methode ergänzt werden müssen.

Der interessierte Nutzer findet in den Unterabschnitten **Vertiefung** weiterführende Hintergrundinformationen über die in der jeweiligen Übersicht angesprochenen Teile und im Abschnitt **Praxis** werden praktische Anleitungen, Vorlagen und Formulare, Best-Practice-Beispiele und andere nützliche Werkzeuge gesammelt, die bei der praktischen Umsetzung der beschriebenen Mindeststandards helfen sollen. Ergänzende Informationen werden in dem Unterabschnitt **Quellen** gelistet.

Das Kapitel **Forschungsmethoden** befasst sich mit den verschiedenen in den Altertumswissenschaften angewandten Methoden und Disziplinen. Auch wenn langfristig eine möglichst hohe Vollständigkeit angestrebt wird, ist es nicht Ziel und Zweck der IT-Empfehlungen, ein umfassendes Handbuch über die Geschichte, Fragestellungen, Anwendung oder Vor-/Nachteile aller relevanten Methoden und Arbeitsweisen zu sein. Stattdessen stehen die Anforderung an die Dokumentation und die Metadaten im Vordergrund, die für die Verstehbarkeit und Nachnutzbarkeit der generierten digitalen Daten durch Dritte zentral sind.

Wie bei den Dateiformaten sind auch hier die einzelnen Abschnitte in **Übersicht**, **Vertiefung**, **Praxis** und **Quellen** untergliedert. Sofern bei einzelnen Disziplinen spezifische Dateiformate eine besondere Relevanz besitzen, sind diese entweder hier beschrieben oder es wird mittels Links auf die entsprechenden Abschnitte im Kapitel „Dateiformate“ verwiesen.

Häufig genutzte oder zentrale Fachbegriffe werden in einem **Glossar** erklärt und sind auf der Webseite unterstrichen. Wenn der Mauszeiger auf einem Wort liegt, wird die Erklärung mittels Tooltip eingeblendet.

In einem **Download-Bereich** können sowohl die verschiedenen längeren und kürzeren Varianten der aktuellen IT-Empfehlungen als auch älteren Versionen heruntergeladen werden. Außerdem sind hier zentrale Dokumente für die Archivierung von Forschungsdaten in IANUS enthalten.

In der **rechten Spalte** findet man Materialien zum Download, die auf den gerade ausgewählten Abschnitt abgestimmt sind.

Zitation der IT-Empfehlungen

Die gesamten IT-Empfehlungen können als eine einzige Publikation betrachtet werden, deren unterschiedliche Kapitel von unterschiedlichen Autoren verfasst wurden. Auf die einzelnen Kapitel kann unter Nennung der Autoren und der Versionsnummer entweder auf die Online-Version oder auf die Vollversion als PDF-Dokument verwiesen werden:

- P. Grunwald - M. Trognitz (2013), „Rastergrafiken“, in: IT-Empfehlungen V1.0. IANUS - Forschungsdatenzentrum Archäologie & Altertumswissenschaften, www.ianus-fdz.de/it-empfehlungen/?q=node/9 (15.03.2013)
- P. Grunwald - M. Trognitz, „Rastergrafiken“, in: IT-Empfehlungen V1.0. IANUS - Forschungsdatenzentrum Archäologie & Altertumswissenschaften (2013) 35 ff.

Mitarbeit und Diskussion

Jeder Abschnitt in den Kapiteln **Dateiformate** und **Forschungsmethoden** enthält einen Unterabschnitt **Diskussion**, der angemeldeten Nutzern die Möglichkeit bietet, Hinweise und Kommentare, z. B. zu nützlichen Softwaretools oder neuen Standards, zu hinterlegen. Ebenso können hier noch fehlende oder unzureichend formulierte Aspekte benannt werden oder gemachte Empfehlungen offen diskutiert werden. Daneben kann natürlich auch eine E-Mail an it-empfehlungen.ianus-fdz@dainst.de geschickt werden, um individuelle Anmerkungen zu formulieren oder die Bereitschaft zur Mitarbeit bei neuen oder zu aktualisierenden Kapiteln zu signalisieren. Alle Rückmeldungen werden regelmäßig von Mitarbeitern in IANUS geprüft und gegebenenfalls in die IT-Empfehlungen eingearbeitet.

1.2 Der Lebenszyklus von Forschungsdaten

M. Trognitz

Die Anforderungen an das Management von Forschungsdaten gehen weit über die Langzeitarchivierung, einer Kernaufgabe von IANUS, hinaus. Daher soll im Folgenden kurz auf das Konzept des Datenlebenszyklus eingegangen werden.

Forschungsdaten haben im Allgemeinen eine deutlich längere Lebensdauer als die Projekte, in denen sie entstanden sind. Auch nach Ablauf von Förderungsphasen kann es sein, dass Forscher weiterhin an den Daten arbeiten oder sie werden in Folgeprojekten weiter verarbeitet und ergänzt. Natürlich können die Daten auch von anderen Wissenschaftlern wiederverwendet werden. Somit können aus bereits gesammelten Forschungsdaten neue Daten entstehen. Dieser Kreislauf wird mit dem sogenannten Datenlebenszyklus beschrieben.

In der gegenwärtigen Praxis ist der Datenlebenszyklus oft unterbrochen, da nur einige wenige Daten ihren Weg in eine Publikation finden. Die übrigen Daten geraten auf den lokalen Speichermedien der Forscher in Vergessenheit oder werden komplett gelöscht und stehen somit einer Nachnutzung nicht mehr zur Verfügung. Diese Tatsache gilt es für die Zukunft zu verbessern und im Idealfall vollständig zu vermeiden.

Der hier vorgestellte Datenlebenszyklus beruht auf dem des „UK Data Archive“⁹. Er beschreibt sehr vereinfacht und idealtypisch die Abfolge der einzelnen Phasen im Zyklus aus einem eher praktischen Umgang mit Forschungsdaten. Es gibt auch andere komplexere Modelle, die einen anderen Blickwinkel beschreiben, wie etwa das „Curation Lifecycle Model“¹⁰, das verschiedene Tätigkeitsfelder bei der Erhaltung und Pflege der Daten beschreibt, und das „Data Curation Continuum“¹¹, das vor allem auf die technischen Bedingungen ein geht und Daten unter dem Gesichtspunkt der Nutzergruppen, von privat bis öffentlich, beschreibt.

In jeder Phase des Datenlebenszyklus gelten unterschiedliche Schwerpunkte mit ihren eigenen Implikationen, die im Folgenden umrissen werden. In dem Kapitel Projektphasen werden die wichtigsten Aspekte dann ausführlich behandelt.

Erstellung Vor der eigentlichen Erstellung von neuen Daten muss schon die Projektplanung erfolgt und die Fragestellung formuliert sein, die maßgeblich bestimmen, wie die gesammelten und erzeugten Daten letztendlich aussehen sollen. Ein Bestandteil der Planung muss auch das Datenmanagement sein, um vorab festzulegen, welche Formate und Benennungsregeln verwendet werden sollen, wie die Speicherung und Sicherung der Daten und die Vernetzung von Daten und Projektmitarbeitern untereinander aussehen soll.



Abb. 1.1: Datenlebenszyklus

⁹<http://data-archive.ac.uk/create-manage/life-cycle>

¹⁰<http://www.dcc.ac.uk/resources/curation-lifecycle-model>

¹¹<http://www.dlib.org/dlib/september07/treloar/09treloar.html>
und http://www.valaconf.org.au/vala2008/papers2008/111_Treloar_Final.pdf

Bereits vorhandene relevante Daten sollten lokalisiert und berücksichtigt werden.

Schon während der Erstellung der Forschungsdaten erfolgt idealerweise die Beschreibung der Daten, da diese besonders im Hinblick auf die spätere Nachnutzung für die Verständlichkeit eine elementare Rolle spielt. Beispielsweise müssen die technischen Parameter der verwendeten Aufnahmegeräte so früh wie möglich dokumentiert werden.

Verarbeitung Sobald die Daten erhoben wurden, können sie verarbeitet werden. Dazu gehören verschiedene Abläufe, wie etwa Digitalisierung, Übersetzung, Überprüfung, Validierung, Bereinigung und andere Verarbeitungsformen mittels Programmen. Für einige Anwendungen oder im Hinblick auf eine spätere Veröffentlichung, kann eine Anonymisierung notwendig sein. Auch gilt es festzuhalten, wie Ausgangsdaten verändert und bearbeitet wurden.

Außerdem ist die Beschreibung von Forschungsdaten ein wichtiger Aspekt für die Archivierung, um die Verständlichkeit für die spätere Nachnutzung deutlich zu erhöhen. Während der Verarbeitung von Forschungsdaten spielt die Verwaltung und Speicherung der Daten eine große Rolle, da gewährleistet werden muss, dass mit der richtigen Version gearbeitet wird und notfalls auch Sicherheitskopien zur Verfügung stehen.

Analyse Durch die Analyse und Interpretation der Forschungsdaten werden die Forschungsergebnisse gewonnen, die dann in Publikationen veröffentlicht werden. In der Regel sind die den neuen Erkenntnissen zugrunde liegenden Daten aber nur ein kleiner Bestandteil einer solchen Publikation. Jedoch werden alle Daten benötigt, um die Analyseergebnisse vollständig nachvollziehen zu können.

Archivierung Die Archivierung von Forschungsdaten beinhaltet die Auswahl und Umwandlung der einzelnen Dateien in geeignete Formate und deren Speicherung auf einem für die Archivierung geeigneten Medium. Die Erstellung und Speicherung von Backups gehört ebenfalls dazu.

Eine wesentliche Rolle bei der Archivierung spielt sowohl die strukturierte als auch die freie Beschreibung der Forschungsdaten, da diese Informationen darüber enthalten, wie und durch wen die Daten gewonnen wurden, welche Geräte dabei Verwendung fanden, wie diese konfiguriert waren und was die Daten bedeuten.

Zugang Da das Ziel einer Datenarchivierung immer die Nachnutzbarkeit von Inhalten ist, sollten archivierte Daten im Rahmen rechtlicher Rahmenbedingungen verbreitet und Dritten ein Zugriff auf diese gewährt werden. Den Zugriff auf die Daten kann man mit verschiedenen Zugriffsrechten steuern, die es beispielsweise nur einer eingeschränkten Gruppe von Nutzern erlauben auf die Daten zuzugreifen. Bevor die Daten zugänglich gemacht werden, sollte man dafür sorgen, dass das Urheberrecht geklärt und gekennzeichnet ist.

Durch die Zugriffsgewährung wird die Sichtbarkeit von eigenen Forschungsleistungen erhöht.

Nachnutzung Zugängliche archivierte Daten können für eigene Forschungsvorhaben kostenlos wiederverwendet und neuen Analysen unterzogen werden. Durch die Nachnutzung wird die Nachprüfbarkeit von Ergebnissen im Sinne der guten wissenschaftlichen Praxis erleichtert.

1.3 Archivierung von Forschungsdaten in IANUS

In diesem Abschnitt werden Informationen zu finden sein, die sich speziell auf den Archivierungsablauf in IANUS beziehen.

2 | Projektphasen

F. Schäfer

Im Umgang mit digitalen Daten gelten für jede Phase eines Forschungsprojektes unterschiedliche Anforderungen und Bedingungen. Da Forschungsdaten einem Lebenszyklus (siehe Seite 9) unterliegen, haben Entscheidungen und Arbeitsschritte, die in einer bestimmten Phase getroffen werden, auch Auswirkungen auf die anderen Phasen des Datenkreislaufs. Bereits bei Entwurf und Planung eines neuen Forschungsprojektes muss überlegt werden, welche Informationen bereits digital existieren, welche Arten von Dateien neu erzeugt werden müssen, welche Informationstechnologien zum Einsatz kommen sollen und wie das Management der Forschungsdaten gestaltet sein wird.

Insofern gilt es einige Aspekte so früh wie möglich, häufig noch vor der Erstellung der ersten Datei, zu adressieren:

- Informationen über existierende Standards und Richtlinien einholen
- Entscheidungen über die zu verwendenden Dateiformate und Softwareprogramme fällen
- Verantwortliche für das Datenmanagement bestimmen
- Kriterien für die laufende Dokumentation entwickeln
- Konventionen für die Benennung und Versionierung von Dateien festlegen
- Strategien zur Speicherung und Sicherung definieren
- Geeignete Infrastrukturen für die Archivierung auswählen und kontaktieren

Diese und weitere Fragen zur Vorbereitung, Durchführung und Nachbereitung eines Projektes werden im Folgenden thematisiert.

Je mehr und je früher in den Einzelentscheidungen die Nachnutzung der Daten durch Dritte auch über die Lebensdauer eines Projektes hinaus berücksichtigt wird und die Langzeitarchivierung als kontinuierliche Maßnahme und nicht als letzter Schritt eines bereits abgeschlossenen Projektes begriffen wird, umso leichter gelingt es, einmal erhobene Daten auch für die Zukunft zu erhalten.

Das Finanzierungskonzept eines Forschungsprojektes sollte neben Hard- und Softwareausstattung ausdrücklich angemessene Anteile für Personalkosten und Dienstleistungen berücksichtigen. Im Zweifelsfall ist es ratsam, sich hierbei beraten zu lassen. Ab einer bestimmten Projektgröße bzw. Umfang der zu prozessierenden Daten sollten eine oder mehrere Personalstellen eingeplant werden, die überwiegend oder ausschließlich für IT-Belange zuständig sind.

Abweichungen von den hier aufgeführten Empfehlungen sind nicht auszuschließen, doch sollten diese bewusst diskutiert und in Abwägung der jeweiligen Vor- und Nachteile entschieden werden.

2.1 Vorlauf und Planung

- 2.1.1 Antragsstellung
- 2.1.2 Vor der Datenerhebung

2.2 Durchführung

M. Trognitz

Um die Archivierung der Daten nach Abschluss eines Projektes zu erleichtern, sollte schon während der Durchführung eines Projektes auf die konsequente Erfüllung folgender Aufgaben geachtet werden:

- Die parallele Dokumentation während der Erstellung und Prozessierung der Daten
- Die Ablage der Daten in einer vorher festgelegten Ordnerstruktur und die Einhaltung von Namenskonventionen
- Das Erstellen von Sicherungskopien der Daten
- Die Sammlung von Rohdaten, wichtigen Arbeitsschritten und finalen Dokumenten in einem separaten Archiv-Ordner

Vor oder kurz nach Beginn des Projektes erstellte und kommunizierte Richtlinien, ermöglichen es allen Projektmitarbeitern diese auch einzuhalten. Auf diese Weise wird die Handhabung der Projektdaten erheblich erleichtert, da geregelte Ordnerstrukturen und vorgegebene Namenskonventionen das Auffinden der Daten vereinfachen, die parallele Dokumentation das Verstehen und die Nachnutzung ermöglicht und Sicherungskopien das Risiko eines Datenverlustes reduzieren.

2.2.1 Dokumentation

S. Jahn

Neben technischen Aspekten ist eine vollständige Dokumentation das wichtigste Kriterium für die Archivierung und Nachnutzbarkeit von Daten. Damit Forschungsdaten von Dritten gefunden und sinnvoll verwertet werden können, müssen sie verständlich und strukturiert beschrieben werden. Ohne zusätzliche Informationen sind die meisten digitalen Dateien, die in einem Forschungsprojekt entstehen, für die Wissenschaft verloren und ist der Aufwand einer langfristigen Datenkuratierung vergeblich. Die Dokumentation und Beschreibung von Daten ist als ein kontinuierlicher Prozess zu begreifen, der in allen Phasen eines Datenlebenszyklus adressiert werden sollte.

Der folgende Abschnitt vermittelt einen Überblick über die Thematik. Es wird sowohl auf die Dokumentation von Projektdaten in freier, beschreibender Form eingegangen als auch der Unterschied zu strukturierten, maschinell verarbeitbaren Metadaten erklärt. Auch werden die verschiedenen Arten von Metadaten erläutert, die Relevanz von einheitlichen Begriffen und Vokabularen hervorgehoben, Hinweise zur Strukturierung von Metadaten gegeben sowie unterschiedliche Arten der Metadaten-Speicherung skizziert.

Ein weiteres Kapitel widmet sich Metadaten in der Anwendung. Hier sind Vorlagen für Metadaten zu finden, die sich einmal auf die Beschreibung ganzer Projekte oder Dokumentensammlungen beziehen und einmal auf einzelne Dateien. Die hier aufgeführten Kriterien bilden auch die Grundlage für die Beschreibung von Daten, die über IANUS archiviert werden sollen.

2.2.1.1 Dokumentation und Metadaten

Bei der Durchführung eines Projekts werden Daten erhoben, analysiert, ausgetauscht und gespeichert. Dies geschieht in der Regel in zyklischen oder sich wiederholenden Prozessen, wie die Ausführungen zum Lebenszyklus von Forschungsdaten auf Seite 9 veranschaulichen. Zu festgelegten Zeitpunkten sowie am Ende von Projekten werden üblicherweise Berichte und Publikationen erzeugt, die die Fragestellung, die angewandte Methode, den untersuchten Gegenstand und die Ergebnisse beschreiben und dokumentieren. Diese können in den Altertumswissenschaften ergänzt werden durch weitere Dokumente wie beispielsweise Tagebücher, Kataloge, Listen, Fotos, Abbildungen, Zeichnungen, Pläne, Karten, Messreihen, Tabellen, Diagramme, Modelle, Filme, Animationen und andere Informationsobjekte. Die Dokumente können dabei nur in analoger Form, in analoger und digitaler oder ausschließlich digital vorliegen. Bei Daten, die direkt mit Hilfe elektronischer Geräte erzeugt wurden und daher zumeist nur digital existieren, wird von *digital born data* gesprochen.

Viele Dokumente und Dateien sind nicht aus sich selbst heraus verständlich. Sie stehen immer in einem gewissen Forschungs- oder Projektkontext, der für die Nachnutzung dokumentiert werden sollte. Welche Informationen sind hierbei erforderlich? Wichtig sind alle Angaben, die den Entstehungsprozess und -kontext sowie die Konventionen von Inhalten und Daten beschreiben oder zumindest skizzieren, damit andere Personen die Daten auffinden, die Inhalte richtig verstehen und sinnvoll für weitere Forschungen verwenden können. So ist es beispielsweise üblich, bei Fotografien das Aufnahmedatum, eine Kurzbeschreibung des abgelichteten Objektes, den Fotografen und eine Inventarnummer anzugeben, Zeichnungen mit einem Maßstab, der geographischen Ausrichtung, dem Zeichner und einem Kurztext zu beschriften oder bei Texten einen Autor, einen Titel und ein Datum zu nennen.

Noch stärker als bei einer rein analogen Dokumentation sind bei digitalen Daten zusätzliche, spezialisierte Informationen erforderlich, die über die rein deskriptiven Angaben zu den Inhalten und zum Forschungsinteresse hinausgehen und nicht nur die primären Fragen zu „*Wer, Wie, Was, Wo, Wann und Warum?*“ beantworten. So sind etwa technische und administrative Angaben über die Vorgehensweise der Datenerhebung und die eingesetzten Programme, mit denen die Daten erzeugt oder digitalisiert wurden, für ein späteres Auslesen, Auswerten und Interpretieren von Forschungsdaten unverzichtbar. Auch wie die Daten strukturiert wurden und in welcher Beziehung Dateien zueinander stehen, muss in der Regel explizit erklärt werden. Angaben zu Qualitätssicherungsverfahren, Änderungshistorie und Versionierung von Daten erlauben es das empirische Vorgehen im Forschungsprozess nachzuprüfen. Zudem ist wichtig zu erklären, wie Dritte zukünftig auf die Daten zugreifen oder sie nutzen dürfen.

Damit unbeteiligte Personen den größeren Zusammenhang einer einzelnen Information oder Datensets verstehen und nachvollziehen können, sollte jede Dokumentation eines Projektes mindestens folgende Punkte enthalten:

- Angaben zur Fragestellung und zur Auswahl des Untersuchungsgegenstandes
- Angaben zu den Projektverantwortlichen für Nachfragen
- Zusammenfassung der wissenschaftlichen Ergebnisse
- Beschreibung von Arbeitsabläufen und Methoden, vor allem bezüglich der Datenerhebung, -verarbeitung und Qualitätssicherung
- Auflistung der erzeugten unterschiedlichen Dokumentarten (z. B. Tagebücher, Berichte, Listen, Fotos, etc.)
- Beschreibung von verwendeten Handbüchern, Standards, projektspezifischen Konventionen, Nummernsystemen, etc.
- Auflistung der eingesetzten technischen Geräte und Programme
- Relevante Publikationen und wichtige Sekundärliteratur
- ggf. wichtige Korrespondenzen, Verträge, Anträge, etc. (in anonymisierter Form)
- Bestimmungen zur weiteren freien oder eingeschränkten Verwendung von Daten

Ein spezifischer Bestandteil einer jeden Dokumentation sind die sog. Metadaten. Während die Dokumentation die Summe aller Angaben zu einem Projekt und der zugehörigen Daten umfasst und sie in Form, Inhalt, Länge und Struktur je nach fachlichen Gegebenheiten völlig frei formuliert sein kann, sind die Metadaten nach festen formalen Kriterien strukturiert (z. B. als Formulare oder Eingabemasken) und geben nur die wichtigsten Kontextinformationen in knapper Form (z. B. als Stichworte) wieder. Aufgrund der Art der Speicherung von Metadaten, beispielsweise als Listen, Tabellen, Datei-Header oder Textauszeichnungen, können sie maschinell verarbeitet werden.

Dadurch dass Metadaten die Eigenschaften von anderen Daten beschreiben, ohne diese selbst zu enthalten, und die fachlich oder organisatorisch notwendigen Kontextinformationen explizit machen, dienen sie dazu, relevante Informationen zu finden, zu identifizieren, auszuwählen und zu verwalten. Beispielsweise sind Fotos nur anhand der mit ihnen assoziierten beschreibenden Metadaten effizient durchsuch- und auffindbar oder Karten nur dank einer Maßstabsangabe und mit einer aussagekräftigen Legende wissenschaftlich nutzbar. Die NISO definiert Metadaten als Werkzeuge, um Forschungsdaten nachhaltig zu managen, zu erschließen, zu verstehen und zu benutzen.

Die Dokumentation eines Projektes und die Erzeugung von Metadaten über Forschungsdaten sollte als ein wichtiger, kontinuierlicher Prozess verstanden werden, der von Anfang an berücksichtigt und während des gesamten Lebenszyklus von Daten umgesetzt wird – und nicht erst nach Abschluss von Arbeiten oder bei Übergabe von Beständen an ein Archiv. Insofern bedarf es innerhalb von größeren Projekten eines Verantwortlichen oder einer Organisationsform aller Beteiligten, der bzw. die die Struktur und Pflege der Dokumentation konzeptionell und koordinierend begleitet. Gemeinsam muss definiert werden, welcher Gegenstand dokumentiert wird, in welchem Umfang und mit welcher Gliederung, welche Form geeignet ist (z.B. Wiki versus PDF), wie die Aktualität der

Inhalte erhalten wird, wie Nutzer über Änderungen informiert werden, usw. Fehlende Strategien für den Aufbau und die Pflege einer Dokumentation führen häufig zu Unübersichtlichkeit und dadurch zu einer Ablehnung der beteiligten Akteure. Von umfassenden, detaillierten und strukturierten Angaben zu digitalen Daten profitieren nicht nur die Archive und zukünftige Generationen von Forschern, sondern auch die Wissenschaftler selbst bereits während der Durchführung eines Projektes – genauso wie es auch bei analogen Dokumenten und Objekten der Fall ist.

Nur wenn Daten ausreichend fachlich wie technisch dokumentiert werden, können sie durch andere Personen wissenschaftlich nachgenutzt werden und besitzen sie einen Wert für die Zukunft. Nur dann lohnt sich auch der Aufwand einer analogen oder digitalen Langzeitarchivierung.

2.2.1.2 Arten von Metadaten

Da Metadaten immer von unterschiedlichen Informationsbedürfnissen und Anwendungskontexten abhängig sind, lassen sie sich unter verschiedenen Blickwinkeln betrachten und nach Arten zusammenfassen.

Metadaten können, egal ob sie ein Forschungsvorhaben in seiner Gesamtheit oder den Inhalten eines einzelnen Dokuments beschreiben, sich auf folgende Aspekte beziehen:

- Deskriptive Angaben, die ein Projekt, ein Objekt oder eine Methode fachlich-inhaltlich näher beschreiben (z. B. Kurzbeschreibung eines Fotos, Laufzeit eines Forschungsvorhabens, Autor eines Textes)
- Strukturelle Angaben, welche die physischen oder logischen Beziehungen zwischen komplexen Objekten beschreiben (z. B. referenzierte Dateien in Zeichnungen, die Reihenfolge von Fotos)
- Administrativ-rechtliche Angaben, die Rechteinhaber, Lizenzbedingungen und Zugangsregeln benennen und für das Management eines Objektes relevant sind (z. B. Fristen für die Veröffentlichung von Ergebnissen)
- Administrativ-erhaltungsbezogene Angaben, welche die Geschichte eines digitalen Objektes, also die vorhergehenden und gegenwärtigen Zustände, nachvollziehen lassen und Erhaltungsmaßnahmen beschreiben (z. B. Angabe zur Herkunft einer Karte, Konvertierungsmaßnahmen)
- Technische Angaben, die Informationen zu Software und Hardware liefern (z. B. ein Dateiformat eines Bildes, die Zeichencodierung eines Textes oder technische Parameter eines Messgerätes)

Ein anderes Unterscheidungskriterium von Metadaten ist der Umfang der Daten, die durch sie beschrieben werden. So können sie sich beziehen auf:

- Eine größere zusammenhängende Datensammlung, sog. Kollektionen (z. B. der gesamte Datenbestand eines Projektes)
- Eine einzelne Datei
- eine einzelne Information innerhalb eines Systems (z. B. ein Datensatz in einer Datenbank)

Während für ein laufendes Projekt eventuell nur ein Ausschnitt dieser Metadaten eine praktische Relevanz besitzt, sind für die digitale Langzeitarchivierung von Dokumenten alle Aspekte gleichberechtigt wichtig. Einige der Metadaten können ausschließlich von beteiligten Personen frühzeitig während des Prozesses der Datenerzeugung erfasst werden und sollten es auch, da nur sie den Inhalt, den Charakter, die Struktur, den Kontext und die Quellen der Daten kennen. Andere dagegen lassen sich auch erst zu einem späteren Zeitpunkt bei der Archivierung und Veröffentlichung von Daten generieren. Technische Metadaten zum ursprünglichen Dateiformat und zur Hardware- und Softwareumgebung werden benötigt, um Daten in veralteten Dateiformaten in neuere umwandeln oder um die ursprüngliche Programmumgebung mittels aktueller Technik nachbauen zu können.

Außerdem kann bei Metadaten Unterschiede zwischen solchen, die eine manuelle Eingabe erfordern, und anderen, die durch Systeme und Programme automatisch erzeugt werden können.

2.2.1.3 Kontrollierte Vokabulare

Damit Metadaten möglichst sinnvoll genutzt und maschinell verarbeitet werden können, ist es notwendig möglichst einheitliche Begriffe und homogene Beschreibungen zu verwenden. Nur wenn gleiche Dinge auch mit den gleichen Begriffen benannt werden, ist es möglich vollständige und präzise Suchergebnisse zu erhalten oder vergleichbare Daten richtig miteinander zu verknüpfen. Die Vorgabe und Definition von festen Begriffen und Regeln hilft zudem, Mehrdeutigkeiten und Redundanzen zu vermeiden, etwa wenn eine Zeichenkette verschiedene Bedeutungen besitzen kann (z. B. Abakus als Rechenhilfsmittel oder als architektonischer Abschluss eines Kapitells), ein identischer Sachverhalt durch unterschiedliche Worte erfasst werden kann (z. B. Survey und Oberflächenbegehung) oder die Form der Angabe variieren kann (z. B. das Datum 12.03.2012 oder 2012-03-12).

Das geeignete Mittel zur Vereinheitlichung der sprachlichen Vielfalt sind so genannte kontrollierte Vokabulare, die entweder einfache Wortlisten oder strukturierte Thesauri sein können, in denen Wörter zusammen mit ihrem semantischen Kontext verwaltet werden. Diese „terminologische Kontrolle“ kann in unterschiedlicher Weise systematisiert und implementiert sein. Beispielsweise kann sie durch projektinterne, kontrollierte Vokabulare erfolgen. Dazu werden alle verwendeten Worte innerhalb eines Projektes unter allen Beteiligten abgestimmt, klar fachlich definiert bzw. voneinander abgegrenzt und in strukturierter Form dokumentiert. Diese Absprachen können dann in einem zentralen Textdokument als Projektleitfaden abgelegt oder in einer Datenbank als Felder umgesetzt werden, die nur eine begrenzte Auswahl von Begriffen zur Beschreibung eines spezifischen Sachverhaltes zulassen (z. B. für das Attribut Filmart nur die Werte Diapositiv (Farbe) – Negativfilm (Farbe) – Negativfilm (SW) – Digital erlauben).

Daneben existieren etablierte, standardisierte, projektunabhängige Thesauri und Vokabulare, die häufig eine fachspezifische oder institutionelle Ausprägung aufweisen und von maßgeblichen Einrichtungen kontinuierlich gepflegt und verbreitet werden. So ist es etwa im Bibliothekssektor üblich, Publikationen mit Schlagworten aus einem gemeinsamen Wörterkatalog zu versehen, damit verschiedene Werke einheitlich beschrieben werden und die Auffindbarkeit von

Werken zu einer bestimmten Thematik überall nach den gleichen Kriterien erfolgen kann. Bereits existierende Thesauri und Vokabulare sollten bei der Vergabe von Metadaten möglichst berücksichtigt und angewendet werden. Insofern gilt die Empfehlung, sich frühzeitig zu informieren, welche einschlägigen kontrollierten Vokabulare vorhanden sind und in einem Projekt genutzt werden können. Abzuwegen ist dabei, ob die Verwendung bestehender Standardvokabulare dem Detailinteresse oder der neuen Erkenntnis in der Forschung gerecht werden, da eine Aktualisierung sich in der Regel nur sehr langsam vollzieht und sehr vom organisatorischen Rahmen der Institution bzw. eines Gremiums abhängt, in dessen Verantwortung die Weiterentwicklung liegt. Trotz dieser Einschränkung überwiegen langfristig aber die Vorteile, wenn existierende Thesauri und Vokabulare verwendet werden, da dies auch den elektronischen Austausch, die Interoperabilität, der eigenen Daten mit anderen Systemen erheblich vereinfacht.

Wenn Ressourcen in mehreren Sprachen vorliegen und entsprechend multilingual beschrieben werden sollen, müssen die genutzten Wörterbücher, Thesauri und Schlagwortsysteme äquivalente Begriffe in mehreren Sprachen abbilden.

2.2.1.4 Struktur von Metadaten

Neben der Verwendung einheitlicher, möglichst weit verbreiteter Begriffe stellt die Struktur und der Umfang von Metadaten ein wesentlicher Faktor dar, um diese sinnvoll nutzen zu können. Die Art und Weise, wie die verschiedenen Informationen erfasst und organisiert werden, spielt eine wesentliche Rolle, ob sie von einer unbeteiligten dritten Person richtig verstanden werden und ob Computer die Angaben automatisiert maschinell verarbeiten können. Wie bei den Vokabularen existieren auch hierfür verschiedene Standards, die als sogenannte Metadatenschemata den Inhalt und die Gliederung von Metadaten verbindlich beschreiben und die bei der Vergabe von eigenen Metadaten berücksichtigt werden sollten. Für viele Bereiche, wie etwa Medienarchive, Bibliotheken oder Museen, gibt es langjährige Erfahrungen und entsprechende eigene Vorgaben.

Ein Metadatenschema definiert die verwendeten Metadaten-Kategorien. Beispielsweise kann eine Publikation mit den Elementen Autor – Jahr – Titel – Reihe – Verlag – Erscheinungsort und Schlagworte beschrieben werden, die dann mit den entsprechenden Informationen gefüllt werden. Diese Minimalbeschreibung kann je nach Bedarf erweitert werden, z. B. um die Elemente Sprache – Seitenzahl – Abbildungszahl – Auflage und ISBN-Nummer. In einem Metadatenschema wird zudem für einzelne Informationen die Genauigkeit (die Granularität) der erwarteten Information festgelegt, also z. B. ob für die Angabe Autor eine freie Texteingabe ausreichend ist oder ob eine Aufteilung in die Attributte Anrede – Titel – Vorname(n) und Nachname sowie eine Referenz zu einer Personennormdatei erforderlich ist.

Für den Austausch von Metadaten zwischen verschiedenen technischen Systemen besitzen die zugrunde liegenden Schemata eine zentrale Bedeutung. Sollen Informationen aus unterschiedlichen Quellen miteinander in Beziehung gesetzt werden, so dass sie gemeinsam ausgewertet werden können, müssen die Informationen auf der Ebene ihrer semantischen Bedeutung miteinander verknüpft und ggf. abgeglichen werden. Das heißt neben dem eigentlichen Wert (z. B. der Zeichenkette „Pompeji“) muss auch die Eigenschaft angegeben werden, die durch diesen Wert beschrieben wird (z. B. das Metadatum Fundort oder Aufbewahrungsplatz oder Publikationsort).

Je internationaler und standardisierter ein verwendetes Schema ist, desto besser ist die Austauschbarkeit von Metadaten mit anderen Systemen gewährleistet. Sofern sich unterschiedliche Metadaten auf ein gemeinsames Metadatenschema abbilden lassen, können sie in ein drittes System importiert und dort zusammen geöffnet werden.

Das am weitesten verbreitete und ISO-zertifizierte Metadatenschema ist „Dublin Core“. Es verfügt über folgende 15 Kernfelder, die jeweils individuell definiert sind: Mitwirkender – Geltungsbereich – Urheber – Zeitangabe – Beschreibung – Format – Identifikator – Sprache – Verleger – Beziehung – Rechte – Quelle – Thema – Titel – Typ.

Eine besondere Relevanz im archäologischen und altertumswissenschaftlichen Kontext haben zudem folgende Standards erlangt:

- ADeX – Archäologischer Datenexport-Standard für den Austausch archäologischer Fachdaten, erarbeitet von der Kommission „Archäologie und Informationssysteme“ im Verband der Landesarchäologen (VLA).
- CIDOC Conceptual Reference Modell (CIDOC-CRM) als erweiterbare Struktur für Begriffe und Informationen im Bereich des Kulturerbes, erstellt von der Arbeitsgruppe „Dokumentationsstandards“ im Internationalen Komitee für Dokumentation (CIDOC) des internationalen Museumsverbandes (ICOM).
- Lightweight Information Describing Objects (LIDO) und museumdat als Austauschformate für bewegliche Objekte in Museen, herausgegeben von der Fachgruppe Dokumentation des Deutschen Museumsbundes und von der Arbeitsgruppe „Data Harvesting and Interchange“ im Internationalen Komitee für Dokumentation (CIDOC).
- Connecting Archaeology and Architecture in Europeana (CARARE) Metadaten Schema als archäologiespezifisches Datenmodell unter Berücksichtigung verschiedener europäischer Standards, herausgegeben von Projekt-partnern innerhalb von Europeana.

2.2.1.5 Speicherung von Metadaten

Für eine strukturierte Speicherung von Metadaten gibt es verschiedene Möglichkeiten und Wege, die einerseits von dem Zeitpunkt (synchron mit der Datenerhebung oder im Nachhinein) und andererseits von der Art der Metadatenerfassung (manuell oder automatisiert) abhängen. Grundsätzlich sollte man sich bewusst machen, dass Metadaten so früh wie möglich, also bereits bei der Generierung von neuen digitalen Objekten oder am Anfang eines neuen Forschungsvorhabens vergeben werden sollten, selbst wenn diese noch nicht vollständig gemacht werden können. Die Erfahrung zeigt, dass viele Informationen sich im Nachhinein (z. B. am Ende eines Projektes oder am Ende eines Arbeitsverhältnisses) nicht mehr ermitteln lassen oder in Vergessenheit geraten. Je nach Art der Metadaten und der Veränderlichkeit des beschriebenen Objektes ist eine regelmäßige Aktualisierung und kontinuierliche Metadatenpflege erforderlich.

Der einfachste Fall liegt dann vor, wenn Metadaten sich auf eine einzelne Datei beziehen und von dem Gerät oder dem Programm, dass die Datei erzeugt, automatisch generiert werden. Beispielsweise können bei digitalen Fotos von der Kamera automatisch technische Angaben zum Dateiformat, Verschlusszeit,

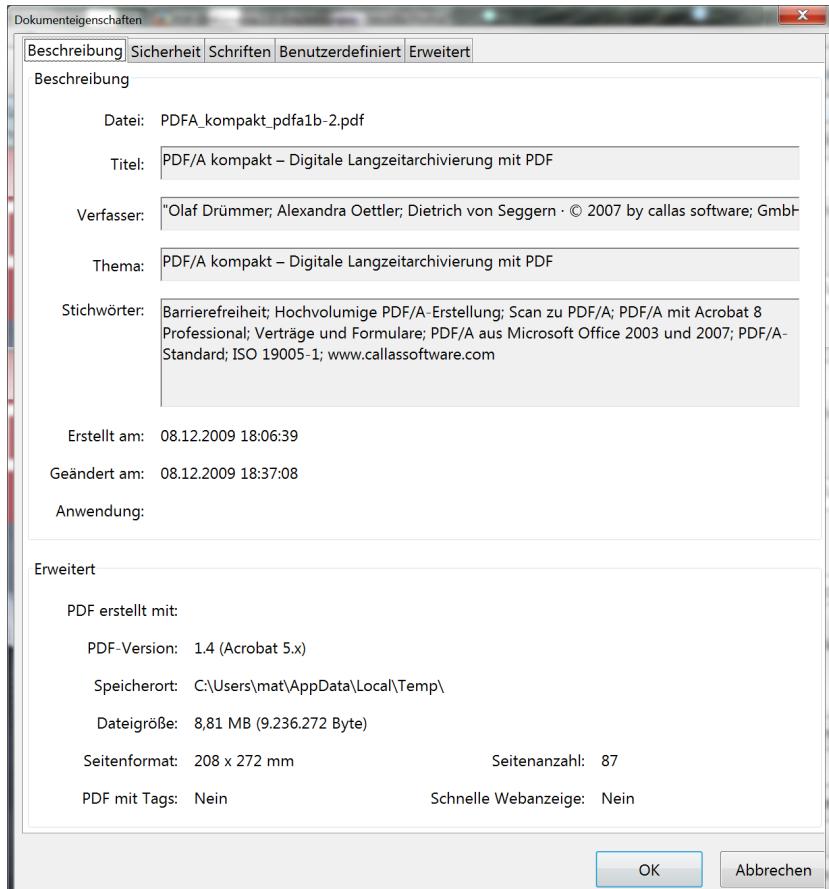


Abb. 2.1: Beispiel für Metadaten für ein PDF im Programm Adobe Reader. Die Metadaten können unter „Datei > Eigenschaften“ angezeigt werden.

Blendenöffnung, Farbinformationen, usw. ermittelt und direkt in der Bilddatei hinterlegt werden. Je nach Gerät können über die Voreinstellungen auch deskriptive Informationen wie Fotograf, Aufnahmedatum, Land, etc. hinzugefügt werden. Ähnliche Verfahren zur automatischen Metadatenerzeugung sind auch bei Vermessungsgeräten weit verbreitet.

Die durch die Geräte generierten Metadaten werden unmittelbar in einem besonderen Bereich und auf standardisierte Weise in der resultierenden Datei gespeichert, etwa bei Fotos üblicherweise im sog. Exif-Format. Diese Informationen können über die Eigenschaften einer Datei angezeigt und mit Hilfe von bestimmten Programmen auch verändert und ergänzt werden. In Abbildung 2.1 sind die Dateieigenschaften eines PDF-Dokumentes zu sehen.

Die Möglichkeit, Metadaten direkt in einer Datei zu integrieren, bieten auch verschiedene Programme an, etwa zur Verarbeitung von Texten, Zeichnungen und Geodaten. Hierbei ist in der Regel eine manuelle Eingabe in entsprechende software- und dateitypspezifische Formulare erforderlich. Bei der Auswahl von Anwendungen sollte darauf geachtet werden, ob diese spezifische Metadaten

entweder als separate Datei exportiert oder ob sie mit den Dateien, in denen sie enthalten sind, auch unabhängig von der ursprünglichen Software geöffnet werden können.

Bei Textdokumenten, die auf expliziten Auszeichnungssprachen basieren (z. B. HTML-, XML-, TEI-, SVG-Dateien), lassen sich die Metadaten ebenfalls einfach in die Datei integrieren, da sie am Anfang des Dokumentes mit speziellen Elementen (sog. Tags) platziert werden können.

Eine andere Form der Metadatenspeicherung besteht darin, die Angaben in separaten Dateien oder Systemen zu speichern und zu verwalten. Die häufigste Form sind dabei Tabellen und Datenbanken, da dort eine manuelle Erfassung, z.T. mithilfe spezifischer Eingabemasken, eine gezielte Suche und eine strukturierte Sicherung von Metadaten möglich ist. Auch hier besteht prinzipiell die Möglichkeit, Metadaten (teil-)automatisiert erzeugen zu lassen, z. B. das Datum der letzten Bearbeitung eines Datensatzes und den Namen des Bearbeiters. Ein weiterer Vorteil besteht in der effizienten Bearbeitung, wenn ein einzelnes Merkmal für mehrere Dokumente identisch ist, z.B. wenn alle Zeichnungen eines Projektes den gleichen Maßstab besitzen.

Da bei dieser Form der Metadatenspeicherung die Metadaten von den digitalen Objekten, die sie beschreiben, physisch getrennt sind, muss in besonderer Weise darauf geachtet werden, dass die Beziehungen zwischen beiden Einheiten eindeutig und aktuell sind. Wird etwa bei den Metadaten der Name einer Datei zur Identifizierung verwendet, muss sichergestellt werden, dass dieser einmalig ist (ggf. in Kombination mit seinem Speicherort) und dass im Falle der Umbenennung der Datei der Eintrag auch bei den Metadaten aktualisiert wird.

Die Erfassung von Metadaten in einer Freitextdatei sollte vermieden werden, da diese häufig nicht automatisiert durch Computer überprüft und verarbeitet werden können.

Bei Dokumenten mit Textinhalt können beschreibende Metadaten auch automatisch erzeugt werden, indem nach charakteristischen Zeichenketten gesucht wird und Schlag- und Stichworte extrahiert werden. Allerdings reicht die Qualität einer automatischen Erschließung bislang nicht an eine manuelle und intellektuelle Metadatenvergabe heran. Da eine Maschine ein Dokument nicht verstehen kann, ist sie auch nicht in der Lage, ausschließlich sinnvolle Deskriptoren herauszufiltern.

Für die Übergabe von Dateien und Metadaten an ein Langzeitarchiv gilt die Empfehlung, die Metadaten sowohl in den Originaldateien selbst als auch in einem separaten, strukturierten und zeichenbasierten Dokument vorzuhalten: in den Originaldateien selbst, um keine verwaisten, d. h. undokumentierten Werke zu erzeugen; als separate Textdatei, um eine automatisierte Verarbeitung und den Austausch von Referenzangaben zu vereinfachen.

2.2.1.6 Weiterführende Informationen

Metadaten allgemein

Gesis: Dokumentation und Metadaten

<http://www.gesis.org/archive-and-data-management-training-and-information-center/forschungsdatenmanagement/dokumentation-und-metadaten/>

Understanding Metadata: National Information Standards Organization
<http://www.niso.org/publications/press/UnderstandingMetadata.pdf>

Archaeology Data Service: Guides to Good Practice - Project Metadata
http://guides.archaeologydataservice.ac.uk/g2gp/CreateData_1-2

Kontrollierte Vokabulare

J. M. Lill, Kontrolliertes Vokabular. Wieso? Weshalb? Warum? (2012)
http://swop.bsz-bw.de/volltexte/2012/1002/pdf/Lill_Textfassung_VortragDMB2012.pdf

J. Lindenthal, Normen und Standards für Thesauri (2013)
<http://www.jlindenthal.de/standards.html#normen>

W3C: Standards: Semantic Web: Vocabularies
<http://www.w3.org/standards/semanticweb/ontology>

Metadatenstandards

nestor: Standardisierung – Metadaten
<http://www.langzeitarchivierung.de/Subsites/nestor/DE/Standardisierung/Metadaten.html>

Deutsche Initiative für Netzwerkinformation: Kompetenzzentrum
Interoperable Metadaten (KIM)
<http://www.dini.de/ag/standards/>

U. Jensen – A. Katsanidou – W. Zenk-Möltgen, Metadaten und Standards, in:
S. Büttner – H.-C. Hobohm – L. Müller (Hrsg.), Handbuch
Forschungsdatenmanagement (2011) 83-100
http://opus4.kobv.de/opus4-fhpotsdam/files/198/2.4_Metadaten_und_Standards.pdf

J. Riley – D. Becker, Glossary of Metadata Standards (2010)
http://www.dlib.indiana.edu/~jenrile/metadatamap/seeingstandards_glossary_pamphlet.pdf

Metadatenschemas

Dublin Core Metadata Initiative
<http://dublincore.org/>

ADeX – Standard für den Austausch archäologischer Fachdaten
<http://www.landesarchaeologen.de/verband/kommissionen/archaeologie-und-informationssysteme/projektarbeitsgruppen/adex/>

ARIADNE – D3.1 Initial Report on the project registry
<http://ariadne-infrastructure.eu/content/download/1781/9956/file/D3.1%20Initial%20report%20on%20standards%20and%20on%20the%20project%20registry.pdf>

CIDOC Conceptual Reference Model
<http://cidoc-crm.gnm.de/wiki/Hauptseite>

LIDO Lightweight Information Describing Objects
<http://network.icom.museum/cidoc/working-groups/data-harvesting-and-interchange/lido-technical/specification/>

CARARE metadata schema
<http://www.carare.eu/eng/Resources/CARARE-Documentation/CARARE-metadata-schema>

2.2.1.7 Metadaten in der Anwendung

Projektbezogene Metadaten

Die wichtigsten Metadaten, die für die Beschreibung eines Projektes oder einer Dokumentensammlung erforderlich sind, werden in der folgenden Tabelle abgebildet und knapp definiert. Sie geben einen Überblick über einen größeren, zusammenhängenden Datenbestand und beschreiben den fachlichen Kontext in dem dieser entstanden ist. Vergleichbar einem Bibliothekskatalog liegt die Hauptfunktion dieser Metadaten darin, dass externe Personen ein Projekt oder eine Dokumentensammlung über Web-Portale und Suchmaschinen finden und einordnen können. Darüber hinaus enthalten sie rechtliche Informationen, die für den weiteren Umgang mit den Daten wichtig sind.

Die hier zusammengestellten Eigenschaften basieren auf dem Dublin Core Metadata Schema und den Angaben, wie sie vom ADS in UK und tDAR in USA erhoben werden, um einen zukünftigen Austausch zu vereinfachen. Ein ausführliches Metadatenschema, das auch die Grundlage für die Archivierung von Projektdaten bei IANUS bildet, sowie ausgefüllte Beispielformulare sind in dem Kapitel Archivierung von Forschungsdaten in IANUS auf Seite 102 zu finden.

Bezeichnung	Kurzdefinition
Identifizierung – Projekttitel	Verbindliche Kurzbezeichnung des Projektes
Identifizierung – Alternativtitel	Ggf. alternative Titel für ein Projekt
Identifizierung – Projektnummer(n)	Nummern oder Kennungen, die z.B. innerhalb der durchführenden Organisation oder von Mittelgebern verwendet wird, um das Projekt eindeutig identifizieren zu können
Kurzbeschreibung	Knappe Angaben zu Fragestellung, Verlauf und Ergebnis des Projektes sowie Skizzierung der Datensammlung (insgesamt ca. 100-300 Worte)
Schlagworte – Fachdisziplinen	Stichworte, die die beteiligten Disziplinen und Fächer benennen. Sofern die Stichworte auf publizierten Standards oder internen Thesauri beruhen, müssen diese mitangegeben werden.
Schlagworte – Inhalt	Stichworte, die den Inhalt der Datensammlung benennen., z.B. zu Materialgruppen, Fundstellen-Klassifizierung, Quellenarten, Kulturgruppen, etc. Sofern die Stichworte auf publizierten Standards oder internen Thesauri beruhen, müssen diese mitangegeben werden.
Schlagworte – Methoden	Stichworte, die die eingesetzten Forschungsmethoden beschreiben. Sofern die Stichworte auf publizierten Standards oder internen Thesauri beruhen, müssen diese mitangegeben werden.
Ausdehnung Geographisch-1	<ul style="list-style-type: none"> - Detaillierte Angaben zur räumlichen Ausdehnung des untersuchten Gegenstandes mittels geographischer Koordinaten, ggf. die max. Ausdehnung als sog. Bounding angeben
Ausdehnung Geographisch-2	<ul style="list-style-type: none"> - Sprachliche Beschreibung des untersuchten Gegenstandes mittels Ortsangaben mit Land, Stadt, Kreis, Straße, Gemarkung, etc. Sofern Namen sich im Lauf der Zeit geändert haben, dies gesondert vermerken. Sofern eine Referenz zu einer Geo-Ressource oder einem Gazetteer existiert, sollte diese ebenfalls angegeben werden.
Ausdehnung – zeitlich	Chronologische Angaben zum untersuchten Gegenstand, entweder als Periodenbezeichnung und/oder mit groben/genauen Jahresangaben. Sofern die Stichworte auf publizierten Standards oder internen Thesauri beruhen, müssen diese mitangegeben werden.
Primärforscher – Person	Personen, die entweder für das Projekt als Ganzes, für das Datenmanagement oder für die Erzeugung bestimmter Datenarten zentral bzw. verantwortlich sind. Hier ist eine Kontaktadressen erforderlich und die aktuelle/letzte institutionelle Zugehörigkeit, damit die Personen bei Rückfragen erreicht werden kann.
Eigentümer – Organisation	Organisation, der die unter 5a genannte Person angehört, oder die nach Ausscheiden derselben für die Daten verantwortlich ist, im weitesten Sinne also Eigentümerin der Daten ist. Hier ist eine Kontaktadressen erforderlich, damit die Organisation bei Rückfragen erreicht werden kann.
Finanzierung	Nennung der Organisation(en) / (Dritt-)Mittelgeber, durch die das Projekt finanziert wurde. Es sollte jeweils die Zeit der Finanzierung angegeben werden

Dateibezogene Metadaten

Bei dieser Art von Metadaten handelt es sich um Informationen, die Archiven und Nutzern verständlich machen, wie einzelne Dateien innerhalb eines Projektes oder einer Datensammlung beschaffen sind und welche Möglichkeiten der Nachnutzbarkeit sie beinhalten. Dateibezogene Metadaten sind zum einen abhängig von dem Dateiformat, dem Inhalt und der Methode, mit der sie erzeugt wurden. Beispielsweise sind für Rasterdateien, die durch digitale Fotographie entstanden sind, andere Angaben erforderlich (Photograph, Aufnahmedatum, Aufnahmeort, abgelichtetes Objekt, etc.) als für Rasterdateien, die durch geophysikalische Messungen erzeugt wurden (Koordinaten, Messgerät, Genauigkeit, Datum, etc.). Die Angaben, die für bestimmte Dateiformate empfohlen werden, sind in den verschiedenen Kapiteln zu den jeweiligen Formaten beschrieben.

Daneben existieren aber auch dateibezogene Metadaten, die unabhängig von Format, Inhalt und Methode für alle Einzeldateien gleichermaßen relevant und notwendig sind. Sie sind eher administrativer und technischer Natur und spielen für ein laufendes Forschungsprojekt möglicherweise nur eine untergeordnete Rolle. Für die Langzeitarchivierung von Daten, besonders für die Migration in neuere Dateiformate oder für die Bereitstellung für Dritte, enthalten sie dagegen zentrale Informationen. Zu diesen Metadaten gehören neben den Angaben zu Dateiname, Dateiformat und Dateiversion auch detaillierte Angaben zur verwendeten Soft- und Hardware, Hinweise zur Speicherung, Versionierung und Referenzen sowie rechtliche Aspekte.

Bezeichnung	Kurzdefinition
Dateiname	Eindeutiger Name der Datei
Dateiformat	Format, in der die abgespeichert ist
Software – Dateierstellung	Computerprogramm/Software, mit dem die Datei erstellt wurde
Hardware – Dateierstellung	Hardware, mit der die Datei erstellt wurde, v.a. bei technischen Geräten wie Kameras, GPS-Geräten, Vermessungsinstrumenten, Laserscanner, etc.
Betriebssystem – Dateierstellung	Betriebssystem, unter dem die Datei erstellt wurde
Erstellungsdatum	Datum, an dem die Datei erstellt wurde
Letzte Aktualisierung	Datum, an dem die Datei zuletzt bearbeitet wurde
Dateiversion	Angabe der Versionsnummer einer Datei
Referenzdateien	Referenzen auf Dateien, die für das Verständnis einer anderen Datei zentral sind, v.a. bei zusammenhängenden, komplexen Dateien oder wenn auf eine Ursprungodatei verwiesen werden soll

Auch wenn es in der Theorie wünschenswert ist, diese Angaben sowie die zugehörigen spezifischen Angaben zu Methoden und Dateiformaten für jede Datei einzeln zu erfassen, so zeigt die Praxis, dass es häufig ausreichend ist, einen Metadatensatz für Gruppen von Dateien anzulegen, wenn diese das gleiche Format und/oder die gleichen inhaltlichen Eigenschaften aufweisen.

Methodenbezogene Metadaten

Jede Fachdisziplin innerhalb der Altertumswissenschaften verfügt über individuelle Forschungsmethoden. Auch diese haben Einfluss auf Umfang, Art, Struktur und Inhalt digitaler Objekte, da sie bei unterschiedlichen Arbeitsweisen und technischen Geräten unterschiedlich ausfallen. Daher variieren die methodenbezogenen Metadaten von Fachgebiet zu Fachgebiet und werden diese individuell in den einzelnen Kapiteln des Abschnittes zu den „Forschungsmethoden“ beschrieben.

Eine Gemeinsamkeit ist den vielen Dateien allerdings, dass sie in einer methodenspezifischen Prozesskette stehen, die es ebenfalls zu dokumentieren gilt — vor allem dann, wenn mehrere Zwischenstände eines solchen Prozesses archiviert und Dritten zur Verfügung gestellt werden sollen. Je nach Genauigkeit der Methodenbeschreibung kann sie sich sowohl auf eine Einzeldatei als auch mehrere Dateien gleichen Typs beziehen.

Bezeichnung	Kurzdefinition
Prozessnummer	Eindeutige Nummer eines Prozesses oder einer Methode
Ausgangsformat(e)	Format der Dateien, die am Anfang eines gesamten Prozesses stehen und den Ausgangspunkt bilden
Zwischenformat(e)	Format der Dateien, die im Verlauf eines Prozesses erzeugt werden und den Ausgangspunkt für weitere Prozesse bilden
Zielformat(e)	Format der Dateien, die am Ende eines gesamten Prozesses erzeugt werden und den Zielpunkt definieren
Durchführende(r)	Person(en), die den Prozess durchgeführt haben
Prozessbeschreibung	Beschreibung des Prozesses/der Methode, vor allem der Ausgangssituation und der Zielvorstellung
Prozessbeginn	Datum, an dem der Prozess begonnen wurde
Prozessende	Datum, an dem der Prozess beendet wurde
Software	Computerprogramme/Software, mit der der Prozess durchgeführt wurde
Hardware	Hardware, auf der der Prozess durchgeführt wurde

2.2.2 Dateiverwaltung

M. Trognytz

Der tägliche Umgang mit digitalen Daten wird durch eine effiziente Dateiverwaltung erheblich erleichtert. Aussagekräftige Dateinamen, die auch für Dritte verständlich sind, sorgen dafür, dass die Dateien gefunden und deren Inhalt verstanden wird. Einheitliche Dateinamensstrukturen erhöhen die Lesbarkeit. Die konsequente Einhaltung von Versionierungsangaben sorgt dafür, dass immer mit der richtigen Dateiversion gearbeitet wird und eine selbsterklärende Ordnerstruktur hilft dabei auch in großen Projekten bestimmte Dateien wiederzufinden.

Die Konzipierung der Dateiverwaltung muss schon zu Beginn des Projektes erfolgen, damit die Regeln von Anfang an angewendet werden können. Die Nie-

derschrift der durch Beispiele ergänzten Benennungsregeln und deren Weitergabe dient im laufenden Betrieb als wichtiges Nachschlagewerk für die konsistente und konsequente Einhaltung derselben. Dies ermöglicht dann eine effizientere Arbeitsweise.

Im laufenden Projektbetrieb sollte die Einhaltung der Benennungsregeln kontrolliert werden und gegebenenfalls angepasst werden.

2.2.2.1 Dateiablage

Mit Dateiablage ist hier vor allem die Ordnerstruktur gemeint. Für die Benennung der Ordner gelten die gleichen Regeln, wie für die Dateibenennung, die in dem nächsten Abschnitt thematisiert werden. Lediglich die Dateinamenserweiterung wird bei Ordnernamen nicht verwendet. Die Dateiablage sollte selbst erklärend sein und unpräzise Namen wie etwa „*In Arbeit*“ sollten unbedingt vermieden werden.

Wichtig ist, dass die Dateiablage logisch und hierarchisch aufgebaut ist. Dies bedeutet unter anderem, dass die Inhalte und Unterordner eines übergeordneten Ordners auch tatsächlich thematisch dort hineinpassen. Beispielsweise erwartet man in einem Ordner mit dem Namen „*Fotos*“ diverse Fotos, die bei einer entsprechenden Menge vielleicht noch auf verschiedene Unterordner, wie zum Beispiel „*Plana*“ und „*Profile*“, verteilt sind.

Ist aber in dem Ordner „*Fotos*“ ein Unterordner mit dem Namen „*Zeichnungen*“ enthalten, in dem verschiedene digitalisierte Zeichnungen abgelegt sind, führt das in der Folge zu Schwierigkeiten. Der Unterordner wird wahrscheinlich nur schwer wiedergefunden werden, da der Name des übergeordneten Ordners einen anderen Inhalt verspricht.

Tritt der Fall ein, dass eine Datei oder ein Ordner thematisch in mehrere verschiedene übergeordnete Ordner passen würde, können verschiedene Lösungswege zur Anwendung kommen. Beispielsweise kann eine Kopie abgelegt werden, was allerdings problematisch ist, wenn eine der Kopien verändert wird und diese nicht mit der anderen abgeglichen wird.

Alternativ kann eine Dateiverknüpfung, also eine symbolische Verknüpfung, angelegt werden. Dateiverknüpfungen verschiedener Betriebssysteme sind meist nicht zu anderen Systemen kompatibel und funktionieren im schlimmsten Fall sogar nur auf dem einen Rechner, auf dem sie erstellt wurden. Dies liegt zum einen daran, dass jedes Betriebssystem unterschiedliche Methoden zur Erstellung verwendet und zum anderen können schon die Laufwerke unterschiedlich benannt sein. Außerdem kann die Dateiverknüpfung ins Leere führen, wenn die originale Datei verschoben oder gelöscht wurde.

Eine bessere Methode ist das Anlegen einer Textdatei mit einem Hinweis auf den Ablageort der Datei oder des Ordners. In diesem Fall muss aber darauf geachtet werden, dass die gesuchte Datei sich auch tatsächlich an dem angegebenen Ort befindet. Bei Verschieben oder Löschen müsste die Textdatei also auch immer berücksichtigt und angepasst werden.

Am besten ist es, nur eine Instanz einer Datei oder eines Ordners zu haben. Bei Zuordnungsschwierigkeiten kann es helfen, die Datei oder den Ordner in der hierarchischen Struktur höher anzusiedeln.

Eine Textdatei kann auch verwendet werden, um die vorhandene Ordnerstruktur zu erklären oder auf Besonderheiten hinzuweisen. Beispielsweise kann in einem Ordner mit Fotos, deren Metadaten in einer Datenbank abgespeichert

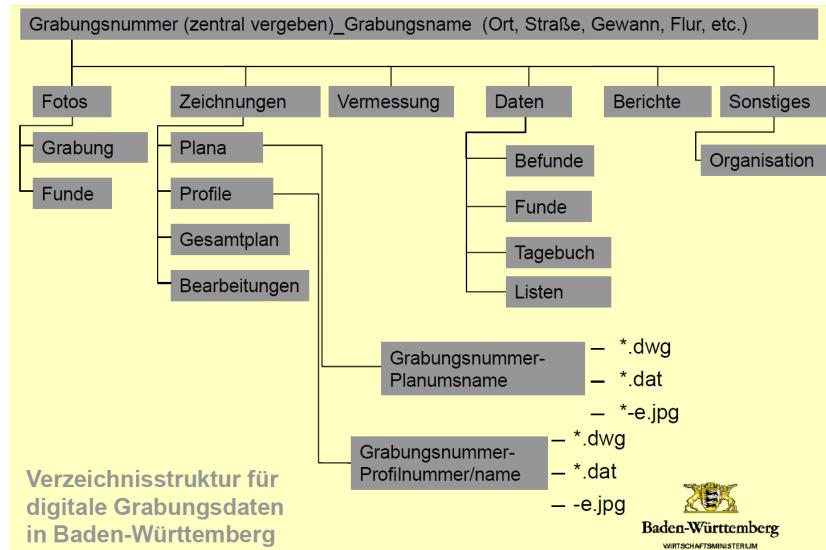


Abb. 2.2: Datenstruktur Baden-Württemberg

sind, mit Hilfe einer Textdatei verdeutlicht werden, wo die Metadaten zu finden sind. Damit die Textdatei auch als eine Hilfdatei erkannt wird, kann man ihr den Namen „*README*“ oder „*LIESMICH*“ geben. Die Schreibung mit Großbuchstaben erhöht die Auffälligkeit der Datei. Durch eine vorangestellte Null kann sie dann auch in der alphabetischen Sortierung ganz an den Anfang gestellt werden.

Praxisbeispiele Abhängig von dem Umfang und der Dauer des Projektes, kann sich die Ordnerstruktur beispielsweise am Thema, dem Material, dem Jahr, dem Bearbeiter oder den einzelnen Arbeitsschritten orientieren.

Das Landesdenkmalamt von Baden-Württemberg verwendet eine Dateiablage, die an der analogen Ordnerstruktur einer Grabung orientiert ist. Sie wird in Abbildung 2.2 veranschaulicht.

„Diese Struktur ist in den oberen Ebenen rigide genug, um für Ordnung und Datendisziplin zu sorgen und gleichzeitig weiter unten flexibel genug, um den unausweichlichen Eigenarten der einzelnen Archäologen Rechnung tragen zu können.“

Die Grabungs- oder Vorgangsnummer, die zentral vergeben wird, ist wichtig. Sie beschreibt nicht nur die Ausgrabung, sie ist auch die Inventar-Stammnummer aller Funde, die auf dieser Grabung gefunden werden. Insofern ist sie die Schnittstelle zum zentralen Fundarchiv des Archäologischen Landesmuseums. Die Ausgräber werden aber nicht allein gelassen. Mit der Datenstruktur werden Anleitungen geliefert, die beschreiben, was wohin gehört. Damit wird tatsächlich eine gewisse Einheit im Land erreicht.“¹

Auch die nachträgliche Strukturierung von bereits vorhandenen digitalen Dateiablagen ist relativ einfach, da Klartextinhaltsverzeichnisse in der obersten

¹D. Bibby, Digitale Datenstruktur auf Ausgrabungen und Archivierung digitaler Grabungsdaten. Praxis und Praxisversuche aus Baden-Württemberg, ANachr 14 2009, 159-163.

Ebene des Verzeichnisses abgelegt werden können, welche die Eigenheiten der Grabung und die strukturellen Abweichungen beschreiben.

Anwendungsgebiete mit mehreren voneinander abhängigen Dateikomplexen, wie zum Beispiel 3D-Scanning, erfordern eigene Dateiablagen. Diese werden in den entsprechenden Abschnitten im Kapitel „Forschungsmethoden“ auf Seite 102 beschrieben.

2.2.2.2 Dateibenennung

Üblicherweise besteht der Dateiname einer Datei aus dem eigentlichen Namen und, durch einen Punkt getrennt, der Dateinamenserweiterung, welche angibt, in welchem Format die Datei vorliegt. Die Erweiterung wird in der Regel von dem Programm, mit dem die Datei gespeichert wurde, an den Dateinamen gehängt.

Ein Beispiel: *IT-Empfehlungen.pdf* gibt an, dass es sich um eine Datei mit dem Namen „*IT-Empfehlungen*“ handelt, die in dem PDF-Format vorliegt.

Da die Erweiterung automatisch erzeugt wird, muss die Datei mit einem geeigneten Programm konvertiert werden, wenn man das Dateiformat ändern möchte. In dem Kapitel „Dateiformate“ auf Seite 37 sind ausführliche Informationen darüber zu finden.

Im Folgenden geht es nur noch um den reinen Dateinamen, ohne die Dateinamenserweiterung.

Erlaubte Zeichen Moderne Betriebssysteme können mit Sonderzeichen umgehen, zu denen Umlaute und Leerzeichen gehören. Das war aber nicht immer so und kann auch heute noch zu Problemen führen. Webserver lesen zum Beispiel das Leerzeichen als die Zeichenfolge „%20“ ein und da Umlaute nicht immer gleich kodiert werden, kann es zu Schwierigkeiten kommen.

Für die Langzeitarchivierung sollten also nur die alphanumerischen Zeichen des englischen Alphabets, also a-z, A-Z und 0-9 verwendet werden. Zusätzlich kann der Bindestrich (-) und bei Bedarf auch der Unterstrich (_) verwendet werden.

Zu vermeidende Zeichen Es gibt eine ganze Reihe von Zeichen, die für besondere Aufgaben von Betriebssystemen verwendet werden. Der Punkt dient zur Trennung des Dateinamens von der Dateinamenserweiterung und der Schrägstrich dient in Windows um Ordnerstrukturen zu kennzeichnen.

Zu den Zeichen, die absolut nicht verwendet werden dürfen, gehören:

\ / : * ? “ < > |

Die Verwendung von allen weiteren Sonderzeichen ist zwar möglich, kann jedoch zu einem unerwarteten Verhalten des Systems führen. Daher wird von der Verwendung von Leerzeichen und Sonderzeichen, Bindestrich (-) und Unterstrich (_) ausgenommen, abgeraten.

Groß- und Kleinschreibung Die Groß- und Kleinschreibung in einem Dateinamen wird von unterschiedlichen Systemen verschieden gedeutet. In Windows beispielsweise kann, wenn es eine Datei mit dem Namen „*TestDatei*“ schon gibt, keine Datei mit dem Namen „*testdatei*“ angelegt werden. Andere Systeme

könnten dies jedoch erlauben, was aber nicht bedeutet, dass man dies auch tun sollte.

Hat man sich in der Praxis einmal für eine Schreibweise entschieden, muss diese auch konsequent eingehalten werden und insbesondere bei der Arbeit auf verschiedenen Systemen darauf geachtet werden.

Länge Der Dateiname sollte so kurz wie möglich und so lang wie nötig sein. Eine aktuelle Obergrenze, die auf manchen Systemen nicht überschritten werden darf, sind 255 Zeichen. Kryptische oder untypische Kürzel sollten vermieden werden, da sie in der Regel in Vergessenheit geraten.

2.2.2.3 Versionskontrolle

Wenn unterschiedliche Personen an einer Datei arbeiten, ist es wichtig, die verschiedenen Änderungen und Entwicklungsstadien zu verfolgen und zu kennzeichnen. Nur so kann vermieden werden, dass an der falschen Dateiversion gearbeitet wird oder diese gar gelöscht wird. Dateiversionen, die nicht mehr benötigt werden, können bei Bedarf gelöscht werden.

Es gibt mehrere Strategien, um die Versionskontrolle durchzuführen.

Angabe im Dateinamen Eine einfache und übersichtliche Methode ist, die Versionsangabe in den Dateinamen zu integrieren. Das kann beispielsweise mit einer Datumsangabe oder Ziffern erfolgen. Durch ein vorangestelltes **v** werden die Ziffern als eine Versionsnummer gekennzeichnet, wie zum Beispiel **v001**. Führende Nullen stellen sicher, dass die Versionsnummern einheitlich und leichter lesbar sind und richtig sortiert werden.

Eine Kennzeichnung von Versionen durch Worte wie „*neu*“, „*neuer*“ und „*alt*“ ist unbedingt zu vermeiden. Eine Ausnahme können endgültige Dateiversionen bilden, die der Übersicht halber etwa durch *FINAL* am Ende gekennzeichnet werden können. Es darf aber nur eine Datei mit dieser Kennzeichnung in einem Ordner und einem bestimmten Format vorliegen. Eine endgültige Version, die zum Beispiel sowohl als *docx* als auch als *pdf* vorliegt, ist also erlaubt.

Angabe im Kopf der Datei Angaben zum Erstellungsdatum und den verschiedenen Versionen und deren Änderungen können auch im Header der Datei oder in standardisierten Kopfzeilen in der Datei selbst angegeben werden.

Änderungsprotokoll Statt einzelne Dateiversionen abzuspeichern, kann auch ein Änderungsprotokoll geführt werden. Dabei werden die einzelnen Änderungen in einer einfachen Textdatei protokolliert, die zusammen mit der eigentlichen Datei abgelegt wird. Im Englischen wird dafür der Begriff *ChangeLog* verwendet.

Software Die bisher beschriebenen Methoden sind hauptsächlich manuell anzuwendende Vorgänge. Es gibt jedoch auch Software zur Versionsverwaltung. Deren Einsatz lohnt sich aber erst in großen Projekten, die zentral auf einem Server abgelegt werden. Versionsverwaltungssoftware kann dann aus den Dateiänderungen automatisch *ChangeLogs* erstellen.

2.2.3 Dateispeicherung und -sicherung

R. Förtsch, R. Komp, M. Trognitz

Um Datenverlust vorzubeugen, ist es unerlässlich eine geeignete Sicherungsstrategie zu verwenden. Dabei muss zwischen einer kurzfristigen Speicherung und einer mittelfristigen Sicherung, unterschieden werden. Ersteres meint, wie Daten während der Erstellung und Bearbeitung gespeichert werden. Letzteres bezieht sich auf einen längeren Speicherzeitraum, der durchaus auch mehrere Monate betragen kann, stellt also ein klassisches Backup der Daten dar.

Die Sicherungsstrategie legt fest wie die Datensicherung erfolgen soll und berücksichtigt folgende Fragen:

- Wer ist für die Datensicherung verantwortlich?
- Wer hat Zugriff auf die gesicherten Daten?
- Wann und wie oft soll die Datensicherung durchgeführt werden?
- Auf welche Weise soll gesichert werden?
- Welche Daten sollen gesichert werden?
- Welche Speichermedien sollen verwendet werden?
- Wie viele Sicherungskopien sollen angelegt werden?
- Wo sollen die Sicherungen aufbewahrt und wie sollen sie geschützt werden?
- Wie soll der Transport der Sicherungskopien erfolgen?
- Wie lange soll eine Sicherung aufbewahrt werden?

Außerdem kann die Sicherungsstrategie mit den zu verwendenden Richtlinien zur Dateiablage eng verzahnt sein, um etwa einen nahezu automatisierten Sicherungsvorgang zu ermöglichen.

Die richtige Speicherstrategie beugt zwar einem möglichen Datenverlust durch Hardware-, Software- oder menschliche Fehler vor, stellt aber noch *keine* Archivierung der Daten dar. Eine Archivierung ist auf Langfristigkeit ausgelegt und impliziert immer eine bewusste Auswahl und umfassende Dokumentation der Daten, da eine Nachnutzung derselben das Ziel ist. Während der Projektlaufzeit kann bereits ein eigener Archivordner angelegt werden, worin beispielsweise finale Dateien oder unprozessierte Rohdaten abgelegt werden können, um die spätere Auswahl der zu archivierenden Daten vorzubereiten.

Weiterführende Hinweise zur Datensicherung sind auf den Seiten des Bundesamtes für Sicherheit in der Informationstechnik zu finden, die sich sowohl an Einsteiger² als auch an Experten³ richten.

²https://www.bsi-fuer-buerger.de/BSIFB/DE/MeinPC/Datensicherung/Sicherungsmethoden/sicherungsmethoden_node.html

³https://www.bsi.bund.de/DE/Themen/ITGrundschutz/ITGrundschutzKataloge/Inhalt/_content/baust/b01/b01004.html

2.2.3.1 Kurzfristige Speicherung

Zur Bearbeitung geöffnete Dateien sollten in kürzeren Abständen gespeichert werden, um einem Verlust von möglicherweise stundenlanger Arbeit infolge etwa eines Stromausfalls vorzubeugen. Von diesen Arbeitsversionen sollten regelmäßig, beispielsweise nach jedem Arbeitstag, Kopien auf externen Speichermedien angefertigt werden, welche in die mittelfristige Sicherung übergehen.

Vorgaben zur Form der Dateiablage, der Dateibenennung und Versionierung müssen schon beim Anlegen der Dateien beachtet werden, um einen reibungslosen Ablauf der darauf abgestimmten Datensicherungsstrategie zu gewährleisten.

2.2.3.2 Mittelfristige Sicherung

Digitale Daten sind nur dann über einen längeren Zeitraum sicher, wenn sie mehr als einmal gespeichert werden. Es müssen also mindestens zwei Sicherungskopien auf physisch getrennten Speichermedien vorliegen, um etwa bei einem Hardwaredefekt auf eine alternative Sicherungskopie zugreifen zu können.

Die Sicherung von Daten auf unterschiedlichen Arbeitsgeräten wird erleichtert, wenn diese zunächst auf einem Datenträger gesammelt werden und dieser dann gesichert wird.

Speichermedium Welches Speichermedium gewählt wird, hängt vor allem von der Speichergröße der zu sichernden Dateien und der vorhandenen Infrastruktur ab. So eignen sich eine CD oder eine DVD nur für Daten bis maximal 900 MB, bzw. 17 GB Speichervolumen. Für größere Datenmengen werden entsprechende Datenträger benötigt.

Steht ein lokaler oder institutioneller Server zur Verfügung, ist dies das Mittel zur Wahl, da diese üblicherweise gewartet werden und meist selbst in eigene Sicherungsstrategien eingebunden sind. In Umgebungen mit Zugriff auf das Internet, kann eine Sicherung auch auf einen entfernten Server, beispielsweise in einem Rechenzentrum, erfolgen. In allen anderen Fällen können externe Festplatten verwendet werden. Von externen kommerziellen Diensten, wie beispielsweise Dropbox, ist für eine mittelfristige Sicherung abzuraten, weil es sich oft um ausländische Anbieter handelt, die nicht dem deutschen Recht unterliegen und den Nutzer teilweise im Unklaren darüber lassen, wie mit den Daten umgegangen wird.

Da die Speichermedien eine begrenzte Lebenszeit von etwa zehn Jahren haben, sollten die Sicherungen von Zeit zu Zeit auf neue Speichermedien migriert werden. Außerdem sollten sie zwischenzeitlich an verschiedenen Orten, mindestens in verschiedenen Räumen, gelagert werden, um etwa im Brandfall den Schaden zu begrenzen. Auch der Transport von Original- und Sicherungsdatenbeständen sollte getrennt durch unterschiedliche Personen erfolgen, um zu vermeiden, dass etwa durch Diebstahl alle Sicherungskopien auf einmal abhanden kommen.

Für das Kopieren der Daten auf ein Speichermedium gibt es verschiedene Methoden, wie die Volldatensicherung, die inkrementelle und die differentielle Datensicherung.

Volldatensicherung Bei der Volldatensicherung werden die zu sichernden Dateien komplett und eins zu eins auf ein Speichermedium kopiert. Wird zum ersten Mal eine Sicherungskopie angelegt, so muss dies als Volldatensicherung

geschehen. Dabei ist zu beachten, dass der Kopiervorgang viel Zeit in Anspruch nehmen kann. Vor der Ausführung der Volldatensicherung muss geprüft werden, dass auf dem Speichermedium ausreichend freier Speicherplatz vorhanden ist.

Die Volldatensicherung ist die einzige Methode, die manuell, ohne weitere Hilfsprogramme, durchgeführt werden kann. Wird eine Volldatensicherung angelegt, sollten, beispielsweise in einer Textdatei, Informationen gespeichert werden, die Auskunft über den Zeitpunkt der Sicherung, den Ansprechpartner und den Umfang der Daten geben.

Liegt eine erste Volldatensicherung vor, können neue oder geänderte Daten mittels inkrementeller oder differentieller Datensicherung gesichert werden, was die Möglichkeit bietet, verschiedene Versionen der Daten zu sichern. Für beide Methoden werden jedoch eigene Programme benötigt.

Inkrementelle Sicherung Die inkrementelle Sicherung speichert nur jene Daten, die sich im Vergleich zu der vorliegenden Volldatensicherung oder vergangenen inkrementellen Sicherungsvorgängen geändert haben. Dies spart Zeit und Speicherplatz, erfordert jedoch im Fall einer Wiederherstellung der Daten, dass zunächst die Volldatensicherung übertragen wird und anschließend alle erfolgten inkrementellen Sicherungen nacheinander eingespielt werden.

Differentielle Sicherung Bei der differentiellen Sicherung werden immer jene Daten gespeichert, die sich im Vergleich zu der vorliegenden letzten Volldatensicherung geändert haben. Im Unterschied zu der inkrementellen Sicherung entfällt also der Vergleich mit Daten aus zwischenliegenden Sicherungsvorgängen seit Erstellung der Volldatensicherung. Diese Methode erfordert zwar etwas mehr Zeit und Speicherplatz als die inkrementelle Sicherung, erleichtert aber die Wiederherstellung der Daten, da nur die Volldatensicherung und die letzte differentielle Sicherung auf das System übertragen werden muss.

Automatisierung Die Datensicherung kann mit Hilfe von Programmen oder Skripten automatisiert erfolgen. Wichtig ist dabei zu kontrollieren, dass die Datensicherung auch tatsächlich in der gewünschten Form ausgeführt wird. Geeignete Programme gibt es viele, wie beispielsweise Bacula⁴, DirSync Pro⁵, TrayBackup⁶, PersonalBackup⁷ oder rsync⁸. Eine ausführliche Liste ist außerdem auf der englischen Wikipedia unter *List of backup software*⁹ zu finden. Oft können die Programme auch zur Wiederherstellung von gesicherten Daten verwendet werden.

Sicherungszeitpunkt Der Zeitpunkt der Sicherung spielt eine nicht zu unterschätzende Rolle. Beispielsweise kann eine Sicherung von Datenbanken im laufenden Betrieb zu Inkonsistenzen führen, weshalb in solchen Fällen ein Administrator diese Aufgabe übernehmen sollte.

Regelmäßige Sicherungsvorgänge, die zu bestimmten Zeitpunkten täglich, wöchentlich oder monatlich automatisiert gestartet und durchlaufen werden,

⁴<http://www.bacula.org/de/>

⁵<http://www.dirsyncpro.org/>

⁶<http://www.traybackup.de>

⁷<http://personal-backup.rathlev-home.de>

⁸<http://rsync.samba.org/>

⁹http://en.wikipedia.org/wiki/List_of_backup_software

gewährleisten, dass eine Sicherung auch tatsächlich erfolgt, zumal sie nicht vom individuellen Verhalten eines Nutzers abhängen.

Für Daten, die verschiedene Arbeitsschritte durchlaufen und dadurch große Änderungen erfahren, können die verschiedenen Zustände als Sicherungspunkte gespeichert werden. Beispielsweise können zunächst unbearbeitete digitale Bilder gespeichert werden, sowie ein daraus erzeugtes photogrammetrisches Modell oder andere nicht oder nur schwer wiederholbare signifikante Verarbeitungsschritte. Solche Sicherungspunkte müssen allerdings manuell gemacht werden, indem Beispielsweise ein Ordner mit den Rohdaten angelegt wird. Hinweise für solche Sicherungspunkte werden für bestimmte angewendete Methoden in dem Kapitel Forschungsmethoden ab Seite 102 gegeben.

Sicherungsversionen Es empfiehlt sich, eine vorhandene Volldatensicherung nicht direkt mit einer neuen Volldatensicherung zu überschreiben. Tritt nämlich während des Sicherungsvorganges ein Fehler auf, könnte im schlechtesten Fall auch die bereits vorhandene beschädigt werden.

Bei der Anwendung von inkrementellen oder differentiellen Sicherungsmethoden sollte trotzdem in geregelten Zeitabständen eine neue Volldatensicherung angelegt werden, welche mindestens bis zur nächsten Volldatensicherung aufgehoben wird. Dies ist im Sinne des Generationenprinzips oder Großvater-Vater-Sohn-Prinzips, einer Strategie zur Datesicherung, bei der mehrere Sicherungen für verschiedene Zeitpunkte und Zwecke angelegt werden. Hierfür können beispielsweise wöchentlich und monatlich Volldatensicherungen angelegt werden (Vater und Großvater), die primär den Datenverlust durch Hardware- oder Software-Fehler reduzieren sollen. Tägliche inkrementelle oder differentielle Sicherungen (Sohn) erlauben es beispielsweise auf Arbeitsversionen des Vortages zuzugreifen und können mit dem Beginn einer neuen Woche nach und nach überschrieben werden.

Disaster Recovery Eine gute Sicherungsstrategie umfasst zusätzlich, dass die Wiederherstellung der Daten geprobt wird, um im Ernstfall sicher zu sein, dass die verwendete Strategie auch wirklich funktioniert und die Daten schnell wieder einsatzfähig sind.

2.2.4 Qualitätssicherung

Datenformate und -qualität Die softwaretechnische Interpretation digitaler Daten beim Laden, Speichern und bei der Verarbeitung derselben erfordert Spezifikationen der Datenformate (hier verallgemeinernd gleichbedeutend für „Dateiformat“ und „Datentyp“). Grundsätzlich sollten für die Übergabe in ein Langzeitarchiv offengelegte standardisierte Datenformate zum Einsatz kommen. Proprietäre, d.h. herstellerspezifische Formate, deren Spezifikationen nicht vollständig veröffentlicht sind, dürfen nur in begründeten Ausnahmen verwendet werden.

2.3 Nachbereitung

2.3.1 Projektabschluss

2.3.2 Vorbereitung zur Archivierung

2.3.2.1 Auswahl

2.3.2.2 Dokumentation

2.3.3 Bereitstellung von Daten

2.3.3.1 Zugriffs- und Nutzungsrechte

2.3.3.2 Präsentationsform

2.4 Publikation

3 | Dateiformate

F. Schäfer

Im Folgenden werden konkrete technische Hinweise und Hintergrundinformationen zu den Dateiformaten gegeben, die nach heutigem Wissen für die Langzeitarchivierung geeignet sind. Des Weiteren werden die minimalen Anforderungen an die technische wie inhaltliche Dokumentation von einzelnen Dateiformaten genannt, damit diese nicht nur heute, sondern auch in Zukunft von Dritten verstanden und nachgenutzt werden können.

Es geht hier nur um die Dateiformate an sich, ihre Entstehungsweise wird dabei nicht berücksichtigt. Abhängig von der jeweiligen Generierung und Verwendung sind gegebenenfalls zusätzliche methodische und fachspezifische Metadaten erforderlich. Diese werden in dem Kapitel Forschungsmethoden ab Seite 102 beschrieben.

Bereits die Auswahl der verwendeten Software beeinflusst das Dateiformat und dessen Nachhaltigkeit. Daher sollte bei der Entscheidung für oder gegen eine bestimmte Software darauf geachtet werden, dass Dateiformate unterstützt werden, die möglichst folgende Eigenschaften aufweisen:

- Weit verbreitet und standardisiert
- Nicht proprietär, also nicht von einer Anwendung oder einem Hersteller abhängig und mit unterschiedlichen Programmen verwendbar
- Offen dokumentiert mit frei verfügbaren technischen Spezifikationen
- Verlustfreie oder keine Kompression
- Einfach dekodierbar oder sogar unmittelbar lesbar, also nicht durch Kodierung versteckt

Werden während eines Arbeitsprozesses andere als die hier empfohlenen Dateiformate erzeugt oder verwendet, sollte darauf geachtet werden, dass diese leicht und mit möglichst geringem Verlust an Informationen und Funktion in eines der in den folgenden Kapiteln aufgeführten Langzeitformate überführt werden können.

In den Übersichtstabellen mit den Formaten für bestimmte Dateitypen sind die präferierten Formate mit einem grünen Haken, die noch akzeptablen mit einer gelben Tilde und für die Langzeitarchivierung ungeeignete Formate mit einem roten Kreuz gekennzeichnet.

3.1 PDF-Dokumente

S. Jahn

Das PDF (Portable Document Format) wurde 1993 von Adobe Systems entwickelt, um den Datenaustausch zu erleichtern. Es ist ein plattformunabhängiges, offenes Dateiformat, das 2008 mit der Version 1.7 als ISO-Standard zertifiziert wurde und seitdem von der ISO weiter gepflegt wird.

Der große Vorteil von PDFs liegt darin, dass Dateiinhalte unabhängig vom Betriebssystem, dem ursprünglichen Anwendungsprogramm und der Hardwareplattform unverändert dargestellt werden. Das Aussehen von Dokumenten wird, wie bei einem analogen Ausdruck, eingefroren und kann somit angezeigt werden, wie es ursprünglich vom Autor intendiert war. Gleichzeitig sind die Möglichkeiten zur nachträglichen Bearbeitung begrenzt, wodurch eine große Authentizität gewährleistet wird.

Für das Öffnen einer PDF-Datei gibt es verschiedene freie Anwendungen, worin ein Grund für die große Verbreitung und Akzeptanz von PDFs liegt. Viele Programme können Dateien direkt im PDF-Format speichern oder exportieren. Darüber hinaus lassen sich mit Hilfe von zusätzlich installierten Druckertreibern PDF-Dateien aus allen Programmen heraus erzeugen.

Langzeitformate Nicht jede Datei mit der Dateierweiterung .pdf ist gleichermaßen für die Langzeitarchivierung geeignet. Für diesen Zweck wurde das PDF/A-Format entwickelt und als ISO-Standard zertifiziert. Es beschreibt in welcher Form bestimmte Elemente in einer PDF-Datei enthalten sein müssen und welche nicht erlaubt sind. Die erste Version der PDF/A-Norm wurde nachträglich um zwei weitere, aufeinander aufbauende Normteile ergänzt. Wird das PDF/A-Format für die Langzeitarchivierung einer Datei verwendet, die nicht nur textuelle Informationen enthält, sollten nach Möglichkeit auch die ursprünglichen Ausgangsdateien in archivierungstauglichen Formaten mitarchiviert werden – entweder als separate Dateien oder integriert in das Container-Format PDF/A-3.

Format	Begründung
✓ PDF/A-1	PDF/A ist gezielt als stabiles, offenes und standardisiertes Format für die Langzeitarchivierung unterschiedlicher Ausgangsdateien entwickelt worden.
~ PDF/A-2	PDF/A-3 ist nur dann für die Langzeitarchivierung geeignet, wenn alle eingebetteten Dateien in einem anerkannten Archivformat vorliegen.
✗ andere PDF-Varianten	Viele gängige PDF-Varianten sind nicht für die Langzeitarchivierung geeignet. Stattdessen sollten entweder die Ausgangsdateien in einem passenden Format archiviert oder eine Migration in ein PDF/A-Format vorgenommen werden.

Dokumentation Welche Metadaten für ein PDF-Dokument relevant sind, hängt von dessen Inhalt ab. Bei PDF-Dateien, die nur Text enthalten, sind meist weniger Informationen erforderlich, als bei PDFs, die Bilder, GIS-Karten oder 3D-Modelle enthalten. Die Metadaten können unmittelbar in einem PDF-Dokument im XMP-Format gespeichert werden.

Die hier angegebenen Metadaten sind als minimale Angabe zu betrachten und ergänzen die angegebenen Metadaten für Projekte und Einzeldateien in dem Abschnitt Metadaten in der Anwendung ab Seite 24.

Metadatum	Beschreibung
Titel	Titel des Dokuments, nicht der Dateiname
Autor	Name des Verfassers oder Erstellers der Datei; gegebenenfalls Name der Einrichtung
Stichwörter	Schlagworte, wie z.B. Periode, Fundstelle oder charakteristische Merkmale. Wenn vorhanden, angemessene Thesauri verwenden
Beziehungen	Dateien oder Ressourchen, die mit dem PDF zusammenhängen, insbesondere der Name der Originaldatei, aus der heraus ein PDF erstellt wurde
Anwendung	Programm, mit dem der Inhalt ursprünglich erzeugt wurde
Datum	Datum der Erstellung oder letzten Änderung der Datei
Copyright-Angaben	Angaben zur Person oder Einrichtung, die das Copyright oder die Lizenzrechte an der Datei oder deren Inhalt besitzt
Zusätzliche Metadaten	
Kurzbeschreibung	Kurzbeschreibung über den Inhalt des Dokuments
Sprache	Sofern schriftliche Inhalte vorhanden sind, die Sprache
Verfasser der Metadaten	Name der Person, welche die Metadaten ausgefüllt hat

Weitere Metadaten sind abhängig vom Inhalt und der Methoden und können in den jeweiligen Abschnitten nachgelesen werden.

Vertiefung

Eine wesentliche Eigenschaft und Stärke von PDF-Dateien ist die Tatsache, dass sie ganz unterschiedliche Inhalte enthalten können. So lassen sich neben Texten und Navigationshilfen, wie etwa Inhaltsverzeichnisse mit Textankern, auch andere Informationen wie Bilder, Verktografiken, 3D-Visualisierungen, Tabellen, Präsentationen oder GIS-Karten einbinden, die zusammen mit allen ursprünglich verwendeten Layoutmerkmalen gespeichert werden. Daher werden die meisten Publikationen wie elektronische Zeitschriften oder Infomaterialien auf Webseiten üblicherweise als PDF-Dateien zur Verfügung gestellt. Bei der Langzeitarchivierung von Dateien spielt das PDF/A-Format eine besondere Rolle. In dessen Spezifikation wird unter anderem vorgeschrieben, Schriften in das Dokument einzubetten und Farben geräteneutral zu definieren. Auf diese Weise wird gewährleistet, dass das originale Aussehen eines Dokuments wie in der ursprünglichen Anwendung und wie vom Autor intendiert erhalten bleibt. Die Intention von PDF-Dateien ist insofern die Erhaltung der ursprünglichen Darstellung, nicht aber der ursprünglichen Bearbeitungsfunktionalitäten.

Um eine möglichst große Authentizität einer PDF-Datei zu erlangen, sind die Möglichkeiten zur nachträglichen Bearbeitung sehr begrenzt. Es können

Kommentare hinzugefügt, Seiten eingebunden oder gelöscht, oder Textstellen geschrägt werden. Nur sehr eingeschränkt möglich sind jedoch Veränderungen der eigentlichen Inhalte oder des Layouts, z. B. Änderungen von Farben in einem Foto oder Umformulierungen von Texten. Als Nachteil ergibt sich daraus, dass die ursprüngliche Funktionalität der nach PDF/A konvertierten Datei verloren geht und eine Nachnutzung der Inhalte wenn überhaupt nur mit Qualitätsverlusten möglich ist. So können beispielsweise tabellarische Daten aus einer PDF-Datei nicht ohne einen zusätzlichen, fehleranfälligen Mehraufwand in eine neue Tabelle übernommen werden.

Da aber zunehmend Softwarelösungen existieren, die diese Einschränkungen der nachträglichen Bearbeitung auflösen oder umgehen, wächst der Bedarf an Schutzmechanismen gegen ungewollte Änderungen durch Dritte. Dazu zählen beispielsweise die Festlegung von einfachen Nutzungseinschränkungen, wie etwa die Erlaubnis zum Drucken, das Kopieren von Inhalten oder die Bearbeitung der im PDF gespeicherten Metadaten, oder die Vergabe von Passwörtern. Für Dateien, bei denen eine Langzeitarchivierung vorgesehen ist, dürfen allerdings keine Schutzfunktionen verwendet werden, damit sie ohne Hindernisse jederzeit nutzbar sind. Falls notwendig können Einschränkungen können als Lizenzhinweise formuliert werden; die Authenzität eines Dokumentes kann durch Signaturen, Zeitstempel und/oder digitale Prüfsummen gewährleistet werden.

Inhalte Dateien im PDF-Format können durch ganz unterschiedliche Anwendungen erzeugt werden und sie können daher ganz unterschiedliche Inhalte enthalten und darstellen. Für jede Dateiart gibt es spezifische Aspekte, die es zu beachten gilt, insbesondere dass einige Inhalte nicht mit den Vorgaben von PDF/A vereinbar sind.

Texte: Standardmäßig sind in PDF-Readern bereits 14 Schriftarten verfügbar. Es lassen sich aber auch weitere in ein PDF-Dokument einbetten, um eine korrekte Darstellung zu gewährleisten. Mithilfe von OCR-Software kann in PDF-Dokumenten eine nachträgliche Texterkennung durchgeführt werden.

Bilder: Wie bei normalen Rastergrafiken können auch in PDF-Dateien eingebettete Bilder durch spezielle Kompressionsverfahren in ihrer Speichergröße reduziert und in ihrer Auflösung heruntergerechnet werden. Bei fast allen Verfahren ist dies mit einem Informationsverlust verbunden, der vor allem die Genauigkeit und Qualität der Anzeige betrifft.

Vektorgrafiken: Vektorgrafiken in PDF-Dateien können wie die Ausgangsdateien frei skaliert werden.

3D: Es gibt zwei PDF-Formate, in die 3D-Dateien eingebettet und mit Adobe Reader geöffnet und betrachtet werden können. Auf diese Weise lassen sich auch 3D-Objekte austauschen und mit einfachen Funktionen bedienen, z.B. in der Ansicht drehen, Lichteinstellungen verändern oder Draufsichten und Schnittflächen erzeugen.

PDF-Varianten PDF-Dateien sind inzwischen ein sehr weit verbreitetes Austauschformat, das in ganz unterschiedlichen Kontexten Verwendung findet. Um eine gleichbleibende Qualität zu gewährleisten, wurden für die häufigsten Anwendungsfälle mehrere Normen und Standards festgelegt.

- PDF/X – Format für die Übermittlung von Druckvorlagen (seit 2001)

- PDF/A – Format für die elektronische Archivierung (ISO 19005-1 seit 2005)
- PDF/E – Format für technische Dokumente aus den Bereichen Ingenieurwesen, Architektur und Geo-Informationssysteme. Dieses Format besitzt die Fähigkeit zur interaktiven Darstellung von 3D-Objekten. Einzelteile können gedreht, auseinandergezogen, ein- oder ausgeblendet werden. (ISO 24517 seit 2008)
- PDF/UA – Richtlinien zum Aufbau eines barrierefreien Dokuments im Format PDF (seit 2008)
- PDF/VT – Format für den Einsatz im hochvolumigen und Transaktionsdruck (seit 2010)
- PDF 2.0 – (seit 2011)

Mehrere PDF-Standards lassen sich miteinander verbinden. Genügt eine Datei dem PDF/X-Standard, eignet sie sich als digitale Druckunterlage. Erfüllt diese Datei zusätzlich den PDF/UA-Standard, kann sie als barrierefreies PDF von Screenreader-Programmen verarbeitet werden.

Das Archivierungsformat PDF/A Von den verschiedenen existierenden PDF-Formaten ist nur das PDF/A-Format ein sicheres und stabiles Archivformat, das speziell für die elektronische Langzeitarchivierung von Dokumenten definiert und publiziert wurde. Die klar festgelegten und als Standard allgemein anerkannten Regeln schreiben vor, welche Bestandteile in einer PDF-Datei enthalten sein müssen und welche nicht zulässig sind, um konform zum PDF/A-Standard zu sein. Während einige Inhaltstypen wie Texte, Bilder, Zeichnungen, Tabellen und Schriften standardkonform in PDF/A-Dateien eingebunden werden können, sind andere Inhalte wie 3D-Objekte, Audio- und Video-Sequenzen, Flash-Animationen oder Scripte nicht erlaubt. Ebenso darf eine PDF/A-Datei keine externen oder dynamischen Inhalte enthalten, die in einem Viewer nachgeladen werden müssen. Beispielsweise werden URL-Links nur als Zeichenkette, nicht aber als aktive Verknüpfung gespeichert. Enthält eine PDF-Datei nicht zulässige Inhalte, kann sie sich nicht nach PDF/A konvertiert werden. Eine Validierung, ob eine vorliegende Datei dem gültigen PDF/A-Format entspricht, ist über entsprechende Prüfwerkzeuge möglich.

Insgesamt sind aktuell drei, aufeinander aufbauende Versionen von PDF/A-Formaten zu unterscheiden, von denen PDF/A-1 und PDF/A-2 echte Archivformate sind, da sie das Objekt in einem stabilen Zustand konservieren. Bei PDF/A-3 handelt es sich hingegen um einen Container, in den beliebige Dateiformate eingebettet werden können. Der große Vorteil liegt also darin, dass editierbare Originaldateien in das Dokument integriert werden können. Es gibt allerdings keine Garantie, dass die angehängten Dateien auch künftig alle angezeigt werden können. Zusätzlich besteht für die automatische Weiterverarbeitung die Möglichkeit einer Integration von Daten im XML-Format

Da es bislang keine Vorgabe über die Datenformate gibt, die in eine PDF/A-3-Datei eingebettet werden dürfen - erlaubt sind beispielsweise auch nicht offene, nicht standardisierte und nicht zukunftssichere Formate -, hängt die Frage der Archivierbarkeit einer PDF-A-3-Datei vor allem von ihrem Inhalt ab. Es wird

daher aktuell diskutiert, ob PDF/A-3 als Format für das Archival Information Package (AIP) nach ISO 14721:2012 OAIS geeignet ist.

Für alle Varianten des PDF/A-Formates gilt, dass Schriften und Zeichen direkt in die Datei eingebettet werden. Ebenso werden Sonderzeichen und Formeln verlässlich dargestellt. Auch Schriftsysteme wie Chinesisch oder Arabisch werden auf allen Geräten richtig wiedergegeben. Für die korrekte Anzeige von Farben werden festgelegte ICC-Profile verwendet. In PDF/A Dokumenten ist grundsätzlich eine Volltextsuche möglich, auch wenn es sich um ein gescanntes Dokument handelt. Zusätzlich kann auch eine digitale Texterkennung (OCR) integriert werden. Über die vergebenen XMP-Metadaten sind erweiterte Suchoptionen verfügbar.

PDF/A-1 (seit 2005):

- Bilder, Grafiken, verwendete Schriftzeichen etc. müssen im PDF/A-Dokument selbst eingebettet sein
- präzise, plattformunabhängig kodierte Farbangaben mittels ICC-Profilen
- Verwendung von XMP für Dokument-Metadaten
- *keine* transparenten Elemente
- *keine* Kompression
- *keine* PDF-Ebenen, Aktionen und JavaScript
- *kein* Passwortschutz
- Einbettung von Signaturen und Hyperlinks möglich
- Konformitätsstufen a und b

PDF/A-2 (seit 2011):

- identisch zu PDF/A-1 mit zusätzlichen Möglichkeiten:
- erlaubt Kompression mit JPEG2000, transparente Elemente und PDF-Ebenen
- ermöglicht Einbettung von OpenType-Fonts
- unterstützt digitale Signaturen in Übereinstimmung mit den PAdES (PDF Advanced Electronic Signatures)
- Dateianhänge: Einbettung von PDF/A-1 und PDF/A-2 Dateien möglich
- Konformitätsstufen a, u und b

PDF/A-3 (seit 2012)

- identisch zu PDF/A-2 mit zusätzlichen Möglichkeiten:
- Einbettung von beliebigen Dateien möglich (z.B. die Ursprungsdatei aus der ein PDF/A-3 erstellt wurde)
- keine Gewährleistung, dass die Anhänge zu einem späteren Zeitpunkt verarbeitet werden können

Konformitätsstufen bei PDF/A Die Qualität der archivierten Dokumente wird durch verschiedene Konformitätsstufen bezeichnet. Die Stufen sind abhängig von Eingangsmaterial und Verwendungszweck und ihre Bezeichnung wird an das Ende des PDF/A-Formates angehängt, z.B. „PDF/A-1a“.

Stufe a (accessible/zugänglich): Das Dokument sieht bei späterer Verarbeitung unverändert aus. Zusätzlich ist der Dokumentinhalt interpretierbar. Die Struktur des Dokuments und die natürliche Lesereihenfolge bleiben erhalten. Das Dokument ist somit barrierefrei und kann mithilfe von Screenreader-Programmen vorgelesen werden. Der gesamte Text wird in Unicode abgebildet. Es besteht die Möglichkeit, Text zu durchsuchen und zu extrahieren.

Stufe b (basic): Das Dokument sieht bei späterer Verarbeitung unverändert aus.

Stufe u (unicode): Das Dokument sieht bei späterer Verarbeitung unverändert aus. Zusätzlich wird der gesamte Text in Unicode abgebildet. Es besteht die Möglichkeit, Text zu durchsuchen und zu extrahieren.

Praxis

Für die Erstellung von PDF-Dokumenten gibt es eine Vielzahl an Programmen, die in manchen Fällen auch für die Bearbeitung der Metadaten verwendet werden können. Die Validierung klärt die Frage, ob es sich bei einem vorhandenen PDF-Dokument um eine Datei handelt, die auch PDF/A-konform ist.

Erstellung von PDF-Dokumenten Eine PDF-Datei lässt sich auf vielfältige Art und Weise erzeugen. Beim Betriebssystem Mac OS X ist die Möglichkeit zur Erstellung einer PDF-Datei über den Druckdialog voreingestellt. Windows bietet diese Möglichkeit nicht von Haus aus. Deshalb gibt es ein großes Angebot an kommerzieller und freier Software. Diese wird häufig über die Druckfunktion in die Anwendungen eingebunden, so dass aus beliebigen Programmen heraus über den Druckdialog ein PDF erstellt werden kann. Gescannte Vorlagen lassen sich in der Regel über die Scansoftware direkt als PDF speichern.

Eine weitere Möglichkeit bieten viele Programme über eine Exportschnittstelle. Die Funktionen dazu finden sich in der Regel im Menü un-

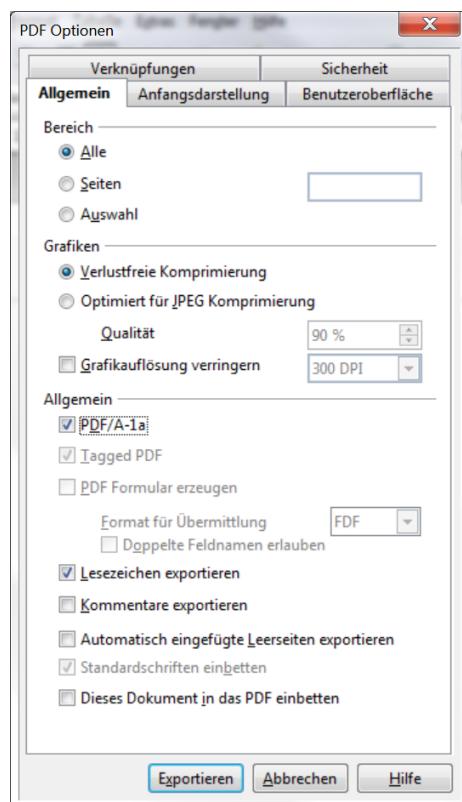


Abb. 3.1: Speichern im PDF/A-Format in OpenOffice

ter „Datei > Speichern unter“ oder „Datei > Exportieren“. Als Beispiele von Anwendungssoftware bzw. Produktsuiten mit der Möglichkeit zum direkten PDF-Export sind zu nennen: OpenOffice, Microsoft Office (ab 2010), Adobe Creative Suite, Framemaker und CorelDraw.

Nur in manchen Fällen lassen sich gezielt Dateien im PDF/A-Format erstellen. Diese Option beim Exportieren von Dateien bieten z.B. OpenOffice und Microsoft Office oder Systeme, bei denen entsprechende Module zur Erstellung von PDF/A-Dateien installiert wurden. Werden PDF-Dateien über einen Druckdialog erzeugt, sollte individuell überprüft werden, ob die jeweiligen Druckeinstellungen entsprechende Optionen anbieten.

PDF-Dateien, die nicht als PDF/A vorliegen oder sich in diesem Format erzeugen lassen, können auch mithilfe von Programmen umgewandelt werden. Als Teil der Adobe Suite ist das Programm „Adobe Acrobat Professional“ weit verbreitet. Es bietet vielfältige Werkzeuge zur Bearbeitung von PDF-Dateien. Dazu gehört auch die Möglichkeit, existierende PDF-Dateien in andere Varianten umzuwandeln. Zusätzlich gibt es ein großes Angebot an Plug-Ins, um die Funktionalitäten zu erweitern, z.B. zur Erstellung von PDFs mit 3D-Inhalten.

PDFCreator:

<http://de.pdfforge.org/>

FreePDF:

http://freepdfxp.de/index_de.html

PDF-XChange Editor:

www.pdf-xchange.de/pdf-xchange-viewer

PDF Split and Merge (einzelne PDFs zusammenfügen und trennen):

www.pdfsam.org

Validierung: Liegt eine PDF-Datei im PDF/A-Format vor? Häufig zeigen Viewer von PDF-Dateien unmittelbar an, ob eine Datei im PDF/A-Standard vorliegt oder diese Angabe ist in den Dateieigenschaften einsehbar ist. Will man aber sicher gehen, ob eine vorliegende Datei mit der Erweiterung .pdf dem PDF/A-Format entspricht, ist eine Überprüfung, eine sog. Validierung, erforderlich. Bei diesem Vorgang werden alle relevanten Bestandteile des Dokuments untersucht und auf PDF/A-Vorgaben getestet. Nur so kann die uningeschränkte ISO-Konformität gewährleistet werden und entschieden werden, ob eine Datei für die Langzeitarchivierung geeignet ist.

Da PDF/A-Dateien grundsätzlich nicht gegen Bearbeitung geschützt werden können, weil dies gegen die Vorschrift der Zugänglichkeit verstößen würde, muss eine solche Validierung nach jeder Bearbeitung durchgeführt werden, um nachträgliche, nicht-standardkonforme Veränderungen ausschließen zu können.

Viele Firmen haben sich mittlerweile auf die Archivierung von PDF-Dateien spezialisiert und bieten verschiedene Tools zur Überprüfung oder zur Reparatur von nicht validen Dateien an. „Adobe Acrobat Professional“ bietet mit dem Preflight-Werkzeug (im Menü „Bearbeiten > Preflight > Profile > PDF/A-Standard Prüfen“) ein Tool zur Validierung an. Auch mit kostenfreier Software lassen sich Validierungen durchführen. Mit PDF/A Live! 6.0 kann man ohne Lizenzschlüssel bis zu 50 Dokumente pro Tag überprüfen und bis zu 15 Dokumente konvertieren. Online besteht die Möglichkeit über den Free PDF/A Validator.

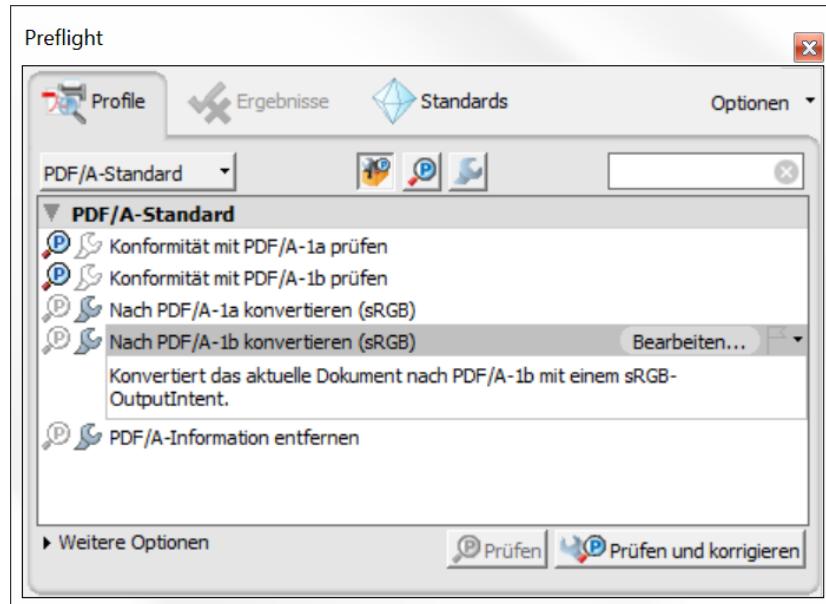


Abb. 3.2: PDF/A Validierung mit Preflight in Adobe Acrobat Professional

Isartor Test Suite:

www.pdfa.org/2011/08/download-isartor-test-suite

PDF/A Live! 6.0:

www.intarsys.de/pdf-produkte/pdfa-live

Free PDF/A Validator:

www.validatepdfa.com/online.htm

Bearbeitung von Metadaten Metadaten lassen sich im kostenlosen „Adobe Reader“ unter dem Menü „Datei > Eigenschaften“ anzeigen und bearbeiten. Zu den in hier aufgeführten Angaben für die inhaltliche Kurzbeschreibung gehören vier Felder: Titel, Verfasser, Thema und Stichwörter. Einige technische Informationen wie z. B. Dateigröße, Zeitstempel, Programmversion oder Seitenformat werden bei der Speicherung automatisch erzeugt und können hier ebenfalls eingesehen werden. Nur in Acrobat Professional werden die vollständigen XMP Metadaten angezeigt, die in einem weiteren Reiter um zusätzliche Informationen, wie Beschreibung, Verfasser der Beschreibung oder Copyright-Angaben, ergänzt werden können.

Neben Adobe Acrobat gibt es weitere Editoren, mit denen sich Metadaten für ein PDF vergeben oder nachträglich ändern lassen. Als uneingeschränkte kostenlose Anwendungen sind für Windows BeCyPDFMetaEdit und für Mac PDFInfo erhältlich. Mit Einschränkungen gibt es für Windows den Hexonic PDF Metadata Editor, der kostenfrei eine Verarbeitung von maximal fünf PDF-Dateien gleichzeitig erlaubt. Das Metadata Extraction Tool kann mit Metadaten von vielen verschiedenen Formaten umgehen.

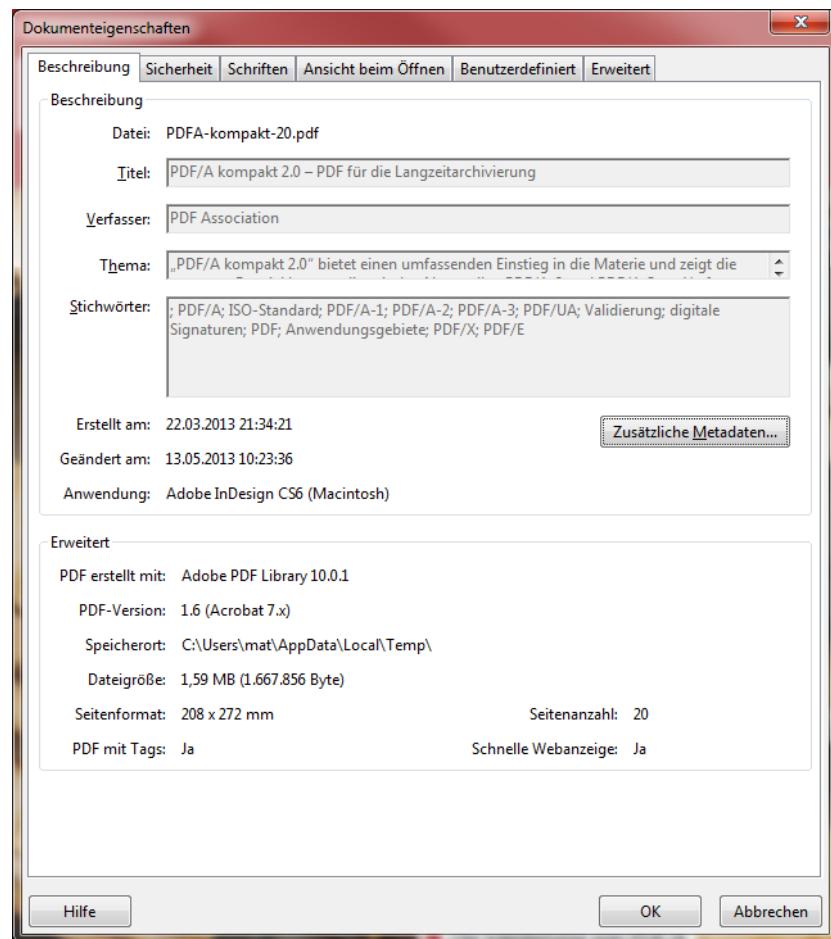


Abb. 3.3: Metadaten unter „Dokumenteneigenschaften“ in Adobe Acrobat Professional

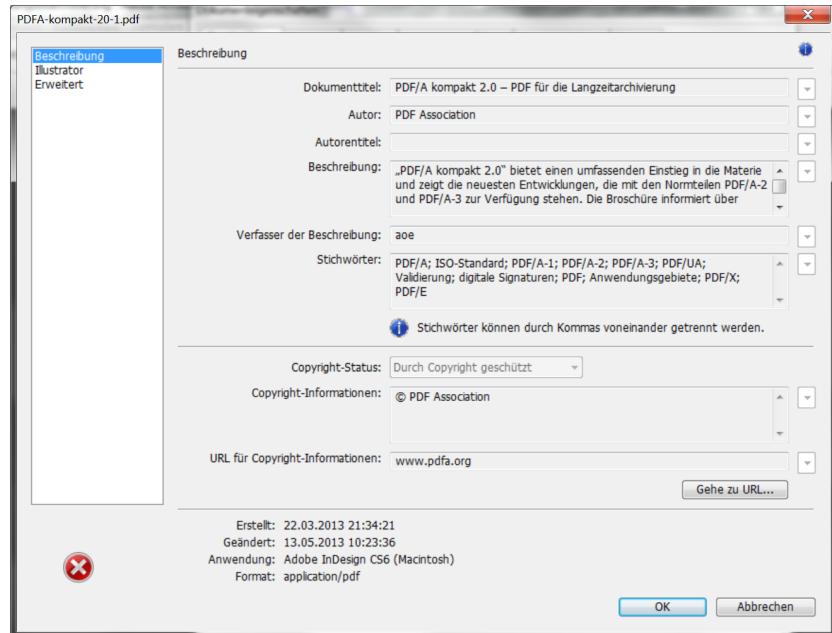


Abb. 3.4: Zusätzliche Metadaten unter „Dokumenteneigenschaften“ in Adobe Acrobat Professional

BeCyPDFMetaEdit:

www.becyhome.de/becypdfmetaedit/description_ger.htm

PDFInfo:

www.macupdate.com/app/mac/23356/pdfinfo

Hexonic PDF Metadata Editor:

www.hexonic.de/index.php/hexonic-pdf-metadata-editor

Metadata Extraction Tool:

<http://meta-extractor.sourceforge.net/>

Quellen

H. Bärfuss – M. Winkler, Pflicht und Kür in der Langzeitarchivierung (2013)

www.pdfa.org/wp-content/uploads/2013/11/DOK.magazin-2013-11-Compliance-DE.pdf

O. Drümmer – A. Oettler – D. von Seggern, PDF/A kompakt – Digitale Langzeitarchivierung mit PDF (2007)

www.pdfa.org/wp-content/uploads/2011/08/PDFA_kompakt_pdfa1b.pdf

H.-J. Hübner, Nestor-Praktikertag: PDF/A – Update und Dienstleistungen für die Langzeitarchivierung (2013)

<http://files.dnb.de/nestor/veranstaltungen/Praktikertag2013/2013-06-pdfa-huebner.pdf>

K. Krieg, PDF/A und Metadaten: XML, RDF und XMP: Was, wie und

- woher? (2008)
http://nestor.sub.uni-goettingen.de/seminar_bundesarchiv/docs/04-Metadaten-KK.pdf
- A. Oettler, PDF/A kompakt 2.0. (2013)
www.pdfa.org/wp-content/uploads/2013/05/PDFA-kompakt-20.pdf
- D. von Seggern, PDF/A und XMP Metadaten: Nutzen und Anforderungen (2009)
www.pdfa.org/wp-content/uploads/2011/09/callas_webinar_xmp_deu.pdf
- Adobe Acrobat: PDF – das ideale Format für den Austausch von Ideen und Informationen
www.adobe.com/de/products/acrobat/adobepdf.html
- Open Format: Archiving of 3D Documents
www.newformat.se/openformat/eng/odf-and-pdf-details/3d-archiving-pdfa-pdfe-english-popup.html
- OpenOffice.org: Export in das PDF-Dateiformat (2010)
www.openoffice.org/de/doc/howto_2_0/office/exportpdfformat.pdf
- PDF/A Flyer (2014)
www.pdfa.org/wp-content/uploads/2014/01/Flyer-PDFA-DEU.pdf
- PDF Association: PDF/A Competence Center: PDF/A Metadaten XMP, RDF & Dublin Core (2011)
www.pdfa.org/2011/09/pdfa-metadaten-xmp-rdf-dublin-core/?lang=de#schemas_im_ueberblickxmp_adobe_pdf_dublin_core
- PDF Association: PDF Competence Center
www.pdfa.org/pdf-assocation
- PDFlib: Die PDF/A-Archivierungsstandards
www.pdflib.com/de/knowledge-base/pdfa
- TechNote 0008: Predefined XMP Properties in PDF/A-1 (2008)
www.pdfa.org/wp-content/uploads/2011/08/tn0008_predefined_xmp_properties_in_pdfa-1_2008-03-20.pdf

Formatspezifikationen

- PDF/A-1 (ISO 19005-1:2005):
http://www.iso.org/iso/iso_catalogue/catalogue_tc/catalogue_detail.htm?csnumber=38920
- PDF/A-2 (ISO 19005-2:2011):
http://www.iso.org/iso/iso_catalogue/catalogue_tc/catalogue_detail.htm?csnumber=50655
- PDF/A-3 (ISO 19005-3:2012):
http://www.iso.org/iso/home/store/catalogue_ics/catalogue_detail_ics.htm?csnumber=57229

Tools und Programme

- Adobe Reader:
<http://get.adobe.com/de/reader>
- Foxit Reader:
<http://foxit-reader.softonic.de>

Ghostscript, Ghostview and GSview:
<http://pages.cs.wisc.edu/~ghost>

PDFCreator:
<http://de.pdfforge.org>

FreePDF:
http://freepdfxp.de/index_de.html

PDF-XChange Editor:
www.pdf-xchange.de/pdf-xchange-viewer

PDF Split and Merge:
www.pdfsam.org

Isartor Test Suite:
www.pdfa.org/2011/08/download-isartor-test-suite

Free PDF/A Validator:
www.validatepdfa.com/online.htm

PDF/A Live! 6.0:
www.intarsys.de/pdf-produkte/pdfa-live

BeCyPDFMetaEdit:
www.becyhome.de/becypdfmetaedit/description_ger.htm

PDFInfo:
www.macupdate.com/app/mac/23356/pdfinfo

Hexonic PDF Metadata Editor:
www.hexonic.de/index.php/hexonic-pdf-metadata-editor

Metadata Extraction Tool:
<http://meta-extractor.sourceforge.net/>

3.2 Textdokumente

M. Trognitz

Textdokumente stellen in der alttumswissenschaftlichen Forschung einen häufig vertretenen Dateityp dar. In Artikeln, Berichten, Anträgen, Tagebüchern, Notizen oder Dokumentationen sind wichtige Informationen enthalten, deren Fortbestehen und Lesbarkeit gewährleistet sein müssen. Auch Beschreibungen von anderen Dateien und Datensätzen oder des gesamten Projektes können als Textdokumente vorliegen.

Die Mehrzahl der Dokumente besteht aus strukturiertem Text, nämlich Sätzen, Absätzen, Seiten, Fußnoten und Kapiteln, und kann Formatierungsangaben, wie verschiedene Schriftgrößen, Fett- oder Kursivschreibung enthalten. Zusätzlich können Medien, wie Bilder, Tabellen oder Videos in die Dokumente integriert sein. Da dasselbe Dokument auf verschiedenen Systemen unterschiedlich dargestellt werden kann, kann die Speicherung von Textdokumenten problematisch sein. Insbesondere wenn bestimmte Formatierungen von Textelementen mit einer Bedeutung verbunden sind und die Authentizität des Erscheinungsbildes, also das Aussehen des Dokumentes, wichtig ist, ist bei der Speicherung besondere Aufmerksamkeit erforderlich.

Langzeitformate Finalisierte Dokumente mit Formatierungsangaben können im Format PDF/A gespeichert werden. Dieses Format erlaubt eine konsistente Darstellung des Dokumentes auf verschiedenen Systemen, verhindert aber auch eine nachträgliche Bearbeitung. Nähere Informationen sind im Abschnitt über PDF-Dokumente ab Seite 37 zu finden.

Textdokumente mit Formatierungsangaben, bei denen auch weiterhin eine Bearbeitung möglich sein soll, sollten in einem offenen auf XML basierenden Format gespeichert werden, wie beispielsweise DOCX oder ODT. Ersteres ist das Standardformat, das in Microsoft Word seit 2007 verwendet wird und auch von Microsoft entwickelt wurde. Letzteres ist das Format für Textdokumente, welches in OpenOffice oder LibreOffice verwendet wird. ODT ist ein Teil vom OpenDocument Format (ODF) und wurde von einem technischen Komitee unter der Leitung der *Organization for the Advancement of Structured Information Standards* (OASIS) entwickelt. Die Darstellung von DOCX- oder ODT-Dokumenten kann jedoch von System zu System unterschiedlich ausfallen, wenn beispielsweise bestimmte Schriftarten fehlen. Gegebenenfalls kann das Dokument parallel im Format PDF/A gespeichert werden.

Bearbeitbare Textdokumente ohne Formatierungsangaben werden am besten als TXT-Datei gespeichert. Neben diesem einfachen, reinen Textformat (*plain text*) gibt es weitere textbasierte Formate, die auf eine bestimmte Weise strukturiert sind oder eine Auszeichnungssprache verwenden. Es handelt sich dabei um sogenannte Textdateien, die im Gegensatz zu binären Formaten darstellbare Zeichen enthalten und in Abhängigkeit ihrer Strukturierung unterschiedliche Dateiformate beschreiben. Beispielsweise werden mit Hilfe von CSV-Dateien Tabellen oder mit PLY-Dateien 3D-Inhalte gespeichert, jedoch werden diese Formate in den Abschnitten „Tabellen“ und „3D und Virtual Reality“ ab Seite 72 bzw. 88 behandelt. Für textuelle Inhalte gibt es spezialisierte Formate, wie beispielsweise SGML-, XML- oder HTML-Dateien. Die Archivierung dieser Dateien, die weit verbreiteten Konventionen folgen, ist unproblematisch, bedarf jedoch zusätzlicher Dateien, die die verwendete Struktur beschreiben, wie beispielsweise die sogenannte Dokumenttypdefinition (DTD, Document Type Definition) oder ein XML Schema (XSD, XML Schema Definition). Auch andere Textdateien mit spezieller Strukturierung können archiviert werden, wenn die Struktur im Dokumente oder in einer separaten Datei erläutert und mitarchiviert wird.

Alle Textdokumente sollten Unicode für die Zeichenkodierung verwenden, wobei UTF-8 ohne BOM besonders empfohlen wird, falls keine speziellen Anforderungen dagegen sprechen. Wenn die verwendete Zeichenmenge es erlaubt, ist ASCII ebenfalls geeignet.

Hinweis: Eingebettete Bilder oder andere Medien sollten zusätzlich separat gespeichert werden. Außerdem muss beachtet werden, dass Links oder dynamische Inhalte, nicht immer dauerhaft erhalten bleiben.

Format	Begründung
PDF/A ✓	Wenn neben dem Inhalt auch das Aussehen des Dokumentes erhalten bleiben soll, ist PDF/A am besten geeignet. Nähere Informationen sind in dem Abschnitt über PDF-Dokumente ab Seite 37 zu finden.
ODT	ODT basiert auf XML und ist Teil vom Open-Document Format. Damit können bearbeitbare Dokumente mit Formatierungssangaben gespeichert werden. ODF verwendet standardmäßig UTF-8 und erlaubt das Einbetten von Fonts.
DOCX	DOCX ist das auf XML basierende Format von Microsoft, das ebenfalls bearbeitbare Dokumente mit Formatierungssangaben speichern kann. DOCX verwendet standardmäßig UTF-8 und erlaubt das Einbetten von TrueType-Fonts.
TXT und <i>plain text</i>	Das Format eignet sich für reinen Text ohne Formatierungssangaben, wie Kursiv-, Fettschreibung oder Schriftgrößen. Die Zeichen sollten in UTF-8 ohne BOM kodiert sein.
strukturierter Text	Alle anderen textbasierten Formate, wie beispielsweise valide SGML-, XML- oder HTML-Dateien können ebenfalls archiviert werden. Für SGML und XML ist zusätzlich die DTD-Datei oder ein XML Schema erforderlich. Anders strukturierte textbasierte Dateien benötigen eine Erläuterung der Struktur innerhalb der Datei oder als zusätzliche separate Datei. Die Zeichen sollten in UTF-8 ohne BOM kodiert sein.
RTF ~	RTF ist ein proprietäres Format von Microsoft für den Datenaustausch, das von vielen Programmen unterstützt wird. Wegen möglichen Kompatibilitätsproblemen sollte DOCX oder ODT bevorzugt werden.
SXW	SXW ist ein Vorgängerformat von ODT, weshalb letzteres auch bevorzugt werden sollte.
DOC ✗	Das DOC-Format von Microsoft eignet sich nicht zur Archivierung, da es proprietär ist und die Inhalte nicht textbasiert gespeichert werden.
PDF	Für die Archivierung wurde speziell das Format PDF/A entwickelt, weshalb dieses verwendet werden sollte.

Dokumentation Metadaten für Textdokumente können in vielen Fällen direkt in das Dokument eingetragen werden. Beispielsweise als Deckblatt oder in dafür vorgesehenen Teilen von strukturierten Dokumenten. Zusätzlich kön-

nen einige Informationen als Dokumenteneigenschaften in der Datei gespeichert werden.

Neben den allgemeinen Angaben zu Einzeldateien, wie sie in dem Abschnitt Metadaten in der Anwendung ab Seite 24 gelistet sind, benötigen Textdokumente insbesondere Angaben zur verwendeten Zeichenkodierung und eine Auflistung der Sprachen.

Falls das Dokument publiziert wurde und eine ISBN oder einen anderen persistenten Identifikator erhalten hat, müssen diese neben den allgemeinen Angaben zur Publikation ebenfalls angegeben werden. Eingebettete Medien, wie Bilder oder Tabellen mit Formeln, sollten separat gespeichert und archiviert werden und in einer Liste weiterer Dateien aufgeführt werden.

Wenn das Aussehen wichtig ist und ein Format verwendet wird, welches das Einbetten von Schriftarten nicht ermöglicht, müssen die verwendeten Schriftarten explizit genannt werden.

Die hier angegebenen Metadaten sind als minimale Angabe zu betrachten und ergänzen die angegebenen Metadaten für Projekte und Einzeldateien in dem Abschnitt Metadaten in der Anwendung ab Seite 24.

Metadatum	Beschreibung
Zeichenkodierung	Welches Zeichenkodierung wird verwendet?
Sprache	In welchen Sprachen ist das Dokument verfasst? Sprachkennungen nach ISO 639 angeben.
Identifikator	Wenn das Dokument bereits veröffentlicht wurde und eine ISBN oder einen anderen persistenten Identifikator erhalten hat, bitte angeben.
weitere Dateien	Liste von eingebetteten Medien, die zusätzlich separat gespeichert wurden. Liegt eine Dokumentationsdatei für das Dokument vor, muss diese ebenfalls genannt werden.
Schriftarten	Angabe der verwendeten Schriftarten (Fonts), für Dokumente ohne eingebettete Fonts.

Weitere Metadaten sind methodenabhängig und können in den jeweiligen Abschnitten nachgelesen werden.

Vertiefung

Textdokumente und Textdateien bestehen aus einer Folge von Zeichen, die Wörter, Sätze und Absätze bilden. Auf Maschinenebene werden diese Zeichen durch Zahlenwerte gespeichert und die Zeichenkodierung beschreibt, welcher Zahlenwert für welches Zeichen steht.

Wie ein Zeichen dargestellt wird, hängt von der verwendeten Schriftart, dem sogenannten Font ab, der einen Satz an Bildern für die verschiedenen Schriftzeichen bereitstellt.

Die Inhalte von Textdateien können durch die Verwendung einer Auszeichnungssprache strukturiert und beschrieben werden und somit auch eine maschinelle Verarbeitung ermöglichen.

Zeichenkodierung und Zeichensatz Zur korrekten Darstellung der Zeichen in einem Textdokument muss der Computer wissen, welche Zeichenkodierung (*encoding*) verwendet wird. Auf Maschinenebene wird ein Zeichen als eine Folge von Nullen und Einsen, in Form von Bytes gespeichert, die wiederum bestimmte Zahlenwerte angeben. Diese Zahlenwerte können in Abhängigkeit der Zeichenkodierung unterschiedlich interpretiert werden.

Eine Zeichenkodierung kann abstrakt als eine Tabelle verstanden werden, in der einer bestimmten Zeichenmenge, dem Zeichensatz, Zahlenwerte zugeordnet werden. Beispielsweise hat der Buchstabe *A* in dem *American Standard Code for Information Interchange* (ASCII) den dezimalen Zahlenwert von 65. Der ASCII-Zeichensatz besteht aus insgesamt 128 Zeichen die jeweils mit einem Byte gespeichert werden. Er enthält keine diakritischen Zeichen oder gar andere Schriften, weshalb verschiedene Erweiterungen der ASCII-Kodierung entwickelt wurden, um insgesamt 256 verschiedene Zeichen zu kodieren.

Beispiele für diese Erweiterungen sind ISO 8859-1 für lateinische Schriften oder ISO 8859-7 für das griechische Alphabet. In beiden Zeichenkodierungen hat das Zeichen *A* jeweils den Wert 65. Jedoch stellt der Wert 228 in ISO 8859-1 das Zeichen *ä* und in ISO 8859-7 das Zeichen *δ* dar. Die Angabe der verwendeten Zeichenkodierung ist entscheidend dafür, ob auf dem Bildschirm *öå÷íç* oder *τεχνη* dargestellt wird.

In der Vergangenheit war es besonders schwierig, wenn in einem Text gleichzeitig Umlaute und griechische Buchstaben verwendet werden sollten, da jede ASCII-Erweiterung jeweils nur insgesamt 256 Zeichen kodiert und einem Dokument nicht mehr als eine Zeichenkodierung zugewiesen werden kann. Deshalb wurde Unicode entwickelt.

Unicode ist ein Zeichensatz, in dem aktuell für 113.021 Zeichen aus 123 Schriftsystemen eindeutige Codepunkte (*code points*) zugewiesen werden. Die Codepunkte werden mittels einer hexadezimalen Zahl und einem vorangestellten *U+* dargestellt, wie beispielsweise *U+00C4* für *ä*. Zugleich stellt dieser Zeichensatz die Umsetzung von dem in ISO 10646 beschriebenen universellen Zeichensatz *Universal Character Set* dar.

Um den Unicode-Zeichensatz in einem System anwenden zu können, wurden Zeichenkodierungen definiert, die unter dem Namen *Unicode Transformation Format* (UTF) subsumiert werden. Zu den häufigsten gehören dabei UTF-8 und UTF-16, die im Web und in verschiedenen Betriebssystemen eine große Verbreitung gefunden haben. Der Unterschied besteht dabei in der Zahl der pro Zeichen verwendeten Bytes. Eine Besonderheit von UTF-8 besteht darin, dass die Bytedarstellungen der ersten 128 Zeichen denen der 128 Zeichen des ASCII-Zeichensatzes entspricht.

Das Unicode-Zeichen *U+FEFF* gibt am Anfang des kodierten Dokumentes an, in welcher Reihenfolge die Bytes angeordnet sind. Diese Bytereihenfolge-Markierung (engl. *byte order mark*) wird als *BOM* abgekürzt und ist bei der Verwendung von UTF-16 und UTF-32 zwingend in der Datei erforderlich. Zusätzlich kann das BOM ein Hinweis auf die Verwendung von UTF-Kodierungen sein, jedoch wird von dessen Verwendung außer für UTF-16 und UTF-32 abgeraten.

Schriftart Das optische Erscheinungsbild eines Textdokumentes hängt maßgeblich von den verwendeten Schriftarten (Fonts) ab. Es handelt sich dabei um

die elektronische Form von Schriftarten, die für jedes Zeichen eine Raster- oder Vektorgrafik zur Verfügung stellt.

Nicht auf jedem Rechner sind die gleichen Schriftarten installiert. Wenn ein Textdokument auf einem anderen System geöffnet wird, wo die Schriftarten nicht verfügbar sind, werden diese automatisch durch andere ersetzt. Das kann zu Inkonsistenzen der Dokumentdarstellung auf unterschiedlichen Systemen führen, weil beispielsweise Wörter, Sätze oder Absätze von einer Seite auf die nächste oder vorhergehende wandern, was für die Referenzierung von Inhalten problematisch ist.

Daher muss für Dokumente, deren optischer Eindruck erhalten bleiben soll, zumindest der verwendete Font in den Metadaten angegeben werden. Wenn es das Format erlaubt, kann der Font auch in die Datei eingebettet werden, wobei allerdings darauf geachtet werden muss, dass die Lizenzen für die verwendete Schriftart vorhanden sind. Das Einbetten von Fonts ist bei PDF-Dokumenten mit geringem Aufwand möglich. Ab der Version 4.1 von LibreOffice ist das Einbetten von Schriftarten auch für das ODT-Format möglich. Microsoft Word bietet diese Funktionalität ebenfalls für das DOCX-Format an. Aktuell funktioniert die Einbettung von Fonts in andere Dateiformate als PDF nicht völlig fehlerfrei.

Auszeichnungssprachen Der Inhalt von reinen Textdateien kann durch die Verwendung von Auszeichnungssprachen (*Markup Languages*) näher beschrieben werden. Beispielsweise können verschiedene Gliederungsebenen mit Hilfe von bestimmten Auszeichnungselementen (auch *Tags*) annotiert werden. Wie diese Tags aussehen und wie sie angewendet und kombiniert werden können, beschreibt eine Dokumentgrammatik. Abstrakt können Tags mit Etiketten verglichen werden, die einzelne Wörter, Wortgruppen oder ganze Textbereiche umschließen. Die Abbildung 3.5 veranschaulicht, wie mit einem Tag die Zeichenkette „24-28“ als Größenangabe etikettiert wird. Das Tag besteht aus einem öffnenden Teil vor und einem schließendem Teil nach der fraglichen Zeichenkette, wobei das schließende Element zusätzlich durch einen Schrägstrich gekennzeichnet ist.

Mit Auszeichnungssprachen wird das Aussehen eines Textdokumentes von dessen Struktur und Inhalt getrennt. Beispielsweise basieren Webseiten auf HTML-Dateien in denen Überschriften, Absätze, Links etc. mit Tags gekennzeichnet werden, die den Inhalt strukturieren. Wie dann beispielsweise die Überschriften formatiert werden, hängt von einer zusätzlichen Datei mit Formatierungsangaben ab, die austauschbar ist.

Die Grundlage vieler heute verwendeter Auszeichnungssprachen bildet die Standard Generalized Markup Language (SGML, Normierte Verallgemeinerte Auszeichnungssprache), die seit 1986 ein ISO-Standard (ISO 8879) ist. Die Regeln für die zu verwendenden Auszeichnungselemente und deren Kombinationsmöglichkeiten sind üblicherweise in einer externen Datei hinterlegt und werden zu Beginn der Datei in der Dokumenttypdeklaration angegeben. Bei SGML handelt es sich dabei um die sogenannte Dokumenttypdefinition (DTD).

```
<groesse>24-28</groesse>
```

Abb. 3.5: Die Zeichenkette „24-28“ wird durch das Umschließen mit einem Tag als Größenangabe gekennzeichnet.

Eine Anwendung von SGML ist die Hypertext Markup Language (HTML, Hypertext-Auszeichnungssprache), welche als Grundlage von Webseiten eine sehr große Verbreitung gefunden hat. HTML wird vom World Wide Web Consortium (W3C) und der Web Hypertext Application Technology Working Group (WHATWG) gepflegt und entwickelt. Die aktuellste Version ist HTML5.

Eine Teilmenge von SGML bildet die Extensible Markup Language (XML, Erweiterbare Auszeichnungssprache) und erlaubt im Gegensatz zu HTML die Definition von eigenen Auszeichnungselementen, um beliebige Strukturen annotieren zu können. De facto wurde SGML von der einfacher anwendbaren XML verdrängt. Auch XML wird vom W3C gepflegt und entwickelt. XML bildet die Grundlage von vielen weiteren Dateiformaten wie ODT, DOCX, SVG etc. Für XML-Dateien gibt es als Alternative zu einer DTD die Möglichkeit der Verwendung eines XML Schemas (XSD, XML Schema Definition).

Auszeichnungssprachen machen implizite Informationen, die nur für den menschlichen Leser verständlich sind, explizit. Dadurch wird ein Dokument maschinenlesbar und eine automatische Verarbeitung von semantisch annotierten Informationen in Texten wird ermöglicht. Beispielsweise kann eine Münze mit Tags beschrieben werden, die das Material, das Gewicht, die Größe, das Avers und den Revers kennzeichnen. So weiß auch ein Computerprogramm, welche Zeichenfolge in einer Datei sich auf das Material oder das Gewicht einer Münze bezieht.

Speziell für Geistes-, Sozial- und Sprachwissenschaften wird von der Text Encoding Initiative (TEI) ein auf XML basierendes Dokumentenformat entwickelt, das den Austausch von maschinenlesbaren Texten unterstützen und standardisieren soll. Die aktuelle Version ist P5.

Es gibt weitere Auszeichnungssprachen, die speziell die Darstellung der Dokumente beschreiben, also definieren, wie ein Dokument auf dem Bildschirm oder gedruckt aussehen soll. Beispiele hierfür sind das Textsatzsystem T_EX mit dem Makropaket L_TE_X, PDF oder PostScript.

Für alle Dateien, die Auszeichnungssprachen verwenden gilt, dass sie wohlgeformt und valide sein müssen. Wohlgeformt meint das Einhalten der Regeln der jeweiligen Auszeichnungssprache. Die Validität bezieht sich auf die verwendete Grammatik und gilt insbesondere für SGML-, HTML- und XML-Dateien. Beispielsweise muss eine XML-Datei einen Verweis auf eine DTD oder ein XML Schema ent-



```
<objekt typ="muenze">
  <material>Silber</material>
  <gewicht einheit="gramm">16,96</gewicht>
  <groesse einheit="mm">24-28</groesse>
  <avers>Kopf der Athena</avers>
  <revers>ΑΘΕ. Εule</revers>
</objekt>
```

Abb. 3.6: Tetradrachme; Objektnummer 18214973 Münzkabinett – Staatliche Museen zu Berlin, Lizenz: CC-BY-NC-SA 3.0 mit einer Beschreibung in XML-Form. Das Material, das Gewicht, die Größe, das Avers und der Revers sind mit Tags gekennzeichnet. Zusätzlich ist die Maßeinheit von Gewicht und Größe als Attribut angegeben.

halten und auch die dadurch vorgegebene Struktur einhalten, um als valide zu gelten.

Praxis

Dieser Abschnitt liefert Hinweise zum Umgang mit Textdokumenten und Textdateien in der Praxis. Neben Hinweisen zur Ergänzung und Extraktion von Metadaten werden auch Texteditoren und das Einstellen der Zeichenkodierung sowie die Einbettung von Schriftarten in Textdokumenten thematisiert. Für die Digitalisierung von Texten wurden die wichtigsten Informationen aus den DFG-Praxisregeln „Digitalisierung“ zusammengefasst.

Metadaten bearbeiten und ergänzen In der Regel werden nur wenige Metadaten automatisch in Textdokumenten von Textverarbeitungsprogrammen wie Microsoft Word, OpenOffice oder LibreOffice angelegt und gespeichert. Dazu gehören vor allem technische Informationen, wie Dateigröße, Dateiname, Erstellungs- und Änderungsdatum. Auch eine Statistik mit der Anzahl der Zeichen, Wörter, Absätze etc. wird erstellt. Als Autor wird der für das jeweilige Programm angegebenen Nutzernname gespeichert. Über die Menüpunkte „Datei > Informationen > Eigenschaften“ bzw. „Datei > Eigenschaften“ lassen sich die Angaben anpassen und ergänzen. Beispielsweise kann ein Titel, Schlagworte und ein Beschreibungstext eingefügt werden. Zusätzliche Angaben können unter „Anpassen“ bzw. „Benutzerdefinierte Eigenschaften“ aus einer Liste gewählt und ausgefüllt werden. Darüber hinausgehende Informationen wie beispielsweise ein Identifikator oder Angaben zur Lizenz, können in einer getrennten Text- oder XML-Datei hinterlegt werden. Ausführlicheres ist in „Verfahren zur Produktion interoperabler Metadaten in digitalen Dokumentenverarbeitungsprozessen“ von Alexander Haffner zu finden.

Bei Textdokumenten bietet sich die Möglichkeit, neben einem Deckblatt auch einen Innentitel mit den relevanten Metadaten zu integrieren. Hier können zusätzlich ein Zitierhinweis und eine längere Versionshistorie untergebracht werden. Ein Beispiel für solch ein Innentitel findet sich am Anfang der PDF-Version dieser Empfehlungen.

In reinen Textdateien, wie TXT oder *plain text*, können keine Metadaten als Eigenschaften in das Dateiformat integriert werden. Es besteht jedoch die Möglichkeit, sie mit in das Dokument einzutragen oder eine separate Datei anzulegen. Auszeichnungssprachen bieten zu diesem Zweck meist einen eigens dafür vorgesehenen Bereich am Beginn der Datei, den sogenannten Kopfbereich oder *Header*.

Tools wie beispielsweise Metadata Extraction Tool oder eines der Tools, die auf forensicswiki.org gelistet sind, können verwendet werden, um Metadaten zu extrahieren und in separaten Dateien zu speichern.

Metadata Extraction Tool:

<http://meta-extractor.sourceforge.net/>

Tools zur Extraktion von Metadaten:

http://www.forensicswiki.org/wiki/Document_Metadata_Extraction#Office_Files

Texteditoren und Editoren für Auszeichnungssprachen Textdokumente mit Formatierungsangaben werden üblicherweise mit Textverarbeitungsprogrammen, wie Microsoft Word oder LibreOffice erstellt und bearbeitet. Soll mit Textdateien wie TXT, XML oder HTML gearbeitet werden, besteht bei Textverarbeitungsprogrammen die Gefahr, dass die Datei korrumptiert wird.

Für die Bearbeitung von Textdateien sind einfache Texteditoren am besten geeignet. In den verschiedenen Betriebssystemen ist üblicherweise mindestens ein Texteditor vorinstalliert, wie beispielsweise *Editor* oder *Notepad* bei Microsoft Windows. Im Vergleich zu Textverarbeitungsprogrammen ist der Funktionsumfang bei Texteditoren deutlich kleiner, was besonders bei den vorinstallierten Editoren der Fall ist.

Gerade für den täglichen Umgang mit Textdateien empfiehlt sich die Verwendung von leistungsfähigen Editoren, die neben ausgefeilten Suchfunktionen auch Auto vervollständigung oder für Auszeichnungssprachen Syntaxhervorhebung bieten. Für Mac OS X gibt es beispielsweise TextWrangler und für Windows Notepad++ als kostenlose Angebote. Eine umfangreiche vergleichende Liste von Texteditoren ist auf Wikipedia zu finden.

Für den regelmäßigen Umgang mit einem bestimmten Format, wie etwa HTML oder XML, können weiter spezialisierte Editoren praktisch sein.

Notepad++:

<http://www.notepad-plus-plus.org/>

TextWrangler:

<http://www.barebones.com/products/textwrangler/>

Vergleich von Texteditoren auf Wikipedia:

http://en.wikipedia.org/wiki/Comparison_of_text_editors

Einstellen der Zeichenkodierung Wenn keine besonderen Anforderungen dagegen sprechen, sollte Unicode für die Zeichenkodierung verwendet werden. Dabei sollte UTF-8 ohne BOM bevorzugt werden.

In modernen Textverarbeitungsprogrammen, die DOCX oder ODT speichern, ist dies meistens voreingestellt und muss nicht weiter angepasst werden.

Bei der Bearbeitung von Textdateien mit Texteditoren muss auf die richtigen Einstellungen und Speicheroptionen geachtet werden. Insbesondere wenn eine Datei auf verschiedenen Geräten bearbeitet wird, ist es wichtig, dass die ursprünglichen Dateieinstellungen, wie eben die Zeichenkodierung, beibehalten werden.

In *Notepad++* kann für alle neu anzulegenden Dateien eine Zeichenkodierung vorgegeben werden. Dazu im Menü auf „Einstellungen > Optionen“ klicken und unter „Neue Dateien“ die gewünschte Kodierung auswählen. Wird eine vorhandene Textdatei mit *Notepad++* geöffnet und bearbeitet, werden beim Speichern die ursprünglichen Einstellungen der Datei üblicherweise behalten. Die Kodierung einer vorhandenen Datei kann über den Menüpunkt „Kodierung“ geändert werden.

In *Text Wrangler* ist diese Option unter „TextWrangler > Preferences > Text Encoding“ zu finden. Auch hier werden die Einstellungen der Zeichenkodierung einer vorhandenen Datei beibehalten. Zusätzlich besteht die Möglichkeit die Zeichenkodierung zu ändern, indem eine Datei über „File > Reopen Using Encoding“ und der gewünschten Kodierung geöffnet wird.

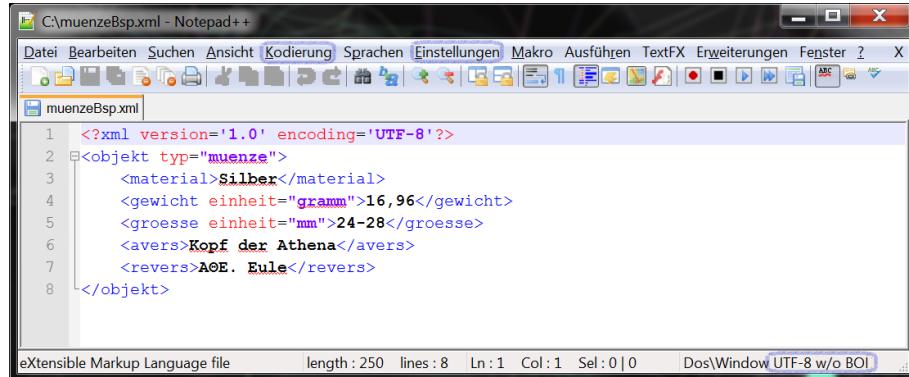


Abb. 3.7: Screenshot von Notepad++ mit einer geöffneten XML-Datei. Die Menüpunkte „Einstellungen“ und „Kodierung“ wurden hervorgehoben. Im unteren rechten Bereich ist die Anzeige der verwendeten Zeichenkodierung gekennzeichnet.

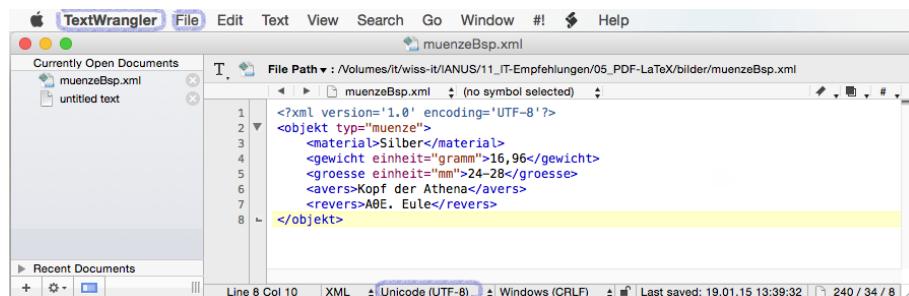


Abb. 3.8: Screenshot von TextWrangler mit einer geöffneten XML-Datei. Die Menüpunkte „TextWrangler“ und „File“ wurden hervorgehoben. Im unteren linken Bereich ist die Anzeige der verwendeten Zeichenkodierung gekennzeichnet.

In beiden erwähnten Texteditoren wird in dem unteren Bereich des Programmfensters die Zeichenkodierung der aktuell geöffneten Datei angezeigt.

Einbettung von Schriftarten Da das optische Erscheinungsbild eines Textdokumentes unter anderem von den verwendeten Schriftarten abhängt, kann die Einbettung derselben ratsam sein. Dabei muss darauf geachtet werden, dass die Lizenzen für die verwendeten Fonts vorhanden sind.

Ab Version 4.1 können in LibreOffice die benutzten Fonts in das ODT-Format eingebettet werden. Dazu im Menü auf „Datei > Eigenschaften“ gehen und in dem Dialog den Reiter „Schriftart“ anwählen. Dort muss ein Haken bei „Schriftarten ins Dokument einbetten“ gesetzt werden und nach dem Bestätigen werden beim Speichern des Dokumentes die Schriftarten eingebettet. Dieser Vorgang muss für neue oder andere Dokumente wiederholt werden.

Auch in Microsoft Word ist diese Einstellung für das DOCX-Format möglich.

Dazu auf „Datei > Optionen“ gehen. In dem Dialog den Punkt „Speichern“ auf der linken Seite auswählen und einen Haken bei „Schriftarten in der Datei einbetten“ setzen. Diese Einstellung ist ebenfalls nur für das aktuelle Dokument gültig und muss bei anderen Dokumenten bei Bedarf wiederholt werden.

Werden Textdokumente als PDF exportiert, so werden die verwendeten Schriftarten automatisch eingebettet.

Digitalisate Für die Digitalisierung von analogen Schriftstücken mittels eines Scanners gibt es ausführliche Hinweise in den *DFG-Praxisregeln "Digitalisierung"*.

Eine kurze Übersicht aus dem oben angegebenen Dokument ist in der folgenden Tabelle zu finden:

Größe des kleinsten signifikanten Zeichens	Auflösung
bis 1 mm	min. 400 dpi
ab 1,5 mm	min. 300 dpi

Die Speicherung erfolgt in Form unkomprimierter Baseline TIFF-Dateien.

Um zu verdeutlichen, dass von der Vorlage nichts abgeschnitten wurde, sollten Seiten immer vollständig mit einem umlaufenden Rand gesichert werden.

Der Scan eines Textdokumentes ist zunächst eine digitale Rastergrafik, die erst durch optische Zeichenerkennung (OCR, von engl. *Optical Character Recognition*) oder Transkription zu einem digitalen Textdokument wird. Mit OCR bearbeitete Texte benötigen eine Angabe zur Genauigkeit der Buchstaben in Prozent. Ab Seite 30 der Praxisregeln wird die Ermittlung der Buchstabengenauigkeit beschrieben.

Die DFG-Praxisregeln beziehen sich teilweise auf die Richtlinien der Federal Agencies Digitization Guidelines Initiative (FADGI), die in englischer Sprache in dem Dokument „*Technical Guidelines for Digitizing Cultural Heritage Materials: Creation of Raster Image Master Files*“ zu finden sind.

Bei der Neubeschaffung eines Scanners muss darauf geachtet werden, dass er die Mindestanforderungen für den jeweiligen Digitalisierungszweck erfüllt.

Quellen

Archaeology Data Service, Documents and Digital Texts: A Guide to Good Practice

http://guides.archaeologydataservice.ac.uk/g2gp/TextDocs_Toc

A. Haffner, Verfahren zur Produktion interoperabler Metadaten in digitalen Dokumentenverarbeitungsprozessen (Frankfurt am Main 2011)
http://www.kim-forum.org/Subsites/kim/DE/Materialien/Dokumente/dokumente_node.html#doc42066bodyText7

R. Ishida, Zeichencodierung für Anfänger
<http://www.w3.org/International/questions/qa-what-is-encoding>

R. Ishida, Zeichencodierungen: grundlegende Konzepte
<http://www.w3.org/International/articles/definitions-characters/>

- A. Morrison – M. Popham – K. Wikander, Creating and Documenting Electronic Texts: A Guide to Good Practice
<http://ota.ahds.ac.uk/documents/creating/cdet/index.html>
- A. Morrison – M. Wynne, AHDS Preservation Handbook: Marked-up Textual Data (2005)
http://ota.ahds.ac.uk/documents/preservation/preservation_markup.pdf
- nestor (Hrsg.) Nicht von Dauer: Kleiner Ratgeber für die Bewahrung digitaler Daten in Museen (2009) 22-28
- H. Neuroth – A. Oßwald – R. Scheffel – S. Strathmann – M. Jahn (Hrsg.) nestor Handbuch. Eine kleine Enzyklopädie der digitalen Langzeitarchiverung. Version 2.0 (2009) Kap. 17.2
- G. Rehm, Texttechnologische Grundlagen, in: K.-U. Carstensen – Ch. Ebert – C. Endriss – S. Jekat – R. Klabunde – H. Langer (Hrsg.) Computerlinguistik und Sprachtechnologie. Eine Einführung²(München 2004) 138-147
- TEI (Hrsg.) A Gentle Introduction to XML
<http://www.tei-c.org/release/doc/tei-p5-doc/de/html/SG.html>
- DFG-Praxisregeln „Digitalisierung“
http://www.dfg.de/formulare/12_151/12_151_de.pdf
- FAQ zu UTF und BOM
http://www.unicode.org/faq/utf_bom.html

Formatspezifikationen

ODT:

<https://www.oasis-open.org/standards#opendocumentv1.2>

DOCX: ECMA-376

<http://www.ecma-international.org/publications/standards/Ecma-376.htm>

SGML: ISO 8879

<http://www.iso.ch/cate/d16387.html>

HTML: WHATWG – W3C (Hrsg.) HTML5 (2014)

<http://www.w3.org/TR/html5/>

XML: T. Bray – J. Paoli – C. M. Sperberg-McQueen – E. Maler, F. Yergeau, Extensible Markup Language (XML) 1.0⁵(2008)

<http://www.w3.org/TR/xml/>

XSD:

http://www.w3.org/TR/#tr_XML_Schema

TEI: Text Encoding Initiative (TEI)

<http://www.tei-c.org/index.xml>

TEI: TEI (Hrsg.) P5: Richtlinien für die Auszeichnung und den Austausch elektronischer Texte

<http://www.tei-c.org/release/doc/tei-p5-doc/de/html/index.html>

Unicode: Unicode Consortium (Hrsg.) Unicode 7.0.0

<http://www.unicode.org/versions/Unicode7.0.0/>

Tools und Programme

Metadata Extraction Tool:

<http://meta-extractor.sourceforge.net/>

Tools zur Extraktion von Metadaten:

http://www.forensicswiki.org/wiki/Document_Metadata_Extraction#Office_Files

Notepad++:

<http://www.notepad-plus-plus.org/>

TextWrangler:

<http://www.barebones.com/products/textwrangler/>

Vergleich von Texteditoren auf Wikipedia:

http://en.wikipedia.org/wiki/Comparison_of_text_editors

3.3 Rastergrafiken

M. Trognitz, P. Grunwald

Bei Rastergrafiken, auch Pixelgrafiken, handelt es sich um digitale Bilder, die mittels rasterförmig angeordneter Bildpunkte, den Pixeln, beschrieben werden. Jedem Pixel ist dabei ein Farbwert zugeordnet. Rastergrafiken haben eine fixe Größe und sind im Gegensatz zu Vektorgrafiken nicht beliebig skalierbar.

Zu den Rastergrafiken gehören: Digitale Fotografien jeder Art, Satellitenbilder, digitalisierte Bilder (Scans), Screenshots sowie digitale Originalbilder und -grafiken.

Langzeitformate Alle als Rastergrafiken vorliegenden Roh- und Urfassungen (Master) von Bildern sind in angemessener Qualität und unkomprimiert im baseline TIFF- oder DNG-Format abzuspeichern. Für georeferenziertes digitales Bildmaterial ist zwecks Erhalt der Referenzdaten das Geo-Tiff-Format zu verwenden.

Nur für Grafiken, *nicht* für Fotos, eignet sich auch das PNG-Format. Allerdings ist jederzeit das TIFF-Format vorzuziehen. JPEG, bzw. JPG, eignet sich nicht zur Langzeitarchivierung, da es keine verlustfreie Komprimierung anbietet.

Es muss darauf geachtet werden, dass die Bildgröße und -auflösung der originalen Datei erhalten bleibt, wenn in andere Formate umgewandelt wird. Außerdem muss bei der Konvertierung darauf geachtet werden, dass eine verlustfreie Komprimierung verwendet wird. Auch Farbtiefe und Farbraum sollten nach der Konvertierung erhalten bleiben.

Bilder, die Ebenen enthalten, müssen vorher auf eine Ebene reduziert werden. Bei Bedarf, sollten die verschiedenen Ebenen und Komponenten als einzelne Dateien abgespeichert werden.

Hinweis: Wiederholtes Bearbeiten und Abspeichern, führt zu einer allmählichen Abnahme der Qualität. Dieser sogenannte Generationsverlust tritt insbesondere bei der verlustbehafteten Bildkomprimierung auf.

Format	Begründung
✓ Baseline TIFF, unkomprimiert	TIFF ist quasi ein Standardformat für die digitale Langzeitarchivierung von Bilddateien und unterstützt auch die Speicherung von Metadaten im Exif-Format. Obwohl das Format auch Kompression verwenden kann, kommt für die Langzeitarchivierung nur die unkomprimierte Form in Frage.
DNG	Das von Adobe entwickelte Digital Negative Format ist ein offenes Format, das für die Langzeitarchivierung geeignet ist. Damit können RAW-Dateien und deren Metadaten (Exif oder IPTC-NAA) gelesen und gespeichert werden. Außerdem können über XMP weitere Metadaten eingespeist werden.
GeoTIFF	GeoTIFF basiert auf TIFF und ist besonders für georeferenzierte Bilddaten geeignet, da somit die Referenzdaten erhalten bleiben.
~ PNG	PNG ist eine verlustfreie Alternative zu dem GIF-Format, welches eine verlustbehaftete Kompression verwendet. Es bietet eine Farbtiefe von 32 Bit, einen Alphakanal für Transparenz und verlustfreie Kompression. Allerdings wird nur RGB als Farbraum unterstützt und es können keine Exif-Daten gespeichert werden. Das Format eignet sich <i>nicht</i> für digitale Fotos.
✗ JPEG	Trotz einiger Vorteile, eignet sich das JPEG-Format <i>nicht</i> für die Langzeitarchivierung, da es <i>keine</i> verlustfreie Komprimierung bietet.
GIF	GIF kann sowohl statische, als auch animierte Bilder speichern. Da es aber verlustbehaftet komprimiert, wird PNG als Alternativformat empfohlen.

Dokumentation Eingebettete Metadaten, wie Exif, IPTC-NAA oder XMP, sollten behalten und archiviert werden. Am besten werden sie in eine eigene Text- oder XML-Datei transferiert und getrennt gespeichert.

Neben technischen Informationen, die sich hauptsächlich mit der Erstellung der Rastergrafik befassen, sollten vor allem auch beschreibende und administrative Metadaten über das Bild gespeichert werden.

Hinweis: Werden digitale Aufnahmen mit Programmen bearbeitet, welche die eingebetteten Metadaten ignorieren, gehen diese verloren.

Die hier angegebenen Metadaten sind als minimale Angabe zu betrachten und ergänzen die angegebenen Metadaten für Projekte und Einzeldateien in dem Abschnitt Metadaten in der Anwendung ab Seite 24.

Metadatum	Beschreibung
Identifikator	Name der Datei, z.B. grabung01.tif
Bildunterschrift	Der Titel oder eine passende Bildunterschrift des Bildes
Beschreibung	Beschreibung des Bildes
Urheber	Name des Fotografen oder Erstellers
Datum	Datum der Erstellung oder letzten Änderung des Bildes
Rechte	Details zum Urheberrecht
Schlagworte	Schlagworte, wie z.B. Periode, Fundstelle oder charakteristische Merkmale. Wenn vorhanden, angemessene Thesauri verwenden
Ort	Ortsinformationen zu dem Bild. Möglichst in einem standardisierten Format angeben, wie z.B. Lat/Long oder Schlagworte aus einem geeigneten Thesaurus, z.B. Getty Thesaurus of Geographic Names oder GeoNames
Dateiformat & Version	z.B. Baseline TIFF 6.0
Dateigröße	Größe der Datei in Bytes
Bildgröße	Maße des Bildes gemessen in Pixeln, z.B. 400px × 700px
Auflösung	Bildauflösung, gemessen in Punkten pro Zoll (dpi)
Farbraum	Der in dem Bild verwendete Farbraum, z.B. RGB oder Graustufen
Farbtiefe	z.B. 24 bit oder 8 bit
Aufnahmegerät	Beispielsweise Details zur Kamera oder dem Scanner
Software	Software mit der das Bild aufgenommen, erstellt oder bearbeitet wurde, wie z.B. Adobe Photoshop CS3

Weitere Metadaten sind methodenabhängig und können in den jeweiligen Abschnitten nachgelesen werden.

Vertiefung

Da eine Rastergrafik mit in einem rechteckigen Raster angeordneten Bildpunkten beschrieben wird und jedem dieser Punkte (Pixel), ein Farbwert zugeordnet wird, gibt es zwei Hauptmerkmale: die Bildgröße und die Farbtiefe. Abhängig von der Bildgröße ist die Auflösung. Hinzu kommen noch weitere Eigenschaften, wie Farbmodell und Farbraum, Komprimierung, Transparenz, Ebenen und Metadaten die hier ausführlicher erklärt werden.

Die einzelnen Eigenschaften können in Abhängigkeit von Quelle und Verwendung der Grafik stark variieren. Es ist praktisch unmöglich, genaue Vorgaben für die einzelnen Einstellungsmöglichkeiten zu machen. Sie sollten im Kontext des

Projektes betrachtet werden und ihren Zweck erfüllen. Nichtsdestotrotz werden in diesem Abschnitt Anmerkungen über die Qualität gemacht.

Entscheidend für die Nachnutzung von Rastergrafiken ist die Dokumentation, worin auch die Entscheidung für ein bestimmtes Format und dessen Einstellungen begründet werden kann.

Bildgröße und Auflösung Die Bildgröße beschreibt den Detaillierungsgrad einer Grafik mittels der Pixelanzahl. Dabei gilt: Je mehr Bildpunkte, desto höher ist auch der Detaillierungsgrad und die Dateigröße. Die Pixelanzahl kann durch die Gesamtanzahl der Bildpunkte, wie beispielsweise in der Digitalfotografie mittels Megapixeln, oder mit der Anzahl der Bildpunkte je Zeile mal der Anzahl der Bildpunkte je Spalte (z.B. 1024×768) angegeben werden. Aus der zweiten Darstellungsvariante geht auch das Seitenverhältnis hervor.

Umgangssprachlich wird die Bildgröße auch als Bildauflösung bezeichnet. Allerdings hängt die Auflösung von einem physikalischen Wiedergabemedium (z.B. Bildschirm oder ein A4 Ausdruck) ab, wobei die Punktdichte maßgeblich für die Wiedergabequalität ist. Die Punktdichte wird üblicherweise in Punkten (*dots per inch; dpi*), Pixeln (*pixel per inch; ppi*) oder Linien (*lines per inch; lpi*) pro Zoll (*inch*) angegeben.

Soll das Bild nur digital verwendet werden, reicht eine minimale Auflösung von 72dpi aus. Wenn das Bild jedoch gedruckt werden soll, muss mit einer Mindestauflösung von 300dpi gearbeitet werden.

Abhängig von der Aufgabe einer Rastergrafik muss eine geeignete Bildgröße gewählt werden. Dabei sollte bedacht werden, dass die Dateigröße mit dem Detaillierungsgrad steigt, und somit eine Balance zwischen dem benötigtem Detaillierungsgrad und der Dateigröße gefunden werden muss.

Farbtiefe Mit der Farbtiefe (engl. auch *bit depth*) wird die Anzahl der Bits angegeben, die den Farbwert eines Pixels speichern. Ein Bit kann dabei 2^1 , also zwei Farbwerte (z.B. Schwarz und Weiß) speichern. Die Anzahl der darstellbaren Farbwerte steigt mit der Anzahl der Bits exponentiell. So können mit 8 Bits bereits 2^8 also 256 Farbwerte (üblicherweise Graustufen) und mit 24 Bits schon $2^{24} = 16.777.216$ Farbwerte (*True color*) dargestellt werden. Größere Farbtiefen von 30, 32, 36, 40 und 48 Bit werden hauptsächlich im Scan-, Kino-, TV- und Druckbereich verwendet.

Wie bei der Bildgröße steigt auch hier die Dateigröße mit der Farbtiefe, weshalb nur die minimal notwendige Farbtiefe gewählt werden sollte. Beispielsweise reicht es aus, eine Schwarz-weiß Grafik mit 8-Bit Graustufen zu speichern.

Ein Spezialfall sind indizierte Farben. Dabei wird für ein Pixel nicht direkt

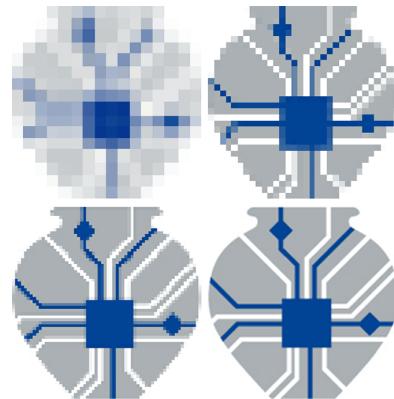


Abb. 3.9: Je mehr Bildpunkte eine Rastergrafik enthält, desto detaillierter wird die Abbildung. Die gleiche Grafik wurde hier mit 16x16, 32x32, 64x64 und 185x185 Pixeln dargestellt.

der Farbwert, sondern ein Index auf eine Farbe aus einer vorgegebenen Farbtabelle oder Farbpalette gespeichert. Somit können Bilder mit wenigen Farben Speicherplatz einsparen. Beispielsweise bietet das Dateiformat GIF eine Farbtiefe von 8 Bit.

Farbmodell und Farbraum Ein Farbmodell ist ein mathematisches Modell, das üblicherweise mit Hilfe von Zahlentupeln beschreibt wie Farben dargestellt werden können. Alle Farben eines Farbmodells können dreidimensional als Farbraum dargestellt werden.

Übliche Farbmodelle sind RGB und CMYK. RGB wird hauptsächlich für die Bildschirmanzeige verwendet, während CMYK im Druckbereich verwendet wird. Insgesamt enthält RGB mehr Farbkombinationen als CMYK, weshalb es sein kann, dass RGB-Grafiken nicht exakt farbtreu gedruckt werden können.

Ein Farbmodell kann auf mehrere Farbräume abgebildet werden, weshalb es für RGB unter anderem die Farbräume *sRGB* und *Adobe RGB* gibt. Die eben genannten Farbräume sind genormte, ausreichend große Farbräume, die für die meisten Anwendungen ausreichen.

Die Kombination von Farbtiefe und Farbmodell beschreibt wie viele Bits pro Farbwert zur Speicherung zur Verfügung stehen und wie viele Farben im Endeffekt dargestellt werden. Beispielsweise bietet *True Color* für RGB, mit einer Farbtiefe von 24 Bit, jeweils 8 Bit für Rot, Grün und Blau. Da man bei CMYK noch einen vierten Wert berücksichtigen muss, hat *True Color* für CMYK eine Farbtiefe von 32 Bit.

Wenn man im Zweifel ist, ob RGB oder CMYK verwendet werden soll, ist zu empfehlen das RGB-Farbmodell zu verwenden, da damit mehr Farben abgebildet werden können. Bei Bedarf lässt sich der Farbraum nachträglich in CMYK oder in einen indizierte Farbraum konvertieren.

Komprimierung Das Ziel einer Komprimierung ist, die Dateigröße für einen bestimmten Zweck zu reduzieren, wie etwa zur Darstellung im Internet. Die Komprimierung von Rastergrafiken kann entweder verlustfrei oder verlustbehaftet erfolgen. Grundsätzlich sollte bei der Speicherung, einem Format den Vorzug gegeben werden, das entweder gar keine (z.B. TIFF oder PNG) oder verlustfreie (z.B. GIF, PNG oder TIFF) Komprimierung verwendet. Verlustbehaftete Formate, wie etwa JPEG, sollten nur dann verwendet werden, wenn es nicht anders geht (z.B. weil die verwendete Digitalkamera nur dieses Speicherformat bietet) und möglichst bald in ein verlustfreies Format konvertiert werden.

Im Umgang mit Rastergrafiken ist es wichtig, sich bewusst zu machen, wann eine Komprimierung erfolgt und in welchem Grad dies passiert. So führt etwa häufiges Bearbeiten und Abspeichern von JPEGs zum sogenannten Generationsverlust, der mit der Verwendung von TIFF-Dateien vermieden werden kann.

TIFF bietet die Möglichkeit, eine verlustfreie Komprimierung mit LZW anzuwenden. Allerdings ist dieses komprimierte TIFF-Format noch nicht für die Langzeitarchivierung erprobt.

Transparenz Transparente Elemente in Grafiken werden von vielen Vektorgrafikformaten unterstützt. Doch da Transparenzen üblicherweise mit dem

sogenannten Alphakanal gespeichert wird, benötigt man ein Rastergrafikformat, das diesen berücksichtigt, wie z.B. TIFF, PNG oder GIF.

Bei der Konvertierung von einem Format in ein anderes, sollte darauf geachtet werden, ob Transparenzen auch unterstützt werden.

Ebenen Eine weit verbreitete Funktion von Grafikprogrammen ist die Möglichkeit, verschiedene Bildelemente auf verschiedenen Schichten, den sogenannten Ebenen, zu verteilen. Diese Eigenschaft wird von Rastergrafikformaten nicht unterstützt!

Wenn man die Datei als Rastergrafik speichert, werden die Ebenen von oben nach unten verschmolzen. Möchte man aber einzelne Ebenen auch für die Zukunft speichern, kann man in Erwägung ziehen, jede Ebene für sich als eigene Bilddatei zu speichern.

Metadaten Einige Bildformate unterstützen die Speicherung der Metadaten direkt in der Datei. Dazu gehören auch TIFF, DNG und JPEG. Es gibt drei gebräuchliche Metadatenformate bzw. -standards, welche die Informationen jeweils in den Header der Bilddatei schreiben. Der erste für professionelle Arbeitsabläufe gestaltete Standard IIM wurde ab 1995 von Adobe teilweise als Metadaten in Photoshop übernommen, wodurch der IPTC-NAA-Standard festgelegt wurde. Gleichzeitig führte Adobe aber auch den XMP-Standard ein. Ein weiterer Standard ist Exif, der vor allem von Digitalkameras zur Speicherung der Aufnahmefotos verwendet wird.

Etwas problematisch ist, dass jeder Standard die Informationen in den Header der Bilddatei schreibt, weshalb die Gefahr besteht, dass sie sich teilweise überschreiben. Deshalb wird empfohlen, die Metadaten zu extrahieren und in einer gesonderten Textdatei zu speichern. Was für diese gesonderte Datei beachtet werden muss, wird im allgemeinen Abschnitt über Metadaten, 2.2.1, auf Seite 14 erläutert.

Die Informationen im Header sollten nicht komplett gelöscht werden, da im Dateiformat gespeicherte Metadaten das Aufkommen von verwaisten Werken verhindern, die keinerlei Rückschlüsse auf den Urheber zulassen.

Die Problematik der drei unterschiedlichen Standards wurde auch von namhaften Herstellern erkannt, weshalb die Metadata Working Group gegründet wurde, welche die Verwendung von Metadaten in Bilddateien vereinheitlichen will. Es soll aber nicht ein neuer Standard geschaffen werden, sondern die Nutzung der bestehenden Standards durch einen übergreifenden Rahmen geregelt werden.

Anmerkungen zur Qualität Gerade weil Rastergrafiken ein breites Anwendungsspektrum bieten, können hier keine spezifischen Aussagen zur Qualität gemacht werden. Im Prinzip muss also der Ersteller entscheiden, was für die jeweilige Aufgabe angemessen ist. Dabei sollte aber nicht nur auf die aktuellen konkreten Anforderungen, sondern gerade im Hinblick auf die spätere Verwendung (z.B. Publikation) oder Arbeitsschritte (z.B. Konvertierung) auch auf zukünftige Anforderungen geachtet werden.

Eine große Datei ist nicht gleichbedeutend mit guter Qualität. Andererseits sollte auch nicht zugunsten von Speicherplatz auf die Qualität verzichtet werden.

Praxis

In diesem Abschnitt sind Hinweise zum Umgang mit Rastergrafiken gesammelt. Neben einem ausführlichem Abschnitt über Digitalfotografie gibt es kürzere Erläuterungen mit Literatur- und Programmhinweisen über das Rastern von Vektorgrafiken, die Konvertierung und Überprüfung von Dateiformaten, das Ergänzen und Extrahieren von Metadaten, die Stapelverarbeitung und Digitalisate.

Außerdem werden auch einige Angaben über Anforderungen an die benötigte Hardware gemacht.

Digitalfotografie Die digitale Fotografie hat bis auf wenige Ausnahmen und spezielle Anwendungen die analoge Fotografie weitgehend abgelöst. Um aber auch hier mit der digitalen Fotografie einen möglichst hohen Standard in Bildqualität und für die Archivierung zu gewährleisten, so wie er aus der analogen Fotografie bekannt ist und sich bewährt hat, bleibt es unerlässlich, Mindestanforderungen an Hard- und Software zu stellen und diese auch einzuhalten.

In diesem Falle ist unter Hardware die Kameraausrüstung und Speichermedium zu verstehen und unter Software die Programme, mit der die Fotos nach der Aufnahme kameraintern bzw. extern zum Bearbeiten bzw. Speichern und zur Langzeitarchivierung aufbereitet werden.

Während der Aufnahme speichert die Kamera Metadaten im standardisierten Exif-Format undbettet sie in die Bilddatei ein. Diese enthalten u.a. Datum, Uhrzeit, aufnahmespezifische Parameter wie Blende, Verschlusszeit, Brennweite, laufende Nummerierung und evtl. auch GPS-Koordinaten. Um korrekte Exif-Daten zu speichern, müssen Datum und Uhrzeit kameraseitig richtig eingestellt werden.

Je nach Kameramodell und Einstellung können die Bilddaten als unkomprimierte Rohdaten (RAW), bereits interpoliert als unkomprimiertes TIFF oder komprimiert als JPEG auf der Speicherkarte abgelegt werden. Verschiedene Kameramodelle lassen sich so einstellen, dass auf der Speicherkarte gleichzeitig ein RAW und JPEG bzw. TIFF und JPEG abgelegt werden. Diese Methode belegt allerdings sehr viel mehr an Speicherplatz. Einige wenige Kameramodelle gestatten auch das Speichern der Aufnahmen im unkomprimiertem JPEG-Format.

Die kameraabhängigen Rohdaten sind um 30% kleiner als Tiff-Dateien, da ihnen der Datenzuwachs durch die Interpolation fehlt; diese findet erst beim Öffnen der Bilddatei statt. JPEG-Dateien können in Abhängigkeit vom gewählten Kompressionsfaktor bis auf unter 1/10 der Rohdaten-Dateigröße bei entsprechendem Qualitätsverlust komprimiert werden.

Bei der Neubeschaffung einer Kamera ist zu bedenken, dass die Bildqualität einer digitalen Kamera nicht nur von der Auflösung, also der Pixelzahl, abhängig ist. Weitere wichtige Aspekte sind Objektivqualität, Sensorgröße, Rauschverhalten, Dynamikbereich, Farbdarstellung etc. Weiterhin sind auch die Handhabung und die Kompaktheit der Kamera wichtige Auswahlkriterien. Die Kamera sollte die Aufnahmen idealerweise als RAW, DNG oder TIFF speichern.

Sollte nur eine Kamera zur Verfügung stehen, die nur im JPEG-Format speichern kann, so sollte man mit der höchsten Bildqualität fotografieren. Die Bilder müssen zum nächstmöglichen Zeitpunkt in das TIFF-Format konvertiert werden, um dem Generationsverlust vorzubeugen.

Digitale Kameras gibt es in drei prinzipiellen Grundbauarten:

- Kompaktkamera mit optischem Sucher, seitlich versetzt vom Aufnahmeobjektiv angeordnet und mit Display, je nach Modell schwenkbares Display. Das Objektiv ist fest eingebaut. Kein Eindringen von Staub und Fremdkörpern auf den Sensor.
- Systemkamera mit elektronischem Sucher und Okular, fest eingebautes oder wechselbares Objektiv, rückseitiges Display, fest eingebaut oder schwenkbar. Kann sowohl automatisch, als auch manuell betrieben werden.
- DSLR-Kamera (Digitale Spiegelreflex-Kamera) mit Wechselobjektiven und rückseitigem Display, fest eingebaut oder schwenkbar.

Unabhängig davon, ob es sich um eine digitale Kompakt-, System- oder Spiegelreflexkamera handelt, sind gewisse Ausstattungsmerkmale erforderlich, um geforderte Standards in Bezug auf Bildqualität und Dateiformat einzuhalten. Sowohl die Qualität des Objektives als auch eine evtl. ab Werk eingestellte kamerainterne Datenkompression nehmen direkten Einfluss auf die Bildqualität.

Derzeit gebräuchliche Bildwandlerformate (kurz als Chip bezeichnet) sind:

- Kleiner und bis $\frac{1}{4}$ -Format-Chip für Mini-, Kompakt- und Sucherkameras
- $\frac{1}{2}$ -Format-Chip für DSLR- und Monitor-Sucher-Kameras mit und ohne Wechselobjektiven
- Vollformat-Chip für DSLR Kameras mit Wechselobjektiven
- Großformat-Chips für Mittelformat-Rückteile, Kamera-Scanner etc.

Das Chip-Format und die Anzahl der Pixel beeinflussen direkt die Schärfeleistung, Kontrastwiedergabe und Farbtrennung.

Die „Normal-Brennweite“ des Objektives berechnet sich nach der Diagonale des verwendeten Chips; sie entspricht der Diagonale des Bildwandlers, angegeben in Millimetern. Die Qualität des Objektives beeinflusst ebenfalls direkt die Bildqualität und die effektive Auflösung des Bildwandlers.

In der Regel hat der Bildwandler das Format 3:4, die (theoretische) Auflösung berechnet sich aus der Anzahl der Pixel in Breite \times Höhe (z.B.: 1500×2000 Pixel entsprechen einer Auflösung von 3 Megapixeln und einer unkomprimierten Bilddatengröße von ca. 9 Megapixel).

Die Angabe des rechnerischen Pixelmaßes kann durchaus um mehr als 10% über der effektiv nutzbaren Pixelzahl liegen. Bei Neubeschaffung einer Kamera sollte derzeit eine effektive Auflösung von mindestens 10 Millionen Pixel nicht unterschritten werden.

Weitere Ausstattungsmerkmale, wie USB-Anschluss zur direkten Datenübertragung von Kamera zum Notebook, Macro-Bereich, schwenkbares Display, externer Blitzanschluss, elektrischer Draht- oder Fernauslöser sind zusätzliche Funktionen, können die Arbeit mit der digitalen Kamera erheblich erleichtern.

Rastern aus Vektorgrafiken Tritt der Fall ein, dass Grafiken, die ursprünglich als Vektordatei vorlagen, in eine Rastergrafik konvertiert, also gerasert werden sollen, so muss eine geeignete Bildgröße ausgewählt werden, die den gewünschten Anforderungen genügt. Die originale Vektordatei sollte zu Archivierungszwecken ebenfalls aufbewahrt werden.

Das Rastern kann am besten in dem Programm gemacht werden, in dem die Grafik erstellt wurde. Dazu wählt man entweder die Option *Speichern unter* oder *Export*. Die weiteren Einstellungen werden dann üblicherweise von dem Programm abgefragt.

Stapelverarbeitung Oft tritt der Fall ein, dass eine ganze Reihe von Bildern mit gleichförmigen Abläufen, wie etwa Umbenennen oder Beschneiden, bearbeitet werden muss. Mittels Stapelverarbeitung (auch Batchverarbeitung) kann dies automatisch und zügig gemacht werden.

Für sogenannte Batch-Jobs bieten die verschiedenen Betriebssysteme eigene Skriptsprachen an, wie etwa Microsoft Batch. Speziell für die Bildverarbeitung gibt es aber eigene spezialisierte und bedienfreundliche Programme. Beispielsweise ist in der Creative Suite von Adobe das Programm Bridge enthalten, dessen Funktionsumfang beachtlich ist. Eine gern verwendete kostenlose, aber nicht ganz so umfangreiche Alternative ist IrfanView.

Irfanview:

<http://www.irfanview.de/>

Dateiformate konvertieren und überprüfen Möchte man Bilder von einem Format in ein anderes überführen, so kann man dies am besten mit den üblichen Grafikprogrammen machen. Mittels *Speichern unter* oder der Exportfunktion können die meisten Formate konvertiert werden. Allerdings muss man dabei beachten, dass eingebettete Metadaten aus dem Quellformat auch ins Zielformat überführt werden. Auch die verschiedenen Bildeinstellungen müssen beachtet werden.

Neben den Grafikprogrammen findet man im Internet auch zahlreiche Online-Dienste, die Dateikonvertierungen anbieten. Dabei sollte geprüft werden, ob das Zielformat die gewünschten Anforderungen erfüllt. Ein Beispiel für so einen Online-Dienst ist Zamzar.

Speziell für digitale Fotos im RAW-Format eignet sich der frei verfügbare DNG Converter von Adobe. Weitere DNG Converter werden von Kameraherstellern zur Verfügung gestellt und sind oft speziell für ein bestimmtes Kameramodell gemacht.

Dateiformate können mit speziellen Programmen überprüft werden. Auch wenn das Dateiformat unbekannt ist, kann ein solches Programm helfen. Ein Programm, das speziell für die Langzeitarchivierung geeignete Datenformate überprüft ist JHOVE. Das Programm bildet die Grundlage für JHOVE2, das eine erweiterte Funktionalität aufweisen wird.

Zamzar:

<http://www.zamzar.com/url/>

Adobe DNG Converter:

<http://www.adobe.com/products/photoshop/extend.displayTab2.html#downloads>

JHOVE:

<http://jhove.sourceforge.net/>

JHOVE2:

<https://bitbucket.org/jhove2/main/wiki/Home>

Ergänzen und extrahieren von Metadaten Technische Metadaten von Bildern werden in vielen Fällen schon bei der Erstellung einer Rastergrafik erzeugt und mit im Dateiformat abgespeichert (z.B. digitale Fotografie oder Scan). Weitere Metadaten können auch nachträglich noch hinzugefügt werden. Das kann man beispielsweise für einzelne Bilder in einem Grafikprogramm machen, welches die Funktionalität bietet, wie z.B. Photoshop oder Gimp (für Gimp muss allerdings noch ein Plugin installiert werden). Wenn es um eine sehr große Menge Fotos geht, empfiehlt sich ein eigenes Bildverwaltungsprogramm, wie z.B. Adobe Bridge, FotoWare oder XnView. Eine ausführliche Liste findet man auf Wikipedia.

Für die Archivierung von Bildern ist es empfehlenswert, wenn man die Metadaten extrahiert und in einer eigenen Textdatei oder XML-Struktur unterbringt. Wie so eine separate Datei aufgebaut sein kann wird in Abschnitt 2.2.1 auf Seite 14 erläutert. Metadaten aus Bildern können aus den Bildverwaltungsprogrammen, wie Adobe Bridge oder FotoWare, exportiert werden oder mit eigenen Programmen extrahiert werden. Beispielsweise kann man das Metadata Extraction Tool oder eines der Tools, die auf forensicswiki.org gelistet sind, verwenden. Es gibt auch die Möglichkeit mit dem exifviewer die Metadaten online zu extrahieren.

Werden Bilder und deren Metadaten in einer eigenen Datenbank verwaltet, so muss der Abschnitt über Datenbanken 3.6 auf Seite 72 für die Langzeitarchivierung berücksichtigt werden.

Bildverwaltung mit XnView:

<http://www.xnview.com/>

Liste von Bildverwaltungsprogrammen auf Wikipedia:

<http://de.wikipedia.org/wiki/Bilderverwaltung#Software>

Metadata Extraction Tool:

<http://meta-extractor.sourceforge.net/>

Tools zur Extraktion von Metadaten:

http://www.forensicswiki.org/wiki/Document_Metadata_Extraction#Images

Metadaten online ansehen und extrahieren mit Exifviewer:

<http://www.exifviewer.org/>

Digitalisate Für die Digitalisierung von analogen Vorlagen mittels eines Scanners, gibt es ausführliche Hinweise in den *DFG-Praxisregeln "Digitalisierung"*.

Eine kurze Übersicht aus dem oben angegebenen Dokument ist in der folgenden Tabelle zu finden:

Vorlage	Auflösung	Farbtiefe
Aufsichtsvorlagen (z.B. Fotos) von Farb- und Graustufenabbildungen	min. 300 dpi	Farbe: 24 Bit Grau: 8 Bit
Durchsichtsvorlagen (z.B. Dias) im Kleinbildformat (24 × 36cm)	3000 dpi	Farbe: 48 Bit Grau: 16 Bit

Die Speicherung erfolgt in Form unkomprimierter Baseline TIFF-Dateien.

Die DFG-Praxisregeln beziehen sich teilweise auf die Richtlinien der Federal Agencies Digitization Guidelines Initiative (FADGI), die in englischer Sprache in dem Dokument "*Technical Guidelines for Digitizing Cultural Heritage Materials: Creation of Raster Image Master Files*" zu finden sind.

Bei der Neubeschaffung eines Scanners muss darauf geachtet werden, dass er die Mindestanforderungen für den jeweiligen Digitalisierungszweck erfüllt.

Quellen

Archaeology Data Service, Raster Images: A Guide to Good Practice
http://guides.archaeologydataservice.ac.uk/g2gp/RasterImg_Toc

Significant Properties Testing Report: Raster Images
<http://www.significantproperties.org.uk/rasterimages-testingreport.html>

nestor (2009) Nicht von Dauer: Kleiner Ratgeber für die Bewahrung digitaler Daten in Museen
http://files.d-nb.de/nestor/ratgeber/ratg01_2_de.pdf

DFG-Praxisregeln „Digitalisierung“
http://www.dfg.de/formulare/12_151/12_151_de.pdf

Technical Guidelines for Digitizing Cultural Heritage Materials: Creation of Raster Image Master Files
http://www.digitizationguidelines.gov/guidelines/FADGI_Still_Image-Tech_Guidelines_2010-08-24.pdf

(2006) Metadaten in Fotos:
<http://www.drweb.de/magazin/metadaten-in-fotos/>

Metadata Working Group – Guidelines for Handling Image Metadata:
http://www.metadataworkinggroup.com/pdf/mwg_guidance.pdf

Formatspezifikationen

TIFF:
<http://www.fileformat.info/format/tiff/egff.htm>

DNG:
http://wwwimages.adobe.com/content/dam/Adobe/en/products/photoshop/pdfs/dng_spec_1.4.0.0.pdf

GeoTiff:
<http://www.remotesensing.org/geotiff/spec/geotiffhome.html>

PNG:
<http://www.w3.org/TR/PNG/>

Tools und Programme

Irfanview:
<http://www.irfanview.de/>

Adobe DNG Converter:
<http://www.adobe.com/products/photoshop/extend.displayTab2.html#downloads>

Zamzar:
<http://www.zamzar.com/url/>

JHOVE:

<http://sourceforge.net/projects/jhove/>

JHOVE:

<http://jhove.sourceforge.net/>

JHOVE2:

<https://bitbucket.org/jhove2/main/wiki/Home>

Bildverwaltung mit XnView:

<http://www.xnview.com/>

Liste von Bildverwaltungsprogrammen auf Wikipedia:

<http://de.wikipedia.org/wiki/Bilderverwaltung#Software>

Tools zur Extraktion von Metadaten:

http://www.forensicswiki.org/wiki/Document_Metadata_Extraction#Images

Metadata Extraction Tool:

<http://meta-extractor.sourceforge.net/>

Metadaten online ansehen und extrahieren mit Exifviewer:

<http://www.exifviewer.org/>

3.4 Vektorgrafiken

Vektorgrafiken werden mit grafischen Primitiven, z.B. Linien, beschrieben. Es handelt sich beispielsweise um mit Hilfe von CAD-Programmen erzeugte Pläne. Im Gegensatz zu Rastergrafiken sind Vektorgrafiken ohne Qualitätsverlust beliebig skalierbar.

(z.B. Planzeichnungen) WMF, EPS, CDR oder SVG für Vektorgrafiken. Bei Bilddateien einer Digitalkamera handelt es sich immer um Rastergrafiken.

Da sich AutoCAD in diesem Bereich als Quasistandard entwickelt hat, sind die beiden Formate DWG Version 2000 oder DXF (Release 12 oder 14) zu verwenden.¹ Vorhandene 3D-Daten müssen in jedem Fall mit abgespeichert werden. Auch GIS kann (gerade hinsichtlich IntraSite Analysen benötigt) für Planzeichnungen verwendet werden.

3.5 Tabellen

3.6 Datenbanken

K. Hofmann, F. Schäfer

In der Archäologie spielen Datenbanken eine zentrale Rolle, da in ihnen eine Vielzahl von unterschiedlichen Inhalten in strukturierter Form verwaltet werden können. In der Regel wurden dabei bislang individuelle Lösungen für ähnliche Probleme neu entwickelt, die zwar für die Bedürfnisse der einzelnen Projekte ausreichend sein können, aber zumeist hinsichtlich der Langzeitarchivierung und des Austauschs von Daten zumeist ungenügend sind. Um diese unbefriedigende Situation zu beheben und neue Auswertungen zu ermöglichen, müssen daher bestimmte Standards bei dem Entwurf und der Benutzung von Datenbanken eingehalten werden.

¹Siehe auch die Empfehlungen zum Umgang mit digitalen Baudokumentationen für eine Langzeitarchivierung: <http://www.denkmalpflege-forum.de/Download/Nr30.pdf>

In Abschnitt 7.1 werden theoretische Hintergrundinformationen zu Datenbanken im Allgemeinen und zum Datenbankentwurf gegeben. Soll für ein Projekt eine neue Datenbank eingesetzt werden, ist zunächst zu prüfen, ob bestehende Systeme den Anforderungen gerecht werden (ggf. nach individuellen Anpassungen), ob die Erstellung einzelner Module in Kooperation möglich ist oder ob gar eine vollständig neue Datenbank benötigt wird. In letzterem Fall ist die Hinzuziehung eines Datenbankspezialisten notwendig. In Abschnitt 7.2. werden Grundregeln für den Betrieb eines fertigen Datenbanksystems beschrieben, in Abschnitt 7.3. wird weiterführende Literatur genannt und in Abschnitt 7.4. fasst eine Checkliste die wichtigsten Punkte zusammen.

Übersicht

Datenformate Unverzichtbar ist die Dokumentation der Datenbank; diese muss enthalten:

- Anforderungsanalyse
- Beschreibung der Datenstruktur:
 - Datenbankschema als ERD
 - Datenkatalog in Tabellenform
- Beschreibung der semantischen Ebene (Wertelisten, Thesauri, Definitionen, Begriffe)
- Die Dokumentation ist regelmäßig zu aktualisieren und auf Richtigkeit zu überprüfen

Datenbanksysteme sollten bevorzugt auf AMP basieren, proprietäre, insbes. sog. Desktopdatenbanken sind zu vermeiden. Die Datenbank darf keine sog. BLOB (z.B. Bilder) enthalten. Diese müssen durch Referenzierung auf den physikalischen Speicherort im Verzeichnissystem eingebunden werden.

Neben der Speicherung der Daten im jeweiligen Datenbanksystem muss auch eine von der Software unabhängige Variante der Datenbankinhalte erzeugt werden und auch bei einem vorzeitigen Projektende verfügbar bleiben. Dazu eignen sich stets XML-Datenbankauszüge auf der Basis einer dokumentierten DTD, im Falle von SQL-fähigen Datenbanken auch die zur Erstellung der Datenbank geeigneten SQL-DDL-Statements (wobei auf die Verwendung von SQL-Dialektken möglichst verzichtet werden sollte).

Datenqualität Von Anfang an muss auf eine möglichst vereinheitlichte Eingabe der einzelnen Werte geachtet werden. So muss z. B. die gleiche Schreibweise von Ortsnamen entweder abgesprochen und dokumentiert oder durch einen entsprechenden Datenbankentwurf kontrolliert werden. Ansonsten kann es beim Wiederauffinden von Informationen zu Problemen kommen.

Bei metrischen Eingaben und statistischen Informationen muss die spätere Auswertung im Auge behalten werden, dies betrifft z. B. mögliche Rundungsfehler oder Hinweise auf unscharfe Eingaben.

Da bei leeren Feldern üblicherweise unklar ist, ob ein Feld vergessen, übersehen, nicht verstanden wurde, keine Angabe vorliegt oder erst später bearbeitet

werden soll (Nullstellenproblematik), muss eine Eingabe erfolgen, die diese Unklarheit beseitigt. Dies wäre durch die Eingabe festgelegter Zeichen, die sich von jedem anderen Wert unterscheiden, möglich. Folgende Standardeingaben werden für Textfelder empfohlen:

- Information fehlt grundsätzlich: -
- Information wird später nachgetragen: #
- Aussage derzeit nicht möglich; nicht zu beantworten: ?

Dokumentation Zu einer vollständigen und damit auch im Hinblick auf eine Langzeitarchivierung adäquaten Dokumentation gehören die Beschreibung und Sicherung folgender Komponenten:

- Anforderungsanalyse als Textdokument
- Beschreibung der Datenstruktur, also aller Metadaten - das Datenbankschema in einer Zeichnung/Diagramm (ERD) und der Datenkatalog in Tabellenform
- Die semantische Ebene, also die Wertelisten, Thesauri, Definitionen von Begriffen
- Screenshots (o.ä.) aller Ein- und Ausgabe-Formulare

Die Dokumentation ist regelmäßig zu aktualisieren und auf ihre Richtigkeit bzgl. des laufenden Systems zu überprüfen.

Kurzzeitige Datensicherung Zur Wiederherstellung eines konsistenten Datenbestandes, z. B. nach einem Störfall oder fehlerhaften Löschaktionen, ist es notwendige regelmäßige Backups (je nach Eingabemenge z. B. täglich, wöchentlich, monatlich) vorzunehmen. Grundsätzlich lassen sich nach dem Umfang der Sicherung zwei Verfahren unterscheiden:

- Komplettsicherung: Es werden immer alle Daten gesichert.
- Differenzsicherung: Es werden nur die Änderungen zur vorhergehenden Datensicherung gespeichert.

Die einfachste Form der Sicherung ist, von den Datenbankdateien Kopien anzufertigen und auf unterschiedlichen Medien zu speichern. Eine alternative und weniger speicherintensive Möglichkeit sind so genannte Datenbankdumps, bei denen die Datensätze und/oder die Datenstruktur in XML-Format oder als SQL-Statements exportiert und in einfache Textdateien geschrieben werden.

Langzeitdatensicherung Für die Sicherung von Datenbanken ist sowohl eine vollständige Dokumentation als auch ein Dump / Datenexport aller Datensätze in einem unabhängigen Format notwendig. Dafür eignet sich besonders XML, da damit alle Inhalte in der strukturierten Weise, wie sie auch in einer Datenbank vorliegen, in einem leicht zu öffnenden Textdokument niedergeschrieben werden. Mediendateien (Fotos, Zeichnungen, Filme, etc.), die in einer Datenbank eingebunden sind, können durch XML nicht wiedergegeben werden und müssen

daher auch außerhalb der Datenbank in eigenen Ordnern gespeichert/archiviert werden. In XML-Dateien können lediglich Angaben zu Pfad, Dateinamen, Dateiformat etc. über eine Mediendatei festgehalten werden, so dass ein späteres Neueinlesen von z. B. Fotos möglich ist.

Vertiefung

Ein Datenbanksystem (DBS) ist ein System zur elektronischen Verwaltung großer Datenmengen, damit diese effizient, widerspruchsfrei und dauerhaft gespeichert und in benötigten Teilmengen in unterschiedlichen Darstellungsformen für Benutzer und Anwendungsprogramme bereitgestellt werden können.

Ein DBS besteht aus der Verwaltungssoftware, genannt Datenbankmanagementsystem (DBMS), und der Menge der zu verwaltenden Informationen, der eigentlichen Datenbasis (DB). Die Datenbank enthält zusätzlich zu den eigentlichen Daten noch die Beschreibung der Datenstruktur, so genannte Metadaten, die in einem Datenkatalog und dem Datenbankschema festgehalten werden.

Bei einem DBMS handelt es sich um eine Software (kommerzielle Produkte sind u.a. FileMakerPro, Access und Oracle, OpenSource sind u. a. MySQL und PostGreSQL), die als Kontrollprogramm intern die strukturierte Speicherung der Daten organisiert und alle lesenden und schreibenden Zugriffe auf die Datenbank ausführt. Jedes DBMS folgt einem bestimmten Datenmodell (s.u.), das die grundlegende Organisation der Einzelinformationen festlegt.

Die Aufgaben eines DBMS umfassen u. a. folgende Bereiche: Eingabe und Auffindung von Daten, Bereitstellung von Views/Layouts, d.h. von Ausschnitten aus der Gesamtmenge der Daten, Überprüfung von Integritätsbedingungen, Ausführen von Transaktionen, d.h. die richtige Veränderung von Daten.

Mit der Datenbasis (DB) wird die von Benutzern eingegebene oder automatisch generierte eigentliche Sachinformation bezeichnet. Diese kann in unterschiedlichen Formaten vorliegen und als Texte, Zahlen, Links oder Medien (Fotos, Zeichnungen, Filme, etc.) in eine Datenbank einfließen. Dieser Datenbestand wird von einem DBMS verwaltet, auf Speichermedien abgelegt und kontrolliert (damit z. B. ein Geburtsdatum immer auch einer Person zugeordnet ist).

Die Konzeption, Strukturierung und Organisation einer konkreten Datenbanklösung wird in einem Datenkatalog festgehalten. Dieser enthält die sogenannten Metadaten, also Informationen, die die Struktur (nicht den Inhalt) der Anwendungsdaten beschreiben. Dort werden z. B. Informationen über den Typ verschiedener Felder (Kurztext, Langtext, Zahlen, Datum, Medien, etc.) und die Abhängigkeiten der Felder zueinander definiert. Der wichtigste Teilespekt des Datenkataloges ist das Datenbankschema, das in abstrakter Form die Beziehung und Art der Speicherung von Einzelinformationen festlegt.

Zur formalen Beschreibung aller in der Datenbank enthaltenen Daten und ihrer Beziehungen untereinander verwendet man auf der konzeptionellen Ebene ein Datenmodell. Es ist das Konzept, die theoretische Grundlage, für ein Datenbanksystem und legt fest, auf welche Art und Weise der Ausschnitt aus der realen Welt in der Datenbank-Welt wiedergegeben wird. Vier verschiedene Datenmodelle werden üblicherweise unterschieden: das hierarchische Modell, das Netzwerkmodell, das relationale Modell und das objektorientierte Modell; daneben existieren eine Vielzahl von Misch- und Nebenformen. Das relationale Datenmodell hat sich trotz einiger Kritikpunkte als Standard von Datenban-

kanwendungen etabliert, da sich damit die Realwelt mit recht einfachen und realitätsnahen Strukturen abbilden lässt. In der archäologischen Forschung wird dieses Datenmodell fast ausschließlich eingesetzt.

Relationale Datenbanken und Datenbanksysteme Eine relationale Datenbank ist eine Datenbank, die auf dem relationalen Datenmodell basiert. Vereinfacht kann man sich eine relationale Datenbank als eine Sammlung von Tabellen (Relationen) vorstellen, in welchen jeder Datensatz in einer Zeile (Tupel) einer Tabelle abgespeichert wird. Jede Zeile besteht aus einer Anzahl von Attributen (Eigenschaften), den Spalten der Tabelle. Jedes Attribut hat einen eindeutigen Namen, und wird durch diesen referenziert.

Pro Tabelle werden immer nur gleichartige, reale Objekte (Entitäten) erfasst, z. B. nur Befunde, nur Münzen, nur Datierungen, nur Fotos, nur Bauwerke, etc. Jeder Eintrag in einer relationalen Datenbank muss logisch durch eine Kombination von Tabellenname, Primärschlüssel und Attributname auffindbar sein. Der Aufbau aller Tabellen, die zu einer Datenbank gehören, die Datenbankstruktur, muß in dem Datenkatalog dokumentiert werden.

Als Datenbanksprache bezeichnet man Computersprachen, die für den Einsatz in DBS entwickelt wurden und mit deren Hilfe ein Benutzer oder ein externes Programm mit einer Datenbank kommunizieren kann. Die am weitesten verbreitete Datenbanksprache im Bereich der relationalen Datenbanken ist SQL (structured query language); sie wurde rechnerunabhängig und produktübergreifend definiert.

Praxis

Datenbankentwurf Neben den eigentlichen Sachdaten ist der Datenbankentwurf bzw. das Datenbankschema das wichtigste Element einer Datenbank. Die richtige Strukturierung von Informationen vor dem eigentlichen Einsatz stellt die Voraussetzung für eine langfristige, flexible und sinnvolle Verwendung einer Datenbank dar - vor allem dann, wenn sich im Laufe der Zeit die Anforderungen und Wünsche ändern.

Der Entwurf von Datenbanken erfolgt in folgenden Schritten:

- Anforderungsanalyse und -spezifikation: Beschreibung des zukünftigen Systems in Rücksprache mit den Endanwendern; generelle Anforderungen, Eigenschaften der Informationen, Arbeitsweise und Rechte der Benutzer, Einbindung von „Altbeständen“ (alte Dokumentation, etc.); Analyse der Häufigkeit verschiedener Abfragen
- Konzeptueller Entwurf: Erstellung eines unabhängigen Datenbankschemas z. B. als Entity-Relationship-Modell (s. u.), Zusammensetzen von Einzelsichten der jeweiligen Nutzergruppen zu einem global view.
- Logischer Entwurf: Umsetzung des konzeptuellen Entwurfs auf ein gewähltes DBMS
- Datendefinition: Realisierung des logischen Entwurfs in einem DBMS
- Benutzerrechte: Festlegung, welcher Benutzer, welche Daten in welcher Form sehen, bearbeiten, löschen, exportieren, drucken etc. darf

- Dokumentation: Festhalten des Datenbankentwurfes, der Felddefinitionen, zulässiger Werte und Indices, Layouts/Views etc. und der dahinter stehenden Überlegungen in strukturierter Form

Ein wichtiges Element beim Aufbau einer Datenbank ist das Entity-Relationship-Modell oder -Diagramm (ERM oder ERD). Es ist ein Diagramm mit Erläuterungen, das dazu dient, den gewünschten Ausschnitt der realen Welt formal zu beschreiben. Grundlage der ER-Modelle ist die Abstraktion von Objekten und deren Beziehungen untereinander. Folgende grundlegende Begriffe und deren graphische Wiedergabe in einem ERM werden in diesem Zusammenhang unterschieden:

- Entität (Entity = Datensatz): Objekt der Wirklichkeit, materiell oder abstrakt, z. B. ein Fund „Münze XY“, ein Befund „Pfostenloch 123“ oder eine Abteilung „DAI Rom“.
- Entitätstyp (Entity-Type = Tabelle): Abstraktion gleichartiger Entitäten, z. B. Personen, Funde, Befunde, Adressen. Sie müssen mindestens zwei Attribute besitzen; Symbol: Rechtecke
- Beziehung (Relationship): semantische Beziehung zwischen verschiedenen Datensätzen aus unterschiedlichen Tabellen, z. B. „Münze“ in „Pfostenloch“; Symbol: Verbindungslinie zwischen Rechteck und Raute
- Beziehungstyp (Relationshiptype): Abstraktion gleichartiger Beziehungen, z. B. „gefunden in“; Symbol: Raute
- Kardinalität: mögliche Anzahl der an einer Beziehung beteiligten Entitäten (s. u. Beziehungsarten); Symbol: 1, N oder M über Strich
- Attribut: Eigenschaften eines Entitätstyps oder eines Beziehungstyps, z. B. Geburtsdatum von Personen; Symbol: Ellipse
- Schlüssel: Attribut/e, welche/s zur eindeutigen Identifizierung einer Entität von einem Entitätstypen dient/en. Um die Eindeutigkeit zu gewährleisten, dürfen Primärschlüssel (PS) nicht doppelt vergeben werden und nicht leer sein. Daher werden am besten automatisch generierte, fortlaufende Zahlen verwendet, auf die ein Benutzer i. d. R. auch keinen weiteren Zugriff besitzt. Als Fremdschlüssel (FS) wird/werden ein/mehrere Attribut/e einer Entitätstyps bezeichnet, die sich auf den PS eines Datensatzes in einer anderen Tabelle bezieht; Symbol: Ellipse mit unterstrichener Text

In einem ERM wird zwischen drei Beziehungsarten unterschieden:

- In 1 : 1 - Beziehungen ist jedem Datensatz einer Tabelle A (z. B. Steinfund) nur ein einziger passender Datensatz in Tabelle B (z. B. Bauglied) zugeordnet. Diesen Beziehungstyp verwendet man z. B., um eine Tabelle mit vielen Attributen zu teilen.
- In 1 : N - Beziehungen, die am häufigsten auftreten, können einem Datensatz der Tabelle A (z. B. Befund) mehrere passende Datensätze aus Tabelle B (z. B. Fundobjekt) zugeordnet sein, aber ein Datensatz aus B ist nie mehr als einem Datensatz aus A zugeordnet.

- Bei M : N - Beziehungen können jedem Datensatz aus A (z. B. Befund) mehrere passende Datensätze aus B (z. B. Foto) zugeordnet sein und umgekehrt.

Neben der graphischen Visualisierung mittels eines ERD ist auch die tabellarische Erfassung mit einer Entitätstypen-Tabelle (im Muster: Entitytyp, Attribute, Schlüsselwert) und einer Beziehungstypen-Tabelle (im Muster: Entitätstyp1, ..., Entitätstypen, Attribute) für eine übersichtliche Dokumentation einer Datenbank notwendig.

Bei der Entscheidung, welche Eigenschaften (Attribute) eine Entität beschreiben, gibt es folgende Punkte zu beachten: Grundsätzlich sind die Eigenschaften (Attribute) eines Entitätstypes möglichst klein bzw. atomar zu halten (z. B. statt einem Feld „Maßangaben“ sind verschiedene Felder wie „Höhe“, „Breite“, „Tiefe“, etc. sinnvoller). Dies erleichtert präzise Abfragen und Berechnungen sowie den späteren Austausch der Daten mit anderen Systemen. Eine automatische Zusammenführung von Daten aus mehreren atomaren Felder in ein einziges, umfangreicheres Feld ist immer möglich - der umgekehrte Weg, also eine automatische Aufteilung eines größeren Felds auf viele kleinere , dagegen in der Regel nicht!

Umgekehrt gilt: je mehr Felder existieren, also Details dokumentiert werden sollen, desto länger dauert die Bearbeitung eines Datensatzes. Es muss ein ausgewogenes Verhältnis von Datenvielfalt (Vollständigkeit) - je nach Fragestellung - und Effizienz gefunden werden.

In DBMS gibt es verschiedene Feldtypen, die spezifische Informationen speichern:

- Zahlen (Integer, Real, Float etc.) sind zu verwenden für Schlüssel (s.o.), für Angaben, über die eine statistische Auswertung erfolgen soll oder z. B. für Koordinaten. In manchen Fällen ist zu beachten, dass auch unge nauen Angaben vorliegen können, so dass hier auch Textangaben (z. B. Bei Maßangaben mit 'ca., max., Elle etc.') notwendig sein können.
- Bool'sche Felder, die nur „ja“ oder „nein“ Werte zu lassen, sind aufgrund des Nullstellen-Problems (s.u.) zu vermeiden.
- Textfelder (VarChars) existieren in zwei Arten - Felder mit vorgegebenen, eingeschränkten Werten (s.u. Feldeingabe) und mit freien Eingabetexten (max. 255 Zeichen). Vor allem Textfelder eignen sich zur automatischen Erstellung von Indices (= Liste aller in einem Feld vorhandener Einträge), wodurch die Suche nach bestimmten Werten und die Vereinheitlichung von Feldinhalten (nachträgliche Korrektur) vereinfacht wird.
- Memofelder erlauben einen beliebig langen Freitexteintrag. Sie sollten so wenig wie möglich verwendet werden, da sie dazu verleiten, Informationen unstrukturiert in einem Feld einzutragen und ihr gezieltes Auffinden erschweren. Zudem können sie bei einer späteren Konvertierung einer DB in ein neues System Schwierigkeiten verursachen.
- Medienfeldern/BLOBs dienen zur Speicherung von externen Dateien (Bilder, Filme, Texte etc.), die importiert oder verknüpft werden können. Generell sollten externe Dateien nur verknüpft werden und nicht direkt in einer Datenbank gespeichert werden, um deren Größe überschaubar zu

halten. Ist im Ausnahmefall dennoch das Importieren von Dateien notwendig, sollten diese datenbankoptimiert (z.B. reicht bei Bildern JPG-Dateien, max. 2048x2048 Pixel Ausdehnung, 96 dpi Auflösung, Qualität 8 aus) und schreibgeschützte sein.

Am Ende des Datenbankentwurf muss dieser nach inhaltlichen und formalen Kriterien (z. B. hinsichtlich Konsistenz- und Integritätsbedingungen, Anomalien) überprüft werden. Letzteres sollte von einem Informatiker erfolgen, der dann auch Verbesserungen an dem Datenbankentwurf vornehmen kann.

Datenbankmanagementsysteme (DBMS)

FileMaker Pro ist ein DBMS für Mac und Win, das sich neben Microsoft Access zum Standardprogramm für Datenbanken auf Einzelplatzrechnern entwickelt hat. Der dezentrale Zugriff auf FileMaker-Datenbanken ist mittels der Software FileMaker-Server möglich. Charakteristisch ist seine einfache Benutzbarkeit, die es ermöglicht schnell komplexe Lösungen zu realisieren. Der Export der Datensätze in Standardformate (z. B. csv, xml, xls) ist gewährleistet, der Export der Datenbankstruktur ist mit FileMaker Advanced in den Formaten html oder xml möglich. Ein Schwäche ist, dass SQL bislang nur rudimentär unterstützt wurde, so dass Abfragen nicht befriedigend gespeichert werden konnten.

Microsoft Access ist Bestandteil des Office-Professional-Pakets von Microsoft und läuft nur unter Windows. Alle Daten werden in einer einzelnen Datei des eigenen mdb-Dateiformates abgespeichert; dies schließt sowohl Elemente der Oberfläche als auch die Datenbanktabellen ein. Es ist allerdings möglich, die Tabellendefinitionen und den Datenbestand sowie die Oberfläche in verschiedenen Dateien zu halten (front- bzw. backend). Microsoft Access eignet sich vor allem für kleinere bis mittlere Datenbanken im lokalen Betrieb.

MySQL/PostGreSQL

sind weit verbreitete kostenlose Open-Source-Software und bilden die Grundlage für Datenbanken, die webbasiert über einen Internet-Browser genutzt werden sollen. Da beide Systeme nur „nackte“ DBMS darstellen, müssen für sie erst Layouts/Formulare mit Programmiersprachen (meistens PHP oder Java) erstellt werden, was fundierte Informatikkenntnisse voraussetzt. Insofern sind sie als System für „schnelle Lösungen“ ungeeignet. Als graphisches Administrationstool existieren phpmyadmin bzw. phppgadmin, die einen browserbasierten Zugriff auf die Daten und die Struktur ermöglichen. Neben technischen Details ist der wesentliche Unterschied zwischen PostGreSQL und MySQL, dass PostGreSQL mit der Erweiterung PostGIS in der Lage ist, geographische Daten adäquat zu speichern und zu verarbeiten, was für die Anbindung von GIS entscheidend ist.

Hinweise zur Datenbankbenutzung

Dateneingabe Zentral für den Nutzen einer Datenbank ist, dass die semantische Definition jedes Feldes bekannt ist, d.h. den eingebenden Personen muss bewußt sein, welche Information wo gespeichert werden! Dies kann entweder durch eine externe Dokumentation, durch deskriptive Eingabeformulare (Hilfefunktionen), durch Beispieldatensätze und/oder vorgegebene Begriffe (Wertelisten, Index, Thesauroi) gewährleistet werden. Letztere sollten bereits

im Verlauf des Datenbankentwurfs definiert werden, um eine semantisch saubere Trennung verschiedener Felder zu gewährleisten.

Von Anfang an muss auf eine möglichst vereinheitlichte Eingabe der einzelnen Werte geachtet werden. So muss z. B. die gleiche Schreibweise von Ortsnamen entweder abgesprochen und dokumentiert oder durch einen entsprechenden Datenbankentwurf kontrolliert werden. Ansonsten kann es beim Wiederauffinden von Informationen zu Problemen kommen.

Bei metrischen Eingaben und statistischen Informationen muss die spätere Auswertung im Auge behalten werden, dies betrifft z. B. mögliche Rundungsfehler oder Hinweise auf unscharfe Eingaben.

Um möglichst vollständige Suchergebnisse zu erhalten und eine weitgehend einheitliche Eingabe zu gewährleisten, ist es sinnvoll Felder mit festgelegten Begriffen und Freitextfeldern zu kombinieren. Bei längeren Beschreibungsfeldern ist es sinnvoll eine inhaltliche Strukturierung vorzugeben.

Treten bei der Dateneingabe grundsätzliche Probleme mit den Feldern und Wertebereichen der Felder auf, müssen diese nach Rücksprache mit dem Entwickler ggf. geändert werden, damit z. B. bereits bestehende Einträge auf neue Terminologien angepasst werden.

Da bei leeren Feldern üblicherweise unklar ist, ob ein Feld vergessen, übersehen, nicht verstanden wurde, keine Angabe vorliegt oder erst später bearbeitet werden soll (Nullstellenproblematik), muss eine Eingabe erfolgen, die diese Unklarheit beseitigt. Dies wird durch die Eingabe hier definierter Zeichen, die sich von jedem anderen Wert unterscheiden, festgehalten:

- Information fehlt grundsätzlich: -
- Information wird später nachgetragen: #
- Aussage derzeit nicht eindeutig möglich / zu beantworten: ?

Mehrbenutzerbetrieb Generell ist bei einer Datenbank, die von mehreren Nutzern gleichzeitig genutzt werden soll, eine Server-Client-Lösung zu verwenden, da nur so Probleme, die bei der Zusammenführung von Daten- teilbeständen entstehen können, vermieden werden. Auf diese Weise wird auch gewährleistet, dass alle Mitarbeiter mit dem gleichen, aktuellen Datenbestand arbeiten. Kann eine Server-Client-Architektur nicht realisiert werden, müssen aufwändige Hilfskonstruktionen programmiert werden (z. B. Individuelle Nummernblöcke für Primärschlüssel).

Besonders bei Mehrbenutzersystemen ist die einheitliche Verwendung von Begriffen bei der Dateneingabe zu beachten, da unterschiedliche Benutzer zu verschiedenen Begriffen neigen.

Ferner kann es bei Mehrbenutzersystemen sinnvoll sein, die Eingabe von Informationen in Freitextfeldern zu authentifizieren. Dies kann durch Kürzel erfolgen, die dann wiederum eindeutig sein und dokumentiert werden sollten.

Bei mehreren Benutzern müssen die Zugriffrechte auf einzelne Datensätze (lesen, löschen, bearbeiten, drucken, exportieren) sowie auf Layouts / Views / Formular geregelt werden. Dies kann u. U. ein aufwändiges Datensatzmanagement erforderlich machen, das die Einhaltung der aufgestellten Regeln automatisch überwacht.

Verschiedenes Dient eine Datenbank u. a. als Arbeitsmittel zur strukturierten Erfassung von Daten, die in anderen Programmen weiterverarbeitet werden sollen, ist auf geeignete Exportformate zu achten. Die meisten Datenbankmanagementsysteme unterstützen einfache Formate wie txt, dbf, csv, tab. Die Wahl für ein DBMS kann von dessen Exportmöglichkeiten abhängen! (s. o.) In den meisten Fällen wird eine ODBC-Schnittstelle zur Verfügung stehen, noch wichtiger sind jedoch SQL- und XML-Schnittstellen.

Da archäologische Datenbanken überwiegend statische Daten enthalten, die nach der ersten Eingabe kaum nachträglich verändert werden, sollte das Löschen von Datensätzen durch Sicherheitsabfragen und restriktive Zugriffsrechte abgesichert werden. Alternativ kann auch vor größeren Veränderungen des Datenbestandes ein Datenexport vorgenommen oder eine Sicherungskopie angelegt werden.

Es sei darauf hingewiesen, dass alle Veränderungen an einer Datenbank immer sofort und ohne Interaktion mit dem Benutzer durch ein DBMS gespeichert werden. Dies hat Vorteile (das 'manuelle' Speichern entfällt), aber auch Nachteile (alle Dateneingaben - auch versehentlich falsche - sind sofort gültig, d.h. nicht revidierbar).

Wird eine Datenbank sowohl im Offline-Modus (Standalone auf einem Rechner) als auch über einen Server im Online-Zugriff betrieben, sind geeignete Maßnahmen zur Sicherung der Datenintegrität und zur verlustfreien Datenzusammenführung zu unternehmen. (vgl. oben Mehrbenutzerbetrieb)

Die Mehrsprachigkeit ist in einer Datenbank nur mit relativ hohem Aufwand zu realisieren. Noch am einfachsten und unproblematischsten ist die Beschriftung der Formulare (z. B. Überschriften, Bezeichnungen neben den Eingabefeldern) in verschiedenen Sprachen. Bei Feldern, für die vorgegebene Begriffe vorliegen, ist eine weitgehend automatische Übertragung in eine andere Sprache prinzipiell möglich, sofern Konkordanzlisten vorliegen, technisch aber aufwändig. Die Übersetzung von Freitextfeldern ist momentan nicht möglich; wird dies benötigt ist ein Feld für jede Sprache mehrfach anzulegen und auszufüllen, z. B. „Kurzbeschreibung (de)“ und „Kurzbeschreibung (eng)“

Punkte zur Erstellung und zum Einsatz einer Datenbank

- Anforderungen einer Datenbank im Vorhinein möglichst umfassend mit allen Beteiligten klären: was wird alles gewollt? Wer soll das System in welcher Weise nutzen? Diese Analyse schriftlich festhalten
- Informieren, ob Systeme mit ähnlicher inhaltlicher und technischer Ausrichtung bereits anderswo im Einsatz sind; Möglichkeiten der Übernahme bzw. Adaption bestehender Datenbanken ausloten
- Falls eigener, neue Datenbankentwurf erforderlich: Definieren von Entitätstypen und ihren Relationen; konzeptuelles Schema der Datenbank mit Hilfe eines Entity Relationship Modell erstellen
- Festlegen, welche Felder welchem Entitätstypen zugeordnet werden; prinzipiell eher mehr Felder mit kleinteiligeren Informationen bereitstellen, als wenige große Freitext-Felder
- festlegen, in welchen Feldern vorgegebene Wertelisten/ Indices notwendig/ sinnvoll/ möglich sind und wo nicht

- den Datenbankentwurf vor Übertragung in ein gewähltes DBMS von einem Fachmann hinsichtlich Vollständigkeit, Redundanzen, Korrektheit, Anomalien, etc. überprüfen lassen
- Bei Wahl eines DBMS auf offene Schnittstellen achten (ein Export der Datensätze in XML-Format muss möglich sein)
- Bei größeren Projekten mit verteilten Mitarbeitern sich rechtzeitig (d. h. vor dem eigentlichen Einsatz) nach Möglichkeiten eines Server-Client-Betriebes erkundigen; potentielle Anforderungen an Hardware, Software und Infrastruktur (z. B. Netzzugriff) klären
- Vollständige Dokumentation der Datenbank bzw. des Datenbankentwurfs anlegen
- festlegen, welche Nutzergruppe welche Felder in welcher Weise sehen und verändern darf; wie sollen danach die Layouts (views) gestaltet sein; hierbei auf Einheitlichkeit und Übersichtlichkeit achten
- vor Beginn der Eingabe verbindliche Begriffe und Termini definieren und dokumentieren; nach ersten Erfahrungen regelmäßig wiederholen; Klärung, wie mit mit der Nullstellen-Problematik umgegangen werden soll
- Zwischen den Eingebenden Begrifflichkeiten und Verständnisse von Feldinhalten absprechen, damit alle das Gleiche bei der Dateneingabe und -abfrage meinen und gleiche Daten in gleiche Felder eintragen;
- Ausreichend Zeit, Geld und Personal für den laufenden Betrieb (Kontrolle und Vereinheitlichung der Eingabe, Aktualisierung der Dokumentation, Fehlerbehebung, etc.) einplanen
- Workflow für die kurzfristige Datensicherung und die langfristige Archivierung festlegen

Quellen

- H. Eiteljorg, Archaeological Computing ²(Bryn Mawr 2008)
(insbes. Kap. III ; download: <http://archcomp.csanet.org/>)
- P. Kandzia - H. J. Klein, Theoretische Grundlagen relationaler Datenbanksysteme. Reihe Informatik 79 (1993).
- R. Elmasri - S. B. Navathe. Fundamentals of Database Systems ⁴(2004).
- A. Kemper - A. Eickler, Datenbanksysteme. Eine Einführung ⁷(2009).
- R. Steiner, Grundkurs relationale Datenbanken. Einführung in die Praxis für Ausbildung, Studium und IT-Beruf ⁷(Wiesbaden 2009).
- A. G. Taylor, Datenbanken für Dummies (Bonn 2001)
- P. Kleinschmidt - Chr. Rank, Relationale Datenbanksysteme. Eine praktische Einführung ³(Berlin 2005).
- G. Lock, Using Computers in Archaeology (London 2003) 85-98.
- D. Smith, Database fundamentals for archaeologists, in: S. Ross et alii (hrsg.), Computing for Archaeologists (Oxford 1991) 111-125.

3.7 GIS

K. Rassman

Für die Langzeitarchivierung von GIS-Daten ist derzeit noch kein allgemeingültiger Standard etabliert, weswegen auf die Vorgaben zu den in das GIS importierten Daten (z.B. Luftbilder, Geländemodell etc.) verwiesen wird. Es sollen jedoch möglichst keine programminternen Formate, die nicht von anderen GIS Systemen importiert werden können, genutzt werden. Bevorzugt werden sollen:

- Vektordaten als Esri Shapefile (shp + shx + dbf)
- Rasterdaten als GeoTiff

Die Haltung von Geodaten sollte vorzugsweise in Geodatenbanken erfolgen. Falls dies nicht möglich ist, müssen die Metadaten ausgefüllt werden. Folgende Informationen sind in der Geodatenbank / den Metadaten bereitzustellen:

- Datenquelle (z.B. SRTM, Tachymeter)
- Verarbeitung: Programm, Algorithmus, Parameter (z.B. QGIS , r.shaded.relief, altitude, azimuth etc.)
- Projektion (WGS 1984, EPSG: 4326)
- Datenqualität (Auflösung 90m, Ungenauigkeit)
- Information, was mit den Layern ausgedrückt wird, da es nicht immer aus dem Dateinamen hervorgeht (z.B. Höhenmodell)

Vertiefung

GIS in der Archäologie Geographische Informationssysteme (GIS) dienen der Aufnahme, Verwaltung, Darstellung und Auswertung raumbezogener (Sach- und Geometrie-) Daten. In der Regel beschreibt der Terminus GIS die Gesamtheit eines GIS-Projektes, d.h. ein Gesamtsystem, das alle für die digitale, raumbezogene Arbeit erforderlichen Werkzeuge (Hardware, Software) und Daten (archäologische Basisdaten, geographisch - naturräumliche Daten) umfasst. Seltener beschränkt sich der Terminus GIS lediglich auf die Software mit der Aufnahme, Verwaltung, Darstellung und Auswertung raumbezogener Daten.

Den Datenbestand eines GIS könnte im Kern bereits eine digitale Liste mit Keramikfunden einer Ausgrabung bilden, unverzichtbar sind dabei Informationen zur Lage der Funde. Daraus lassen sich mit Hilfe von GIS-Software Karten erstellen, die verschiedene Informationen zu den Keramikfunden wiedergeben (Verbreitung der Verzierungsmotive, Typen, Menge der Scherben usw.). Viele Nutzer beschränken sich beim Gebrauch eines GIS auf die computergestützte Kartographie. Der entscheidende Vorteil eines GIS besteht aber in den darüber hinausgehenden vielfältigen Möglichkeiten der Datenanalyse. Derartige Analysen setzen in der Regel Berechnungen zum Raumbezug voraus, wie die Abstände zwischen den Funden, die Größe der ausgegrabenen Flächen oder der entsprechenden Ausgrabungsbefunde. Solche Daten lassen sich mit geringem Aufwand mit Hilfe eines GIS automatisch erheben und in Bezug zueinander setzen. Damit eröffnen sich neue Wege, die Verteilungen des Fundmaterials mit statistischen Methoden zu vergleichen, häufig werden hier Funddichteberechnungen durchgeführt, wie die Verteilung von Scherbenanzahl oder -gewicht.

Maßstabsebenen Die Aufnahme, Verwaltung, Darstellung und Analyse raumbezogener Daten mit einem GIS ist auf verschiedenen Maßstabsebenen archäologischer Arbeit sinnvoll. In diesem kurzen Ratgeber wird vor allem der Einsatz innerhalb einer Ausgrabung thematisiert. GIS-Anwendungen sind jedoch auch für die Auswertung größerer Landschaftsausschnitte attraktiv. Der Fundplatz, den man ausgräbt, ist eingebettet in eine Umgebung, die archäologisch teils durch frühere Arbeiten bekannt ist, teils durch eigene Oberflächenbefahrungen weiter untersucht wird. Dies ist das Niveau von „Siedlungskammer“ oder „Schlüsselgebiet“. Die naturräumlich - geographischen Daten stehen auf diesem Niveau meist im Maßstab 1:25.000 oder 1:50.000 zur Verfügung. Die Größe solcher Mikro-Regionen beträgt typischerweise zwischen wenigen $10km^2$ und wenigen $100km^2$. Auf dieser Maßstabsebene ist es möglich, alle Nachbarplätze inklusive Fundstoff selbst zu überschauen und man kann Vollständigkeit anstreben.

Auf der nächst höheren Maßstabsebene, der der Regionalstudien, bewegt man sich in einer Größenordnung von wenigen $1.000km^2$. Wenn man die archäologischen Daten einer solchen Region selbst erfassen will, muss mit einem Arbeitsaufwand in der Größenordnung eines Dissertationsprojektes gerechnet werden. Bei Maßstäben ab 1:500.000 und einigen $10.000km^2$ oder gar größer muss man sich auf die Richtigkeit von Angaben aus der Literatur verlassen und es ist unmöglich, die Vollständigkeit des archäologischen Datensatzes zu gewährleisten. Trotzdem ist auch die Betrachtung dieser Maßstabsebenen notwendig, denn Fragen zu kulturellen Diffusionsprozessen, zu Migrationen, zu Tausch und Handel, zur Mensch-Umwelt-Beziehung und auch zur Lage des selbst ausgegrabenen Fundplatzes in Bezug zu kulturellen Zentren sowie peripheren Regionen usw. sind nicht in Maßstabsebenen zu beantworten, die nur die Darstellung von wenigen $100km^2$ erlauben. GIS-Anwendungen erlauben theoretisch einen gleitenden Übergang von einer Skalenebene zur anderen. Die archäologischen Konsequenzen der eben beschriebenen, scheinbar trivialen Zusammenhänge steht in der Archäologie erst ganz am Anfang. Lösungen sind nur vom Einsatz derjenigen Rechenverfahren zu erwarten, die GIS-Programme mit anbieten und für die sich Archäologen bisher nur am Rande interessiert haben. Da man sich nicht darauf verlassen kann, dass auf einer Karte, die ein Gebiet von mehreren $10.000km^2$ Größe darstellt, alle archäologischen Fundpunkte vorhanden sind, muss man an dieser Stelle eben von der Punkt- zur Schraffurdarstellung übergehen. Allerdings sollte der schraffierte Bereich, in dem die meisten Fundpunkte liegen, nach nachvollziehbaren Kriterien bestimmt sein. Es liegen bereits Vorschläge vor, welche Methoden man zu diesem Zweck verwenden sollte.

Aber natürlich gewinnt auch der Einsatz von GIS auf Ausgrabungen eine zunehmende Bedeutung. Umso mehr, da mit höherer Komplexität der erhobenen Daten (Funde, Architekturbefunde, naturwissenschaftliche Daten) die Schwierigkeit wächst, diese Informationseinheiten in ihrer Gesamtheit zu erfassen und die vielfältigen Beziehungen zwischen ihnen auswerten zu können.

Datenmodell eines GIS Man unterscheidet allgemein zwischen Sach- und Geometriedaten. Um beim Beispiel der Liste der Keramikfunde zu bleiben, handelt es sich bei diesen Informationen um Sachdaten. Aus Geometriedaten besteht der ins GIS eingebundene digitalisierte Grabungsplan. Er könnte beliebig viele geometrische Objekte enthalten, wie die Flächen von Häusern oder

Pfostenlöcher.

Den Kern des GIS bilden die Sachdaten, die in unterschiedlich komplexen Datenbanken organisiert werden. Diese Sachdaten sind in Abhängigkeit von der archäologischen Fragestellung zu strukturieren. Unverzichtbar sind Informationen zur Lage der Funde. Das sind zumeist x,y-Koordinaten und Tiefenangaben, häufig aber auch Angaben des entsprechenden Quadranten mit der horizontalen Auflösung von 1x1m bei Nennung des jeweiligen Planums.

Geometriedaten stehen in zwei verschiedenen Klassen zur Verfügung. Man unterscheidet zwischen Vektor- und Rasterdaten.

Vektordaten ermöglichen eine exakte Abbildung räumlicher Objekte, z. B. der Grenze einer Hausgrube oder einen Flusslauf. Jedes Objekt besteht dabei aus einer variablen Menge von Koordinatenpaaren, die gewissermaßen Knotenpunkte in diesem System darstellen. Die Knotenpunkte können zu beliebigen Strukturen kombiniert werden. Auf diese Weise lassen sich Punkte, Linienzüge oder Flächen abbilden. Die Kombination der Knotenpunkte zu Flächen oder zu Linien ergibt sich aus Zusatzinformationen. Ein Pfostenloch kann in einem Grabungsplan als Objekt dargestellt werden, das aus fünf oder mehr Knotenpunkten besteht. Die Zusatzinformationen beschreiben die Zusammengehörigkeit der Knotenpunkte und die Eigenschaft des Objektes als Fläche. Die Geometriedaten werden im GIS dann mit Sachdaten verknüpft. Für das Objekt Pfostenloch könnten dies Daten zur Höhe bzw. Tiefe der Unterkante des Pfostenloches sein oder Informationen zu dem hier vorgefundenen Keramikmaterial.

Rasterdaten bestehen aus nur einem geometrischen Grundelement - der Rasterzelle. Die in der Regel quadratischen Rasterzellen werden in Zeilen und Spalten angeordnet. Die Zellgröße bestimmt die Auflösung der so entstehenden Karte. Jeder Zelle wird dann ein Attributwert zugewiesen. Das häufigste Anwendungsbeispiel für eine Rasterdatei ist ein Digitales Geländemodell (DGM), in der jede Zelle die Information des Höhenwertes enthält. Am bekanntesten dürfte das weltweit kostenlos zur Verfügung stehende SRTM-Höhenmodell (Shuttle Radar Topography Mission) aus dem Jahr 2000 mit einer Rastergröße von ca. 90x90m sein. In einer Rasterdatei lässt sich auch die Verteilung der Scherbenanzahl oder des Scherbengewichts in einer Grabungsfläche mit Rasterzellen von 1x1m Quadraten veranschaulichen.

In einem GIS-Projekt lassen sich je nach Fragestellung Raster- und Vektordaten integrieren. Für die Umwandlung von Rasterdaten in Vektordaten oder umgekehrt stehen dabei in den meisten GIS Standardwerkzeuge zur Verfügung. Dabei gilt es zu bedenken, dass Rasterdateien in der Regel größer sind als Vektordateien vergleichbarer Auflösung, sie bieten aber beim Verschneiden mit Hilfe von Basisrechenverfahren einige Vorteile.

Praxis

Die Software eines GIS setzt sich aus zwei Hauptbestandteilen zusammen. Erster Bestandteil ist ein Datenbankprogramm für die Verwaltung der Sachdaten. Häufig wird für diese Arbeit auf spezielle Datenbanksoftware zurückgegriffen (MS Access, FileMaker, MySQL). Den zweiten Teil bilden spezielle GIS-Programme wie ArcView, Manifold, MapInfo, QuantumGIS, SAGA, gvSIG oder GRASS. Derartige Programme ermöglichen es, die Daten in ihrem räumlichen Bezug zu analysieren und deren Strukturen zu visualisieren. Die graphische Funktionalität der GIS-Programme, eröffnet für die Erstellung thematischer Karten vielfältige

Möglichkeiten. Der große Vorteil von GIS-Programmen sind deren Werkzeuge zur Analyse raumbezogener Daten. Durch die Möglichkeiten der Visualisierung, der Herstellung von Karten, lassen sich viele Fragen auf eine empirische Weise verfolgen. Es ist es jedoch unverzichtbar, dass der Visualisierung eine Analyse folgt, mit der geprüft wird, inwieweit die herausgearbeiteten Unterschiede oder Gemeinsamkeiten bedeutsam sind. Die analytischen Werkzeuge ermöglichen einfache Abfragen, die Berechnung von Vektor- und Rasterflächen bis zu komplexen statistischen Operationen. Spezielle GIS-Programme enthalten daneben auch Bausteine, mit denen Datenbanken erstellt und verwaltet werden können. Meist wird man aber auf spezielle Datenbanksoftware zurückgreifen.

In der Praxis werden häufig Grabungszeichnungen in AutoCAD erzeugt und dann als DXF-Datei in das GIS importiert und mit den vorhandenen Sachdaten zusammengefügt. Ein weiteres klassisches Anwendungsbeispiel für ein vektorbasiertes GIS ist ein digitales Landschaftsmodell, in dem Straßen, Waldflächen, überbaute Flächen u.a. enthalten sind. Der Vorteil liegt darin, dass jedem dieser Objekte Zusatzinformationen zugewiesen werden können (Breite einer Straße, Belag, Steigung usw.).

Besondere Aufmerksamkeit ist bei der Planung von GIS-Vorhaben dem Einsatz der entsprechenden Software zu widmen. In den zurückliegenden Jahren sind leistungsfähige OpenSource-Programme entwickelt worden, die nahezu alle Anwendungsgebiete abdecken. Dabei ist zu bedenken, dass die hohen Kosten kommerzieller GIS-Software ihrem Einsatz bislang Grenzen gesetzt haben. An Universitäten stehen die Programme häufig nur in den PC-Pools der Rechenzentren oder aber auf einigen Rechner zur Verfügung. Für weit vernetzte, internationale Forschungsvorhaben ist dieser Umstand von erheblichen Nachteil.

Eine besondere Empfehlung unter den neu aufkommenden leistungsfähigen OpenSource-Programme verdient die spanische GIS-Software gvSIG, die plattformübergreifend auf Windows-, Linux- und Mac-Betriebssystemen eingesetzt werden kann.

Die eingesparten Kosten lassen sich zukünftig effektiver durch die gezielte Anpassung der Software an die spezifischen Projektanforderungen einsetzen oder aber für Schulungen.

Ausgrabungen und GIS Die ersten Anwendungen zur Digitalisierung von Grabungsdaten basierten auf der Konstruktionssoftware AutoCAD. Diese Versuche reichen bis in die frühen 90er Jahre zurück.

Die Vorzüge dieser Werkzeuge kamen bei der Herstellung und Vorlage digitaler Planzeichnungen zum Tragen. Nachteilig ist die umständliche Einbindung von Datenbanken und das weitgehende Fehlen von Werkzeugen für die Analyse von Raumstrukturen.

Die Vorzüge eines GIS bei der Durchführung und Auswertung einer Ausgrabung liegen auf der Hand. Nahezu alle auf einer Ausgrabung gewonnenen Informationen haben einen Raumbezug. Viele der Sachdaten sind in Datenbanken zu verwalten, wie Funddaten, Vermessungsdaten, Schichtbeschreibungen usw. Die Form, Ausdehnung und Lage der Befunde und Architekturreste lassen sich durch geometrische Daten eines GIS abbilden. Die reine graphische Dokumentation ist auch mit einer Software wie AutoCAD möglich, nur bieten derartige Programme standardmäßig keine Werkzeuge, mit denen sich bspw. Flächengrößen und Mittelpunkte von Flächenobjekten berechnen lassen. Das GIS er-

öffnet darüber hinaus die Möglichkeit Verteilungen zu vergleichen, Flächen zu verschneiden etc. Bliebe man bei der digitalen Umsetzung der konventionellen Grabungspläne, wäre ein Programm wie AutoCAD ausreichend. Folgerichtig wird AutoCAD bei Ausgrabungen da eingesetzt, wo das besondere Augenmerk auf der Dokumentation liegt. Bewährt haben sich speziell für AutoCAD entwickelte Werkzeuge, wie das Programm TachyCAD von der Firma Kubit oder das Programm ArchäoCAD der Firma ArcTron. Mit diesen Lösungen lassen sich mittels einer Totalstation auf Ausgrabungen Befunde einmessen. Computer und Totalstation sind auf der Grabung miteinander verbunden. Die Daten werden direkt ins AutoCAD eingelesen. Später lassen sich die Daten problemlos in ein GIS exportieren. Das gängige Austauschformat ist DXF/DWG.

Ein weiteres AutoCAD-Werkzeug der Firma Kubit ist Photoplan, mit dem sich Grabungsbefunde photogrammetrisch dokumentieren lassen. Diese Arbeitsschritte ließen sich auch mit einer GIS-Lösung ohne AutoCAD realisieren. Nach unseren Erfahrungen sind diese Programmbestandteile jedoch nicht so anwendergerecht. In der Regel wird man bei der Wahl der Software nicht allein das nach den theoretischen Leistungsparametern beste Programm wählen, sondern diejenigen Programme bevorzugen, für die ein guter Ausbildungsstand vorhanden ist und kompetente Ansprechpartner für die Diskussion von Problemen zur Verfügung stehen. Zudem hat sich herausgestellt, dass keines der angebotenen GIS-Programme alle benötigten Rechenverfahren gleich oder in gleicher Anwendergerechtigkeit zur Verfügung stellt. Häufig ist es daher - je nach Fragestellung - sinnvoll oder unumgänglich, dass verschiedene GIS-Programme zum Einsatz kommen.

Den Vorzug sollten zukünftig mehr und mehr OpenSource-Lösungen erhalten.

Quellen

- Bill, R. , Grundlagen der Geo-Informationssysteme (Heidelberg 1999).
Blankholm, H. P., Intrasite Spatial Analysis in Theory and Practice (Aarhus 1991).
Burrough, P. A. / R. A. McDonnel, Principles of Geographical Information Systems (Oxford 1999).
J. Conolly/M. Lake, Geographical Information Systems in Archaeology. Cambridge Manuals in Archaeology (Cambridge 2006).
Gaffney, V. / Z. Stancic GIS approaches to regional analysis: A case study of the island of Hvar (Ljubljana 1991).
Hietala, H. J. , Intrasite spatial analysis: a brief overview (Cambridge1984).
Hodder, I. / C. Orton (1976). Spatial Analysis in Archaeology. Cambridge, Cambridge University Press.
Kunow, J. / J. Müller Archäoprognose Brandenburg 1. Symposium Landschaftsarchäologie und geographische Informationssysteme.
Prognosekarten, Besiedlungsdynamik und prähistorische Raumordnung (Wünsdorf 2003).
G. Lock/B. Leigh Molyneaux (Hrsg.), Confronting scale in archaeology (Berlin 2006).
Neteler, M., GRASS-Handbuch, Der praktische Leitfaden zum Geographischen Informationssystem GRASS. Hannover, Abteilung Physische Geographie und

Landschaftsökologie am Geographischen Institut der Universität Hannover (Hannover 2000).

C. Orton, Sampling in Archaeology (Cambridge 2000).

Schier, W. (1992). Zum Einsatz multivariater Verfahren bei der Analyse des Lage- und Umweltbezugs prähistorischer Siedlungen. Archaeologische Information 15/1&2: 117-122.

Wheatley, D. and M. Gillings. Spatial Technology and Archaeology. The archaeological applications of GIS. (London / New York 2002).

Zimmermann, A., J. Richter, et al., Landschaftsarchäologie II - Überlegungen zu Prinzipien einer Landschaftsarchäologie. Bericht der Römisch-Germanischen Kommission 2004, 85: 37-95.

Preserving Geospatial Data:

http://www.dpconline.org/component/docman/doc_download/363-preserving-geospatial-data-by-guy-mcgarva-steve-morris-and-greg-janee
;
<http://eur-lex.europa.eu/LexUriServ/LexUriServ.do?uri=OJ:L:2007:108:0001:0014:DE:PDF>
;
<http://www.gdi-de.org/>

Weiteres:

<http://www-sul.stanford.edu/depts/gis/Archaeology.htm>

Weiteres:

<http://oadigital.net/software/gvsigoade>

Weiteres:

http://www.fuerstensitze.de/1140_Publikationen.html

3.8 Statistische Daten

3.9 Bewegte Bilder, Videos

Videoaufnahmen müssen in den Formaten MPEG-1 und MPEG-2, mit einem der Profile: Simple, Main, oder 4:2:2 gespeichert werden. Für die langfristige Verwertbarkeit von Videosequenzen, bei denen die Fähigkeit zum präzisen Schnitt langfristig erhalten bleiben sollte, ist Motion JPEG zu verwenden.

Qualitätsempfehlungen können auf Grund der relativ geringen vorliegenden Erfahrungen noch nicht ausgesprochen werden.

3.10 Audio

Waveform Audio File Format (WAVE) mit linearem, unkomprimiertem PCM Bitstream oder Audio Interchange File Format (AIFF) mit linearem PCM Bitstream.

Qualitätsempfehlungen können auf Grund der relativ geringen vorliegenden Erfahrungen noch nicht ausgesprochen werden.

3.11 3D und Virtual Reality

M. Trognitz

Im Gegensatz zu statischen zweidimensionalen Bildern können dreidimensionale Repräsentationen von Objekten aus jeder Richtung betrachtet, skaliert und rotiert werden. Ein Punkt in einem 3D-Modell wird von seiner Lage auf der x-, der y- und der z-Achse eines kartesischen Koordinatensystems beschrieben, wobei die z-Achse in diesem Zusammenhang üblicherweise die Tiefe, seltener die Höhe, angibt.

Virtual Reality (Virtuelle Realität) bezeichnet digitale dreidimensionale Welten, mit welchen in Echtzeit interagiert werden kann.

3D-Inhalte können auf unterschiedliche Weise entstehen: durch manuelle Modellierung, wie Rekonstruktionen von Gebäuden, durch automatisierte Aufnahme, wie etwa einem 3D-Scan von Objekten, oder durch automatisierte Erstellung mittels eines Programms, wie etwa Photogrammetrie. Von der Entstehungsweise hängen weitere Angaben für die Dokumentation ab, die über die hier angegebenen hinausgehen. Die zusätzlichen Angaben sind in den jeweiligen Abschnitten in dem Kapitel Forschungsmethoden ab Seite 102 zu finden, wobei vor allem die Abschnitte Bauforschung, Geodäsie, Geodatenanalyse und Materialaufnahme von Interesse sind.

Langzeitformate 3D-Inhalte sollten in einem offen dokumentierten, textbasierten Format (ASCII) gespeichert werden. Dies ermöglicht bei Bedarf die Rückentwicklung unabhängig von einem bestimmten Programm.

Das zu verwendende Format hängt von der Entstehungsweise und dem Zweck des 3D-Inhaltes ab, da unterschiedliche Formate unterschiedliche Eigenschaften und Elemente speichern, wie beispielsweise Geometrie, Texturen, Lichtquellen oder Standpunkt und Bildausschnitt (auch Viewport genannt). Eine Übersicht über die Speichereigenschaften von den hier empfohlenen 3D-Formaten wird in Tabelle 3.1 auf Seite 97 gegeben.

Das vom Web3D Consortium entwickelte X3D-Format eignet sich sowohl zur Speicherung von einzelnen 3D-Modellen, als auch komplexer 3D-Inhalte, wie etwa Virtual Reality. Es ist das Nachfolgeformat vom VRML-Format und sollte diesem daher vorgezogen werden.

Ein weiteres für komplexe 3D-Inhalte geeignetes Format ist COLLADA (DAE), das von der Khronos Group entwickelt wurde.

Das U3D-Format bietet einen ähnlichen Funktionsumfang wie X3D und COLLADA und ist insbesondere für 3D-Inhalte von PDF-Dokumenten gedacht.

Die Formate OBJ, PLY und STL eignen sich nicht für komplexe Szenen mit Lichtquellen oder gar Animationen, bieten aber alle Eigenschaften, um die visuellen Oberflächeneigenschaften eines 3D-Objektes zu speichern.

Aus dem CAD-Bereich stammt das Format DXF, welches neben 2D-Inhalten auch 3D-Inhalte speichern kann. Dieses Format sollte nur verwendet werden, wenn die 3D-Inhalte mit CAD-Software erstellt wurden. In der Industrie werden als alternative Formate auch IGES und STEP verwendet.

Nicht für die Langzeitarchivierung geeignet sind programmsspezifische oder binäre Formate, wie beispielsweise 3DS, MAX, SKP oder BLEND.

Um zukünftigen Nutzern einen schnellen Überblick über die 3D-Inhalte zu bieten, ist die zusätzliche Speicherung von Bild- oder Videodateien, die einen ersten Eindruck des Modells vermitteln, zu empfehlen.

Hinweis: Bei der Konvertierung von einem 3D-Format in ein anderes können bestimmte Informationen verloren gehen, wenn sie von dem Zielformat nicht un-

terstützt werden. Zusätzlich zu dem gewählten Archivierungsformat sollten die originalen Quelldateien, verwendete Texturdateien, Visualisierungen und ähnliches aufgehoben werden. In den entsprechenden Abschnitten in dem Kapitel Forschungsmethoden ab Seite 102 sind nähere Details zu finden.

Die Abkürzungen in der folgenden Tabelle geben die unterstützten Eigenschaften der 3D-Formate an: DG=Drahtgittermodell, P=Parametrisch, F=Farbe, X=Textur mittels Bild, B=Bumpmapping, M= Material, V= Viewport und Kamera, L= Lichtquellen, T= Transformationen, G=Gruppierung. Diese Begriffe werden in dem Abschnitt Vertiefung ab Seite 93 erläutert.

Format	Begründung
X3D ✓	Das X3D-Format (extensible 3D Graphics) wurde vom Web3D Consortium entwickelt und ist seit 2006 ISO-zertifiziert. Es darf nicht mit dem proprietären Format 3DXML verwechselt werden. Speichert: DG, P, F, I, B, M, V, L, T, G und Animationen.
COLLADA	COLLADA (collaborative design activity, .dae) wurde von der Khronos Group entwickelt und ist seit 2012 ISO-zertifiziert. Es basiert auf XML und speichert: DG, P, B-Rep, F, I, B, M, V, L, T, G und Animationen.
OBJ	Das offene OBJ-Format wurde von Wavefront Technologies entwickelt und hat eine weite Verbreitung gefunden. Speichert: DG, P, F, I, B, M und G.
PLY	Das Polygon File Format ist ein einfaches Format, das an der Universität Stanford für Daten von 3D-Scannern entwickelt wurde. Speichert: DG, F, I, B und M.
VRML ~	Die Virtual Reality Modeling Language ist das Vorgängerformat von X3D. Die jüngste Version wurde 1997 unter dem Namen VRML97 veröffentlicht. Speichert: DG, P, F, I, B, M, V, L, T, G und Animationen.
U3D	Das Universal 3D Format ist ein 2005 von der ECMA standardisiertes 3D-Format, das vom 3D Industry Forum mit Mitgliedern wie Intel und Adobe Systems entwickelt wurde. Dieses Format ist nur für die Integration von 3D-Modellen in ein 3D-PDF relevant. Speichert: DG, F, I, B, V, L, T, G und Animationen.
STL	Das Format STL wurde von 3D Systems entwickelt. Es steht für <i>stereolithography</i> oder <i>Standard Tessellation Language</i> und findet weite Verbreitung im Bereich von 3D-Druckern und digitaler Fabrikation. Die ASCII-Variante des STL-Formats kann nur die Geometrie eines 3D-Modells speichern. Die Binärvariante des Formats ist weniger speicherintensiv und kann mit einer entsprechenden Erweiterung auch Farben des 3D-Modells speichern, ist aber nicht für die Langzeitarchivierung geeignet.
DXF	Das von Autodesk entwickelte Drawing Interchange Format stammt aus dem CAD-Bereich und sollte nur für 3D-Inhalte verwendet werden, die mit CAD-Software erstellt wurden. Speichert: DG, P, CSG, B-Rep, F und G.
3DS, MAX ✗	Proprietäre binäre Formate von AutoDesk 3ds Max.
SKP	Natives Format von Google SketchUp.
BLEND	Natives binäres Format von Blender.

Dokumentation Für die Dokumentation von 3D-Inhalten sollten die Leitsätze der *Londoner Charta*² berücksichtigt und eingehalten werden. Dabei ist insbesondere „Leitsatz 4: Dokumentation“ wichtig, dessen erster Absatz lautet:

„Es sollen genügend Informationen dokumentiert und weitergegeben werden, um das Verstehen und Bewerten der computergestützten Visualisierungsmethoden und -ergebnisse in Bezug auf die Zusammenhänge und Absichten, für die sie eingesetzt werden, zu ermöglichen“

Dazu gehören unter anderem die Dokumentation der Forschungsquellen, die zur Erstellung des 3D-Modells herangezogen wurden, die Dokumentation der Prozesse, die im Verlauf der Modellerstellung durchlaufen wurden, die Dokumentation der angewendeten Methoden und eine Beschreibung der Abhängigkeitsverhältnisse zwischen den unterschiedlichen Bestandteilen.

Hinweis: Wenn das Dateiformat es erlaubt, sollte ein Teil der Metadaten zusätzlich dort integriert werden. Allerdings kann der Großteil der Metadaten nur extern abgelegt werden.

Die hier angegebenen Metadaten sind als minimale Angabe zu betrachten und ergänzen die angegebenen Metadaten für Projekte und Einzeldateien in dem Abschnitt Metadaten in der Anwendung ab Seite 24.

Metadatum	Beschreibung
Anzahl Eckpunkte	Aus wie vielen Eckpunkten besteht das 3D-Modell?
Anzahl Polygone	Wie viele Polygone hat das 3D-Modell?
Geometriertyp	Welcher Geometriertyp wird verwendet (Drahtgittermodell, parametrisch, CSG, B-Rep etc.)?
Maßstab	Welcher Maßstab liegt vor bzw. was stellt eine Einheit dar?
Detaillierungsgrad (LOD) oder Auflösung	Wie detailliert ist das Modell oder welche Auflösung wurde beim 3D-Scan verwendet?
Ebenen	Werden Ebenen verwendet? Wie viele?
Textur	Werden Texturen verwendet? Falls ja, müssen zusätzlich die Texturdateien archiviert werden.
Material	Informationen über die Materialeigenschaften des Modells und inwieweit sie physikalisch korrekt sind.
Licht	Informationen über die Lichtquellen und inwieweit sie physikalisch korrekt sind.
Shader	Werden spezielle, erweiterte Shader verwendet?
Animation	Ist das Modell animiert? Welche Art von Animation wird verwendet (Keyframe, motion capture)?
Externe Dateien	Eine Liste aller externen Dateien, die für das Öffnen der Datei notwendig sind (z.B. Texturen).

Weitere Metadaten sind methodenabhängig und können in den jeweiligen Abschnitten nachgelesen werden.

²Londoner Charta für die computergestützte Visualisierung von kulturellem Erbe: www.londoncharter.org

Vertiefung

Ein übliches 3D-Modell besteht aus Eckpunkten (*vertices*), die Polygone beschreiben. Meistens handelt es sich dabei um Dreiecke. Sind die Eckpunkte und die zu den Polygonen gehörenden Kanten erfasst, spricht man von einem Drahtgittermodell (*wire-frame model* oder *mesh*). Sind nur die Eckpunkte erfasst, handelt es sich um eine Punktfolke, welche beispielsweise von 3D-Scannern erzeugt wird. Um eine Punktfolke weiter zu verarbeiten, muss diese vorher meist in ein Drahtgittermodell umgewandelt werden.

Die Inhalte von 3D-Modellen können in drei Kategorien eingeteilt werden: Geometrie, Oberflächeneigenschaften sowie Belichtungs- und Kameraparameter. Zusätzlich kann noch eine Animation oder eine Interaktion hinterlegt sein. Aus diesen Angaben wird die Visualisierung berechnet. Dieser Vorgang wird als Bildsynthese bezeichnet (*rendering*) und resultiert in statischen Rastergrafiken, Videos oder interaktiven Modellen.

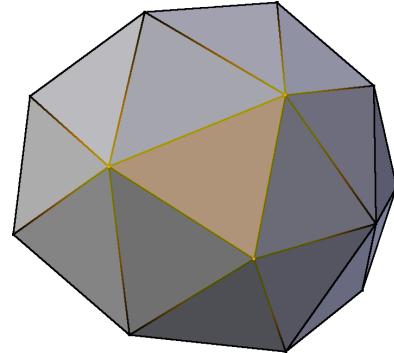


Abb. 3.10: Die gelb markierten Eckpunkte beschreiben das hervorgehobene Dreieck in dem 3D-Modell.

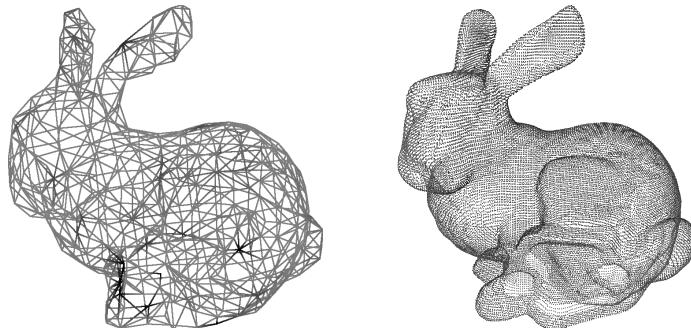


Abb. 3.11: Das Stanford Bunny links als Drahtgittermodell und rechts als Punktfolke.

Geometrie Die Form eines 3D-Modells kann mit vier verschiedenen Methoden beschrieben werden: durch ein Drahtgittermodell oder Facetten, parametrisch mit mathematisch beschriebenen Kurven und Flächen, mittels geometrischen Körpern, der sogenannten Konstruktiven Festkörpergeometrie, oder durch die begrenzenden Oberflächen, dem sogenannten Begrenzungsflächenmodell.

Drahtgittermodell: Hierbei wird die Form des 3D-Modells durch dessen Eckpunkte beschrieben, welche wiederum eine Reihe von Polygonen bilden, die zusammen die Oberfläche des Modells darstellen. Drahtgittermodelle sind einfach und schnell zu rendern, jedoch sind bei Detailansichten von konkaven oder konvexen Oberflächen immer die Flächen und scharfen Kanten der einzelnen

Polygone erkennbar. Mittels sogenannten Shading-Algorithmen kann beim Rendern der Eindruck von gleichmäßigen Oberflächen generiert werden. Jedoch ist dann an der Kontur immer noch die polygonale Herkunft zu erkennen, wie in Abbildung 3.13 im Abschnitt Oberflächeneigenschaften ab Seite 94 dargestellt.

Eine Annäherung an eine gleichmäßige Oberfläche kann auch durch eine größere Anzahl an kleineren Polygonen erzielt werden, was aber zur Folge hat, dass die Dateigröße des Modells wächst.

Parametrische Darstellung: Viele Kurven und Flächen können mathematisch mit wenigen Parametern errechnet werden. Im Bereich der 3D-Grafik werden für die parametrische Darstellung häufig NURBS (Non-Uniform Rational B-Splines, nicht-uniforme rationale B-Splines) verwendet. Die Verwendung von mathematisch beschriebenen Kurven und Flächen erlaubt eine in der Detailliertheit der Oberfläche verlustfreie Skalierbarkeit. Wird ein 3D-Modell mit parametrischen Flächen in einem Format gespeichert, das diese nicht unterstützt, muss das Modell in Polygone umgerechnet werden, was dazu führt, dass Informationen der Oberflächenstruktur verloren gehen, was vergleichbar mit dem Informationsverlust bei der Konvertierung von einer Vektorgrafik in eine Rastergrafik ist.

Konstruktive Festkörpergeometrie: 3D-Modelle können, anstatt durch Eckpunkte, Flächen oder Kurven auch mit Hilfe von geschlossenen geometrischen Körpern konstruiert werden. Dabei kann die Vereinigung, die Differenz oder die Schnittmenge der Körper gebildet werden. Beispielsweise kann ein Verkehrshütchen aus der Vereinigung eines Kegels und eines flachen Quaders konstruiert werden. Daher wird diese Vorgehensweise als Konstruktive Festkörpergeometrie (Constructive Solid Geometry, CSG) bezeichnet. Sie erfordert die Speicherung sowohl der einzelnen geometrischen Körper, als auch der angewandten Methoden, um eine spätere Bearbeitung der Modelle einfach zu ermöglichen. Insbesondere Dateiformate aus dem CAD-Bereich berücksichtigen dies. Eine Konvertierung von Formaten, die CSG unterstützen, zu denen, die keine unterstützen, führt zu Einschränkungen bei der Bearbeitbarkeit, da nur noch Polygone und deren Eckpunkte verändert werden können. Eine Konvertierung von einem Polygonformat zu einem CSG-Format ist nur schwer möglich.

Begrenzungsflächenmodell: Eine weitere Form der Speicherung der Geometrien von 3D-Modellen aus dem CAD-Bereich stellt das Begrenzungsflächenmodell (Boundary Representation, B-Rep) dar. Dabei wird das Modell durch dessen begrenzende Oberflächen beschrieben.

Oberflächeneigenschaften Neben der Form müssen für ein 3D-Modell auch Oberflächeneigenschaften gespeichert werden, die das Aussehen des Modells bestimmen. Neben der Farbe gehören dazu Texturen und Materialeigenschaften, die kombiniert zu einem sehr realistisch wirkenden 3D-Modell führen können.

Texturen können abstrakt als eine auf das Modell aufgebrachte Tapete verstanden werden. Beispielsweise kann auf einen einfachen Zylinder ein Bild von Holzmaserung aufgebracht werden, um einen Baumstamm fotorealistisch darstellen zu können. Dabei wird jedem Punkt im 3D-Modell ein Punkt aus dem zweidimensionalen Bild zugewiesen.

Auch die Materialeigenschaften können in einem 3D-Modell modelliert werden, um dem Objekt die gewünschten Reflexionseigenschaften zuzuweisen, denn ein Holztisch weist bei Beleuchtung andere Eigenschaften auf als ein Glastisch.

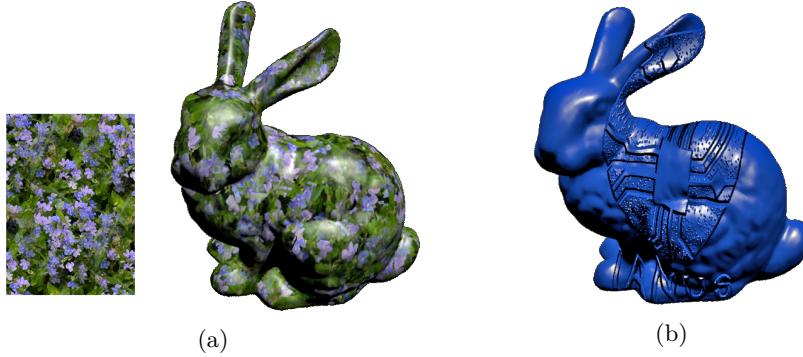


Abb. 3.12: (a) Eine Textur und deren Anwendung auf ein 3D-Modell. (b) Mittels Bumpmapping wurde das IANUS-Logo auf ein 3D-Modell aufgebracht. Es erweckt den Anschein einer dreidimensionalen Veränderung der Oberfläche, jedoch hat sich in der Geometrie des Modells nichts verändert, was an den Umrissen zu erkennen ist.

Hierfür werden in dem Modell verschiedene Parameter gespeichert, welche diffuse Streulicht, spiegelndes Spekularlicht, Umgebungslicht, Transparenz, Lichtbrechung, Lichtemission etc. beschreiben.

Eine weitere Technik, um das Aussehen einer Oberfläche zu beeinflussen ist das Bumpmapping. Dabei werden mittels einer Textur die Normalenvektoren der einzelnen Polygone verändert, was dazu führt, dass die Schattierungen und Reflexionen auf der Oberfläche verändert werden und somit Oberflächenunebenheiten simuliert werden, die geometrisch eigentlich nicht vorhanden sind.

Die Oberflächeneigenschaften werden mit Shadern beim Rendern visuell umgesetzt. Shader (dt. Schattierer) sind Programme, die mittels verschiedener Algorithmen unter Berücksichtigung der Lichtquellen die Farbe für jeden darzustellenden Pixel berechnen, um das Aussehen des 3D-Modells in der gerenderten Darstellung zu bestimmen. Ein Shader kann beispielsweise den Eindruck von gleichmäßigen Oberflächen erzeugen, wie in Abbildung 3.13 dargestellt.

Belichtungs- und Kameraparameter Wie einem Nutzer ein 3D-Modell angezeigt wird, hängt von dem Szenenaufbau ab. Dazu gehören die Größe des Viewports, die Positionierung des 3D-Modells darin, die Position der Kamera und die Lichteinstellungen.

Der Viewport ist dabei vergleichbar mit einer Bühne, die den für die Darstellung zur Verfügung stehenden Bildausschnitt in seiner Höhe, Breite und Tiefe definiert. Für die Kamera muss nicht nur die Position, sondern auch die Blickrichtung gespeichert werden.

Werden 3D-Inhalte ohne Licht gerendert, wird ein schwarzes Bild erzeugt. Daher sind Lichtquellen notwendig, um die Szene auszuleuchten. Werden keine Angaben zu Anzahl, Position, Intensität und Art der Lichtquellen gespeichert, bleibt dies dem Nutzer überlassen oder sie werden gegebenenfalls automatisch vom Programm gesetzt.

Die Szene kann ein oder mehrere Modelle umfassen, welche auch gruppiert werden können. Gruppierungen sind insbesondere dann notwendig, wenn ein Modell aus mehreren Teilen besteht. Dabei muss außerdem die Lage der Teile

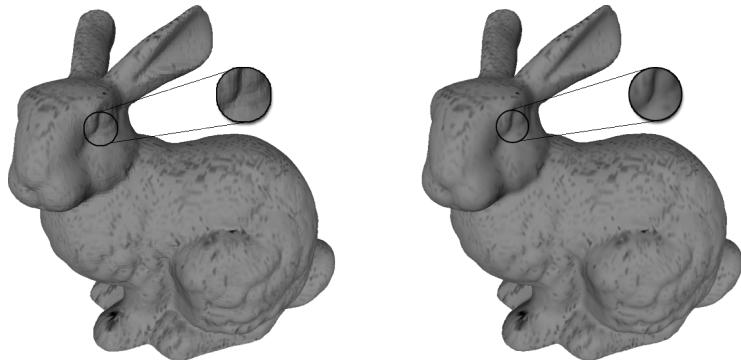


Abb. 3.13: Das linke Modell wurde ohne spezielle Shader gerendert, weshalb die einzelnen Polygone zu erkennen sind. Wird auf das gleiche Modell ein glättender Shader angewendet, entsteht der Eindruck von gleichmäßigen Oberflächen, wie im rechten Teil der Abbildung.

zueinander gespeichert werden. Es handelt sich dabei um Transformationen, die Verschiebungen, Drehungen oder Skalierungen der Objekte betreffen.

Bei der Darstellung von umfangreichen Szenen können unterschiedliche Detailstufen für die einzelnen Objekte verwendet werden. Beispielsweise kann eine Mauer im Vordergrund, nahe der Kamera sehr detailliert dargestellt werden, während ein Baum weit im Hintergrund nur grob angedeutet werden muss, wobei der Detailgrad von 3D-Modellen dabei von der Anzahl der Polygone abhängt. Dieser Detaillierungsgrad wird als „Level of Detail“ (LOD) bezeichnet und findet insbesondere dann Anwendung, wenn das Rendern von 3D-Modellen effizienter werden soll.

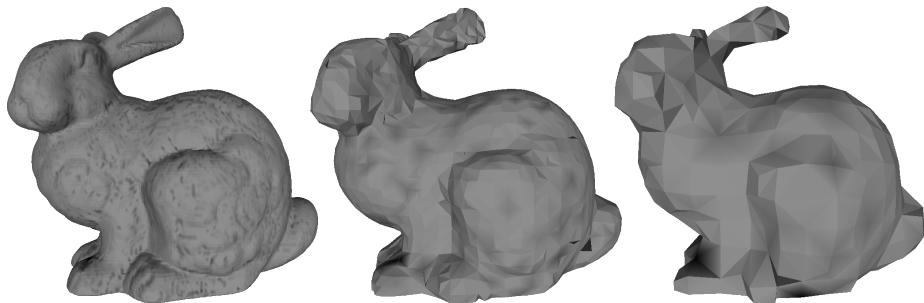


Abb. 3.14: Auswirkungen von verschiedenen Detaillierungsgraden (LOD) auf ein 3D-Modell. Das Stanford Bunny mit 69451, 3851 und 948 Polygonen.

Animation und Interaktion Für Animation und Interaktion ist die Speicherung von zusätzlichen Parametern erforderlich. Dies muss bei der Wahl eines Archivierungsformates berücksichtigt werden und erfordert zusätzliche Angaben in der Dokumentation. Werden Animationen beispielsweise als Videodateien exportiert, sollten die Hinweise in dem Abschnitt Bewegte Bilder, Videos ab Seite

88 berücksichtigt werden.

Speicherung der verschiedenen Eigenschaften Nicht jedes 3D-Format unterstützt die Speicherung aller eben genannten Eigenschaften. Daher muss bei der Wahl des Speicherformates bedacht werden, welche Eigenschaften unbedingt erhalten bleiben sollen. Beispielsweise ist für ein gescanntes Objekt die Speicherung von Lichtquellen oder Animationen nicht unbedingt erforderlich, wohingegen bei einer Architekturrekonstruktion zur Darstellung von Lichtverhältnissen die Lichtquellen unerlässlich sind.

Eine Übersicht über die Speichereigenschaften der hier empfohlenen Formate zur Langzeitarchivierung gibt die folgende Tabelle.³

Die Tabelle ist nicht erschöpfend, da es noch viele weitere spezielle Eigenschaften von 3D-Inhalten gibt, die aber oft nur in spezialisierten, häufig proprietären Anwendungen und 3D-Formaten zum Tragen kommen. Daher ist außerdem zu empfehlen, dass die originalen Dateien ebenfalls archiviert werden, falls es sich dabei nicht schon um eines der hier angegebenen Formate handelt.

Format	Geometrie				Aussehen				Szene				Anim.
	DG	P	CSG	B-Rep	F	X	B	M	V	L	T	G	
X3D	✓	✓			✓	✓	✓	✓	✓	✓	✓	✓	✓
VRML	✓	✓			✓	✓	✓	✓	✓	✓	✓	✓	✓
COLL.	✓	✓		✓	✓	✓	✓	✓	✓	✓	✓	✓	✓
U3D	✓				✓	✓	✓		✓	✓	✓	✓	✓
PLY	✓				✓	✓	✓	✓					
OBJ	✓	✓			✓	✓	✓	✓					✓
STL	✓				(✓)								
DXF	✓	✓	✓	✓	✓								✓
STP	✓	✓	✓	✓	✓								✓
IGS	✓	✓	✓	✓	✓					✓	✓		

Tabelle 3.1: Unterstützte Eigenschaften von verschiedenen 3D-Formaten. DG=Drahtgittermodell, P=Parametrisch, F=Farbe, X=Textur mittels Bild, B=Bumpmapping, M= Material, V= Viewport und Kamera, L= Lichtquellen, T= Transformationen, G=Gruppierung. Leere Zellen bedeuten entweder fehlende Speichereigenschaften oder es wurden keine Angaben in der jeweiligen Formatspezifikation gefunden.

Praxis

Im Umgang mit 3D-Inhalten müssen in der Praxis einige Details beachtet werden. Dazu gehören die Hinweise aus der Londoner Charta und dass bei der Konvertierung von einem Format in ein anderes Informationsverlust auftreten kann. Eine bequeme Weitergabe von 3D-Modellen kann mittels 3D-PDF erfolgen, deren Erstellung in diesem Abschnitt erläutert wird.

³Nach K. McHenry, P. Bajcsy, An overview of 3D data content, file formats and viewers

London Charter Die Londoner Charta wurde 2006 ins Leben gerufen, um die digitale Visualisierung von Kulturgut so intellektuell und technisch rigoros wie andere etablierte Forschungsmethoden zu machen. Die Londoner Charta strebt danach, strenge Regeln im Umgang mit computergestützten Visualisierungsmethoden zu definieren.

Es gibt sechs Leitsätze:

- Leitsatz 1 adressiert den Umgang mit der Londoner Charta.
- Leitsatz 2, Ziele und Methoden, regt dazu an, darüber nachzudenken, ob die computergestützte Visualisierungsmethode auch die geeignetste verfügbare Methode für den gewünschten Zweck ist.
- Leitsatz 3, Forschungsquellen, thematisiert die Auswahl und Dokumentation des Quellmaterials für eine Visualisierung.
- Leitsatz 4, Dokumentation, gibt wertvolle Hinweise darüber, was bei dem Entstehungsprozess des 3D-Inhaltes alles dokumentiert werden sollte, um das Verstehen und den Umgang mit den Inhalten zu erleichtern.
- Leitsatz 5, Nachhaltigkeit, behandelt die langfristige Zukunftsfähigkeit und vor allem die langfristige Benutzbarkeit von 3D-Inhalten.
- Leitsatz 6 thematisiert einen wichtigen Aspekt im Umgang mit Kulturgütern, nämlich den Zugang zum Kulturgut mittels computergestützten Visualisierungen. Auch der Zugang zu den Visualisierungen selbst wird besprochen.

Londoner Charta:

www.londoncharter.org

Deutsche Fassung der Londoner Charta:

www.londoncharter.org/fileadmin/templates/main/docs/london_charter_2_1_de.pdf

Konvertierung In dem Abschnitt Vertiefung wurden die Speichereigenschaften von verschiedenen 3D-Formaten besprochen und in der Tabelle auf Seite 97 zusammengefasst. Die Speichereigenschaften spielen insbesondere dann eine Rolle, wenn von einem Format in ein anderes konvertiert werden muss, um beispielsweise von einem proprietären Format verlustfrei zu einem langzeitarchivfähigen offenen Format zu gelangen.

Wenn die Software, mit der das 3D-Objekt erstellt wurde, einen Export in eines der hier empfohlenen Formate zulässt, so ist diese Variante vorzuziehen. In manchen Fällen kann es jedoch sein, dass das gewünschte Zielformat nicht unterstützt wird und zunächst ein Export in ein Zwischenformat vorgenommen werden muss, welches anschließend mit einem weiteren Programm in das Zielformat überführt werden kann. Soll beispielsweise ein 3D-Objekt aus *Blender* in ein 3D-PDF integriert werden, könnte dieses etwa im OBJ-Format gespeichert werden und anschließend mit *MeshLab* in U3D konvertiert werden. Mit der *ConversionSoftwareRegistry* können Programme gefunden werden, die von einem Format in ein anderes konvertieren können, wobei eventuelle Zwischenformate auch berücksichtigt werden.

Für die Konvertierung von umfangreichen 3D-Inhalten gibt es auch spezialisierte kommerzielle Programme, wie beispielsweise *Polytrans* und *NuGraph* der Firma Okino.

Blender:

www.blender.org

MeshLab:

<http://meshlab.sourceforge.net>

ConversionSoftwareRegistry:

<http://isda.ncsa.illinois.edu/NARA/CSR>

Okino (Polytrans/Nugraph):

www.okino.com

3D-PDF Eine Möglichkeit, um 3D-Modelle unkompliziert mit Dritten zu teilen, ist die Einbettung in ein 3D-PDF. Dabei können neben dem eigentlichen Modell zusätzliche Informationen in Form von Text, Bildern und Links eingefügt werden. Zusätzliche Programme zur Betrachtung des 3D-PDFs sind in der Regel nicht notwendig, da diese Funktion in Adobe Reader bereits integriert ist und dieser eine breite Anwenderbasis hat. Im Reader können Annotations- und Messwerkzeuge verwendet werden, um Strecken, Radien und Winkel an dem Modell auszumessen.

Ein 3D-PDF kann am komfortabelsten mit Adobe Acrobat Pro erstellt werden. Dabei muss das Modell bereits im U3D-Format vorliegen, welches über „Werkzeuge > Multimedia > 3D-Werkzeug“ in das zu erstellende PDF eingefügt werden kann. Die Firma tetra4D arbeitet eng mit Adobe zusammen und bietet neben dem Programm *3DPDF Converter* eine Reihe an Plugins für professionelle 3D-Software wie AutoCAD oder Maya an. Eine günstigere Alternative bieten die Produkte von *PDF3D*. Freie Alternativen gibt zurzeit es wenige und auch nur mit eingeschränktem Umfang. Ein Beispiel wäre *CutePDF*.

3D-Modelle in Adobe Reader ansehen:

<http://helpx.adobe.com/de/acrobat/using/displaying-3d-models-pdfs.html>

3D-PDFs mit Acrobat erstellen:

<http://helpx.adobe.com/de/acrobat/using/adding-3d-models-pdfs-acrobat.html>

3D-PDFs für Europeana erstellen:

www.carare.eu/rum/Media/Files/3D-Training-Materials

tetra4D:

www.tetra4d.com

PDF3D:

www.pdf3d.com

CutePDF:

www.cutepdf.com

Quellen

S. Boeykens – E. Bogani, Metadata for 3D models. How to Search in 3D Model Repositories? (2008)

<https://lirias.kuleuven.be/bitstream/123456789/202356/1/boeykens-bogani.pdf>

K. McHenry – P. Bajcsy, An Overview of 3D Data Content, File Formats and Viewers (2008)

<http://isda.ncsa.illinois.edu/drupal/sites/default/files/NCSA-ISDA-2008-002.pdf>

D. Pletinckx – D. Haskiya, D5.1 Functional Specification of Requirements for Preparing 3D/VR for Europeana (2011)

http://www.carare.eu/eng/content/download/2026/15338/file/D5_1_Functional_specification_3DVR_final.pdf

J. Slick, 3D Basics – Getting Started in 3D

<http://3d.about.com/od/3d-101-The-Basics/u/3d-Basics-Getting-Started-In-3d.htm>

3D ICONS Projekt:

www.3dicons-project.eu

Stanford Bunny aus dem Stanford Computer Graphics Laboratory:

<http://graphics.stanford.edu/data/3Dscanrep/>

Formatspezifikationen

X3D und VRML:

www.web3d.org

COLLADA:

www.khronos.org/collada

OBJ:

http://en.wikipedia.org/wiki/Wavefront_.obj_file

PLY:

<http://paulbourke.net/dataformats/ply/>

U3D:

www.ecma-international.org/publications/standards/Ecma-363.htm

STL:

www.ennex.com/~fabbers/StL.asp

DXF:

http://images.autodesk.com/adsk/files/acad_dxfo.pdf

Tools und Programme

Londoner Charta:

www.londoncharter.org

Deutsche Fassung der Londoner Charta:

www.londoncharter.org/fileadmin/templates/main/docs/london_charter_2_1_de.pdf

Blender:

www.blender.org

MeshLab:

<http://meshlab.sourceforge.net>

ConversionSoftwareRegistry:

<http://isda.ncsa.illinois.edu/NARA/CSR>

Okino (Polytrans/Nugraph):

www.okino.com

3D-Modelle in Adobe Reader:

<http://helpx.adobe.com/de/acrobat/using/displaying-3d-models-pdfs.html>

3D-Modelle erstellen mit Acrobat:

<http://helpx.adobe.com/de/acrobat/using/adding-3d-models-pdfs-acrobat.html>

3D-PDFs für Europeana erstellen:

www.carare.eu/rum/Media/Files/3D-Training-Materials

tetra4D:

www.tetra4d.com

PDF3D:

www.pdf3d.com

CutePDF:

www.cutepdf.com

3.12 Präsentationen

3.13 Webseiten

3.14 Eigene Programme und Skripte

4 | Forschungsmethoden

F. Schäfer, M. Trognitz

Die Ergebnisse aus verschiedenen in den Altertumswissenschaften angewandten Methoden setzen sich oft aus mehreren verschiedenen Dateien unterschiedlicher Formate zusammen. Dadurch gehen die Ansprüche an die Dokumentation und die erforderlichen Metadaten zu den einzelnen Dateiformaten über die des vorherigen Kapitels hinaus und unterscheiden sich von Methode zu Methode.

Sofern spezifische Dateiformate eine besondere Relevanz besitzen, sind diese entweder hier beschrieben oder es wird auf die entsprechenden Abschnitte im Kapitel Dateiformate auf Seite 37 verwiesen.

Da die Kapitel der einzelnen Forschungsmethoden von unterschiedlichen Spezialisten verfasst wurden, fallen sie in Inhalt, Länge, und Gliederung sehr unterschiedlich aus. Allen gemeinsam sind aber Angaben zu folgenden Themenbereichen:

- Einleitende Informationen zu einer Forschungsmethode
- Umfang und Form der generierten und prozessierten Daten
- Etablierte Standards für Metadaten zur Dokumentation von Primär- und Sekundärdaten
- Praktische Empfehlungen für die Archivierung und Nachnutzung
- Fallstudien und Praxisbeispiele
- Bibliographien und Weblinks mit weiterführenden Quellen

4.1 Anthropologie

- 4.1.1 Genetik (Genotyp)
- 4.1.2 Morphologie und Metrik (Phänotyp)
- 4.1.3 Physiologie (Ökotyp)
- 4.1.4 Verhaltensforschung (Ethotyp)

4.2 Archäobotanik

- 4.2.1 Makroreste
- 4.2.2 Pollenanalyse (Palynologie)

4.3 Archäozoologie

4.4 Bauforschung

- 4.4.1 Bauaufnahme
- 4.4.2 Rekonstruktion

A. Müller, U. Wulf-Rheidt

Vertiefung

3D-Modelle Einfache 3D-Modelle sind relativ schnell angelegt und können zur visuellen Kommunikation einen erheblichen Beitrag leisten. Nach Auswertung erster Forschungs- oder Grabungsergebnisse entstehen oft erste, vereinfachte Massenmodelle, die z. B. der Erläuterung von Rekonstruktionsideen dienen können. Es ist dann kein Problem, die erstellten Volumina in georeferenzierte Systeme, wie beispielsweise Google Earth zu integrieren oder in präzisere Geländemodelle einzubauen. Im Verlaufe des Projektes wird das 3D-Modell in der Regel immer differenzierter ausgearbeitet und es werden mehr Datensätze und Informationen angehängt, in dem einzelne Gebäudeteile und Räume differenziert dargestellt, Bauteile ausgearbeitet, u.U. Bilder, Geodaten, Befund-Daten und Literaturhinweise angehängt und schließlich die zur Visualisierung notwendigen Texturen und Lichtquellen sowie dynamische und statische Schnitte generiert werden. Derart komplexe Aufgaben erfordern eine gut durchdachte Datenverwaltung, da ihr Verwaltungs- und Pflegeaufwand exponentiell zur Datenmenge anwächst. Deshalb ist es wichtig, sich vor Anlegen eines 3D-Modells über die Ziele, die verwirklicht werden sollen, klar zu werden. Wenn z.B. ein Modell nur benötigt wird, um einige Perspektiven für eine Publikation zu visualisieren, genügt es, die Kubatur des Gebäudes zu erstellen, sie zu texturieren, Lichtquellen zu setzen und Ansichtsdefinitionen festzulegen. Dementsprechend gering bleibt der Sicherungs- und Dokumentationsaufwand. Je genauer der Auftraggeber eines 3D-Modells die Ziele, zur Verwendung des Modells definiert, desto geringer kann der Aufwand der Datenerstellung und Datenhaltung gehalten werden.

Deshalb sind Mindestanforderungen bei der Auftragsvergabe nur auf sehr niedrigem Niveau möglich. Zurzeit beschränken sich diese Forderungen in der Regel auf die Sicherung in einem gut dokumentierten Format wie z.B. dxf oder Wavefront OBJ-Dateien, mit allen Nachteilen, die sich dabei aus einer eventuellen Datenkonvertierung ergeben.

Praxis

Es ist derzeit verbreitet, die Wahl der Software dem Zufall zu überlassen: Softwarekenntnisse des Bearbeiters, das Vorhandensein von Software oder die Frage, welche Software preiswert zu erwerben ist, bestimmen meist die Wahl.

Das bedeutet zwar nicht, dass eine spätere Entscheidung für eine andere Software zu totalem Datenverlust führen muss, denn grundsätzlich ist die Konvertierung beinahe jedes Zeichenformates in ein anderes möglich. Dies ist jedoch häufig mit erheblichen Informationsverlusten oder/und gewaltigem Arbeits- und Kostenaufwand verbunden.

Wurde ein Modell beispielsweise in einer Visualisierungssoftware wie Rhinoceros, Maya oder 3ds Max erstellt, so haben die Objekte hauptsächlich Metainformationen hinsichtlich Geometrie und Textur. Mit dieser Software sind sehr hochwertige Bilder und Animationen generierbar, die Verwaltung hinsichtlich bautechnisch sinnvoller Einheiten wie Wände und Fenster ist dagegen nicht vorgesehen und ist deshalb schwierig, zeitaufwändig und umständlich.

Architektursoftware bietet erhebliche Vorteile hinsichtlich der Datenverwaltung, da Objekte von vornherein in üblichen Klassifizierungen, wie Wänden, Decken, Stützen, Böden und Öffnungen usw. verarbeitet werden können. Die Eingabe ist aufwändig, da sie parametrisch erfolgt. Sie bietet aber den Vorteil

der Nachvollziehbarkeit. Außerdem besteht die Möglichkeit, zwischen verschiedenen Maßstäben hin- und herzuschalten und standardmäßig 2D-Schnitte und -Grundrisse darzustellen bzw. zu exportieren. Nachteile liegen vor allem im Preis der Anschaffung und der Notwendigkeit regelmäßig upzudaten, verlustfreier Datentransfer ist - wenn überhaupt - meist nur innerhalb der Produktgruppe des selben Software- Entwicklers möglich. Standardisierte Objekte wie Wände sind starr definiert und können nicht frei modelliert werden, eine verformungsgetreue Darstellung ist damit nicht möglich. Allerdings ist in den meisten Fällen eine verformungsgetreue Nachbildung des Baukörpers im Modell nicht nötig und verkompliziert unnötig die Geometrie und vergrößert die Datenbanken.

Offene Systeme wie AutoCad, VectorWorks und MicroStation bieten viele Vorteile hinsichtlich der Konvertierbarkeit und haben Schnittstellen zu beinahe jeder Art von Software. Sie ermöglichen jedoch meist keine normierten Klassifizierungen (Wände, Türen etc), es sei denn, es wird eine spezifische Applikation (z.B. für Architektur oder GIS) verwendet. Diese Vorgabe muss daher vor Anlegen des 3D-Modells festgelegt werden. Diese Systeme haben neben den genannten Vorteilen vor allem den Vorzug, weit verbreitet, gut dokumentiert und als Schulungsversionen relativ kostengünstig zu sein. Nachteile liegen in der Datenverwaltung und dem Bearbeitungskomfort.

Ein wichtiges Kriterium stellt ein gut dokumentiertes und leicht lesbares Format dar, das sämtliche Erfordernisse des Projekts mit einem Datenformat erfüllt. Ein gut dokumentiertes Format ist dabei unbedingt einem proprietären Binärformat, welches außer von einer kleinen Community nicht genutzt wird, vorzuziehen.

Wegen ihrer Verbreitung und den ubiquitär verfügbaren Importern sollte als erstes die Verwendung der ASCII-Version von DXF oder eines reinen Wavefront OBJ-Files in Betracht gezogen werden.

Zudem sollte das Datenformat rekursives Laden von Daten ermöglichen, also die Zerlegung eines Modells in mehrere Dateien, die dann wiederum an ein datenbankunabhängiges Bauwerksinformationssystem angehängt werden können.

Auswahl geeigneter Software Bei den 3D-Architekturmodellen im archäologischen Kontext ist es sinnvoll, drei Kategorien zu unterscheiden:

- 1. Arbeitsmodelle
- 2. Visualisierungsmodelle
- 3. Interaktive Modelle

Arbeitsmodelle müssen maßstäblich und ggfls. auch georeferenziert sein. Dabei können sehr unterschiedliche Fragestellungen im Vordergrund stehen, z. B. stadträumliche oder topografische Beziehungen, Massenermittlungen, bei Einzelbefundrekonstruktionen aufgrund eines Versturzes z.B auch Lagebestimmungen, statische und konstruktive Bedingungen, bis hin zu einfachen Licht- und Schatten- Untersuchungen. Aus solchen Modellen sollten maßstäbliche und vermaßbare technische Pläne generierbar sein, die der Kommunikation exakt nachvollziehbarer Zusammenhänge wie Höhen, Längen, Breiten und Massen dienen. Die Geometrie kann hierbei stark vereinfacht sein, grundsätzlich gilt dabei, dass

Genauigkeit und Nachvollziehbarkeit vor Schönheit stehen sollte. Je nach gewünschter (mess- und abfragbarer) Informationsdichte des Modells sollte sorgfältig überlegt werden, welche Software bei welchem Arbeitsaufwand die gewünschten Standards bietet. Je nach Komplexität der angestrebten Informationsdichte besonders bei Rekonstruktionsmodellen ist zusätzlich zu beachten, dass auch der Zeichner zumindest architektonische Vorkenntnisse haben sollte.

Geeignete Software sind vor allem Architekturprogramme, wie z.B. Archicad, AutocadArchitectural, Nemetschek, Spirit usw. aber auch offene Systeme wie Microstation, Vectorworks und AutoCad. Architekturprogramme bringen logische Klassifizierungen, wie Wände, Stützen, Unterzüge, Treppen, Fenster, Dächer etc. mit sich, die Eingabe erfolgt dabei parametrisch und alle Parameter sind in Projekt-Datenbanken erfasst. Ob solche Datenbanken nur programmintern abgefragt oder wie sie in geeignete übergreifende Systeme exportiert werden können, muss sorgfältig geklärt werden.

Mit allen diesen Programmen lassen sich auch mehr oder weniger realistische Bilder generieren, häufig jedoch nur von mäßiger Qualität. Die Modellierung hochkomplexer geometrischer Körper, wie z. B. eines korinthischen Kapitells, ist jedoch kaum möglich.

Bei Visualisierungsmodellen ist vor allem Art und Qualität der angestrebten Visualisierung zunächst zu klären. Dabei gilt „je höher die Qualität, desto höher der Arbeitsaufwand und die aufzuwendenden Kosten. Von einfachen Modellen ohne Textur bis hin zu fotorealistischen Bildern ist heute alles möglich. Für fotorealistische Bilder, wenn diese nicht als animierte Szenen gewünscht werden, kann auch überlegt werden, ob eine Kombination von Einzelbildsynthese und Bildmontage in einem Bildbearbeitungsprogramm (z.B. Photoshop) einfacher und schneller zum Ergebnis führt.“

Zur Anwendung können sehr einfache, z.T. auch Freewareprogramme kommen, wenn das Interesse in erster Linie der Geometrie gilt und diese eine überschaubare Polygon - Anzahl umfasst. Sollen anspruchsvolle, realistische oder gar fotorealistische Szenen erstellt werden, ist die Wahl einer professionellen Visualisierungs- Software ratsam. Da Visualisierungsprogramme in erster Linie der Erstellung maßstabloser, möglichst ansprechender Bilder dienen, ist präzises, maßstäbliches Zeichnen nur bedingt möglich. Die Definition der Körper erfolgt bei den einfacheren Programmen über ihre absolute Geometrie, bei aufwändigen Programmen wie Rhino, Cinema4d, MAYA oder 3dsMAX über Parameter für die Ausgangsgeometrie und ggf. verschiedene Modifikatoren für Geometrie und Animation.

In Visualisierungsprogrammen ist - mit entsprechendem Aufwand - die Herstellung jeder denkbaren Qualität von Bildern, sowohl hinsichtlich der Auflösung wie der Detailqualität und des Realismus, möglich. Außerdem können Filmszenen generiert werden, die z.B. für die Visualisierung der Funktionsweise von Maschinen, für dynamische Schnitte oder die Darstellung von Bauabläufen sehr sinnvoll sein können.

Da das Erstellen fotorealistischer Bilder mit 3d-Software hochkomplex ist, ist eine Verknüpfung mit bau-, geo- oder grabungsspezifischen Datenbanken nicht sinnvoll. Es gilt ganz allgemein der Satz: Schönheit und/oder visuelle Aussage vor Genauigkeit. Solche Modelle dienen allein der visuellen Kommunikation über Standbilder und Filme.

Interaktive Modelle können mit Datenbanken verknüpft werden. Diese sind ohne Programmierkenntnisse bislang kaum sinnvoll erstellbar. Es stellt sich da-

bei - abgesehen von der Qualität der verknüpften Datenbanken und ihren Fra gestellungen - vor allem das Problem der Ladezeiten. Deshalb sind besondere Render- Engines unverzichtbar, die Geometrie und Texturen mit intelligenten Algorithmen reduzieren, je nachdem, ob sich diese im Vorder-, Mittel- oder Hintergrund befinden.

In der Regel werden solche Modelle von einem Team aus Zeichnern und Programmierern erstellt. Wegen der sehr spezifischen Anforderungen an die Benutzeroberflächen und den Workflow ist auch an Personen mit Kenntnissen in der Erstellung von 3d-Spielen und/oder Webdesigner zu denken.

Allgemein gilt die Prämisse: Workflow, einfache Steuerung, Übersichtlichkeit und intuitive Verständlichkeit der Oberfläche. Komplexe Inhalte können über Links abgefragt werden und sollten nicht auf der Oberfläche platziert sein.

Auswahl der Hardware Bei der Erstellung von 3d- Modellen sind naturgemäß sehr hohe Anforderungen an die grafische Rechenleistung zu stellen. Aufwändige Visualisierungsarbeiten erfordern eine entsprechend gute Ausstattung mit Hard- und Software, die teuer ist. Beim Echtzeit- Rendering im virtuellen 3d- Raum müssen riesige Datenmengen in sehr kurzer Zeit bearbeitet werden. Dabei sind Einzelplatz- Rechner meist auf die Render- Parameter, wie sie für eine gute Performance in 3d- Spielen erforderlich sind, ausgelegt. Sie sind für die Produktion hochwertig texturierter Einzelbilder oder Filme nicht geeignet. Man spricht heutzutage von Render- Farmen und Netzwerk- Rendering. Das bedeutet, das Rechenleistungen auf viele Prozessoren in einem Netzwerk verteilt werden können. Dabei stellt sich die Frage, ob solche Konstellationen vom Administrator zu gewährleisten sind. Außerdem muss die Software Netzwerkrendering unterstützen. Multiple Grafikprozessoren, Multikern- Hauptprozessoren und adäquat ausgelegte Arbeitsspeicher sind sinnvoll (z.B. 128 GB). Dabei ist darauf zu achten, dass die Hardware auch vom Betriebssystem unterstützt wird (speziell beim Arbeitsspeicher: Windows hat hier bislang die größten Nachteile) und von der eingesetzten 3d- Software gleichermaßen sinnvoll verwaltet werden kann. Riesige Festplatten sind nur bei der Erstellung von Filmen notwendig. Hier empfiehlt sich die Auslagerung auf externe Medien. Wegen der umfangreichen Paletten ist ein großer Monitor mit zusätzlichem Kontrollmonitor unverzichtbar.

Quellen

Da Software- und Hardwaremärkte sehr dynamisch sind, ist es empfehlenswert, sich in aktuellen, Zeitschriften zu informieren, z.B. <http://utils.exeter.ac.uk/german/media/archited.html> und Messen, wie die Bautec zu besuchen.

Außerdem kann man sich auf Wikipedia.de eine gute Orientierung über die diversen Probleme bei der Erstellung von 3d- Modellen verschaffen. Dort finden sich auch Links zu weiterführender Literatur die i.d. Regel recht aktuell sind: <http://de.wikipedia.org/wiki/Kategorie:Bildsynthese>, sehr empfehlenswert ist auch der Artikel:

<http://de.wikipedia.org/wiki/Grafik-Engine>

Viele Software- Hersteller unterhalten eigene Foren oder verweisen zumindest auf ihren Seiten auf User- Foren, z.B.: <http://www.autodesk.de/>.

Gerade im Bereich der 3d-Modellierung gibt es viele einschlägige Foren, z.B.: 3D-Ring:

<http://www.3d-ring.de/forum.php>

3Dlinks:

<http://www.3dlinks.com/>

Grafiker:

<http://www.grafiker.de/forum/forumdisplay.php?f=39>

3Dcenter:

<http://www.forum-3dcenter.org/vbulletin/>

3Dcafe:

<http://www.3dcafe.com/>

Zur spezifischen Problemstellung interaktiver oder Web- basierter Modelle:
ki-smile:

<http://www.ki-smile.de/kismile/view145,11,1424.html>

garybeene:

<http://www.garybeene.com/3d/3d-pure.htm>

Quality management systems - Requirements(Iso- Norm) Edition: 4 ; Stage: 60.60 ; TC 176/SC 2 ICS: 03.120.10 Beuth- Verlag,Berlin
nestor edition 5: Langzeiterhaltung von 3D-Röntgen-Computertomographien
in der Archäologischen Denkmalpflege. Sayer-Degen, Leila (2012)
<http://files.dnb.de/nestor/edition/05-sayer-degen.pdf>

4.5 Datierung

4.5.1 Andere Methoden

4.5.2 C14-Datierung

4.5.3 Dendrochronologie

4.5.4 OSL/TL-Datierung

4.5.5 Uran-Ungleichgewichtsmethoden

4.6 Geoarchäologie

4.6.1 Biomarker

4.6.2 Bodenuntersuchungen

4.6.3 Geologische Untersuchungen

4.6.4 Geomorphologie

4.6.5 Sedimentuntersuchungen (Bohrkerne)

4.7 Geodäsie

K. Heine, U. Kapp

Alle Protokolle von Messungsrohdaten, mit Ergebnissen der Netzmessungen, der Ausgleichung und Festpunktkoordinaten inkl. Einmessungsskizzen müssen im ASCII-Format (TXT, CSV, DAT) gespeichert werden.

Vermessungswesen

Es ist ja eine Binsenweisheit, dass archäologische und bauforscherische Tätigkeiten nicht ohne fundierte vermessungstechnische Basis- und begleitende Arbeiten auskommen. Die Zeiten, in denen man im 5X5 Meter Planquadrat seine Erkenntnisse sammelte, gehören zwar nicht der Vergangenheit an, aber die Bedingung ist, dieses Planquadrat in einen globalen Zusammenhang zu bringen. Die Vermessung bekommt in diesem Fall eine andere Bedeutung, die von der bloßen Herstellung von rechtwinkligen Quadranten abweicht. Andere Unterlagen wie Satelliten Images und Luftbilder sowie genaueres Kartenmaterial oder auch Unterlagen von z. B. geomagnetischen Prospektionen geben der Vermessung eine neue Wertigkeit.

Aber: der Einsatz elektronischer und satellitengestützter Geräte führt leider wie auch in der digitalen Fotografie zu einer fast unkontrollierbaren Anhäufung von Daten. Diese Ergebnisse müssen kurz- und langfristig verwaltbar sein. Aber dafür gibt es keine Ideallösung, weil die Entwicklungen im Gerätbau und den damit zusammenhängenden Programmen sich überschlagen, und was heute noch als Standard gilt, ist morgen schon überholt.

Meine Empfehlung: die Ergebnisse möglichst schnell auswerten, solange sie noch lesbar sind, denn nach wie vor ist eine Langzeitarchivierung von digitalen Daten nicht gesichert.

Bezugssystem für Messdaten

Nach wie vor ist für viele archäologische Aktivitäten die Vermessungsgrundlage ein lokales Vermessungsnetz, das nicht in überörtliche oder gar in globale Systeme eingebunden ist. Für kleinere Messgebiete ist das legitim, solange sie nicht in einen Zusammenhang gebracht werden müssen.

Da das DAI aber in der Zwischenzeit viele Projekte mit großer räumlicher Ausdehnung bearbeitet, ist es sinnvoll, Messdaten in globalen Systemen zu erfassen, was durch die mittlerweile zur Verfügung stehenden Methoden und Geräte der Satelliten gestützten Vermessung deutlich vereinfacht wird. Durch die Einbeziehung von GPS-Messungen (Genauigkeit 5-10 m) und Differential GPS-Messungen (Zentimetergenauigkeit) kann der räumliche Zusammenhang von verschiedenen Arbeitsplätzen hergestellt werden.

Als Voraussetzungen für globale Positionierungsbestimmungen mit cm-Genauigkeit muss entweder ein Punkt im globalen Koordinatensystem (im Umkreis von 10 km) bekannt sein oder die Möglichkeit der Einbindung eines Satellitenpositionierungsservices (z. B. EGNOS) bestehen. Eine hinreichende Genauigkeit kann auch erzielt werden, wenn auf einem Punkt im Messgebiet entsprechend lange Beobachtungszeiten registriert werden. Grundsätzlich sollten für die Anlage von Vermessungsnetzen im globalen Koordinatensystem mittels GPS Zweifrequenzempfänger benutzt werden. Alternativ können Einfrequenzempfänger mit langer Beobachtungszeit (mindestens 20 min) genutzt werden. Eine Netzauswertung sollte im Post Processing erfolgen. Für die Ermittlung von Höhen sind ein Referenzpunkt sowie ein Geoid-Modell notwendig.

Geografisches System

Grundsätzlich sollte als geografisches Bezugssystem das System WGS 84 (World Geodetic System 84) gewählt werden. Dieses ist auch Bezugssystem für das Satellitennavigationssystem GPS und zukünftig auch für das europäische System

Galileo. WGS 84 ist ein räumliches, globales, geozentrisches System mit den rechtwinkligen Koordinaten x,y,z oder wahlweise auch geografischen Koordinaten geografische Länge (longitude) L und geografische Breite (latitude) B ($^{\circ}, ', ''$). Die Koordinaten lassen sich nach Bedarf in andere Koordinatensysteme transformieren.

Geodätisches System

Für praktische Zwecke der Aufnahme mit der Totalstation und Darstellung von Objekten in Zeichnungen und Plänen, insbesondere für großmaßstäbige Darstellungen (großmaßstäbig bedeutet hier: großer Abbildungsmaßstab, demzufolge i.d.R. kleineres Gebiet) ist dieses räumliche System in ein Abbildungssystem (geodätisches Koordinatensystem, projected coordinate system) zu transformieren. Hierfür eignen sich insbesondere transversale Zylinderabbildungen wie die UTM-Abbildung (Universal Transversal Mercator projection). Mit der UTM-Abbildung können auch lokale Systeme realisiert werden, indem als Mittelmeridian (central meridian) ein durch das Aufnahmegerüst verlaufender Meridian (Längengrad) und als Maßstab der Wert 1,0000 festgelegt wird. Die Angabe der UTM-Koordinaten erfolgt als East (E)- und North (N) - Wert.

Nationale Systeme

In vielen Ländern existieren ein oder mehrere amtliche Systeme, denen unterschiedliche Bezugsellipsoide (z.B. Hayford, Bessel, Krassowski o.a.) mit unterschiedlichem Datum (Lagerung) und verschiedene Abbildungsmethoden (stereografisch, Lambert, Gauß-Krüger, UTM o.a.) zugrundeliegen. Sofern Ellipsoidparameter, Lagerung und Abbildungsverfahren bekannt sind, kann auch in diesen Systemen gearbeitet werden, da diese dann jederzeit in andere Systeme transformierbar sind. Sofern die Parameter nicht bekannt sind, ist zu empfehlen, ein eigenes System unter Verwendung des WGS 84 und der UTM-Abbildung (s.o.) zu wählen und bestehende Karten im unbekannten System über Passpunkte in das neue System zu integrieren.

Momentan verfügen die meisten europäischen Staaten und auch die meisten Bundesländer noch über eigene amtliche Systeme. Für die nächsten Jahre ist aber der Übergang zum einheitlichen System ETRS89 (European Terrestrial Reference System 89) geplant. ETRS89 basiert auf dem Ellipsoid GRS80 (für praktische Zwecke mit WGS 84 identisch) sowie der europäischen Lagerung ETRF (European Terrestrial Reference Frame) von 1989. Als Abbildungsverfahren wird die UTM-Abbildung mit 6° Streifenbreite und dem Maßstabsfaktor 0.9996 gewählt. Messungen in Deutschland sowie in den betroffenen europäischen Staaten sollten dann grundsätzlich ebenfalls in diesem System erfolgen, da die amtlichen Koordinaten für Festpunkte sowie Geobasisdaten dann ebenfalls in diesem System vorliegen.

EPSG

International werden Bezugssysteme nach dem System der EPSG (European Petroleum Survey Group) angegeben. Die EPSG stellt die Parameter für die meisten Bezugssysteme bereit. Diese sind als Download auf den Webseiten der EPSG (www.epsg.org) zu beziehen.

Örtliche Systeme für die Bauforschung

In der Bauforschung ist auch ein objektbezogenes Koordinatensystem, welches beispielsweise parallel zur längsten Bauwerksachse ausgerichtet ist und einen beliebigen Koordinatenursprung besitzt, anwendbar. Dies ist für große und komplexe Bauwerke unter Umständen praktikabler als die Verwendung eines globalen Systems. Um die Messungen bzw. Pläne später in solch ein übergeordnetes System einhängen zu können, sollten mindestens drei Passpunkte bestimmt werden, deren Koordinaten sowohl im bauwerksbezogenen, als auch im globalen System (bestimmbar beispielsweise mittels GPS) bekannt sind.

Einsatz von Hard- und Software in der Praxis

Da es eigentlich nur noch zwei wesentliche Hersteller von Vermessungsgeräten gibt - Leica und Trimble, die alle anderen Hersteller integriert haben - liegt der Entschluss, welches Gerät man wählt, eigentlich nur in der Beziehung, die zum Verkäufer besteht, denn preislich findet man die Unterschiede nicht mehr so groß. Auch die Handhabung ist nicht so unterschiedlich, da sie einem Schema folgt: Gerät aufbauen, Orientieren, Messen, Auslesen. Bei Neuanschaffungen sollte darauf geachtet werden, dass eine Systemreihe fortgeführt wird, wenn nicht zwingende Gründe dagegen sprechen, denn mit jedem Gerätesystemwechsel geht auch ein Softwarewechsel einher.

Eine Beschreibung der Handhabung der Geräte geht meistens aus der Gebräuchsanleitung hervor und würde den Rahmen dieses Leitfadens sprengen.

Messungsdaten

Ich möchte hier nicht das Handaufmaß einbeziehen, sondern nur die elektronischen Messweisen mit Totalstation und GPS. Laserscan-Daten fallen beim DAI noch nicht an, da es noch kein eigenes Gerät gibt. Zum Handaufmaß gehören auch Daten, die mit Laser-Distomat gemessen, also nicht registriert, gespeichert werden.

Grundsätzlich muss man die eigentliche Vermessung von der Weiterverarbeitung im Computer trennen, da es für viele Vermessungsgeräte nach wie vor keine direkte Schnittstelle zum Computer gibt, sieht man von einigen Programmen ab, wie z.B. TachyCad als Aufsatz für AutoCad. Doch damit tauchen dann auch andere Probleme auf, die hardwaremäßig bedingt sind.

Sämtliche Vermessungsdaten der gängigen Totalstationen lassen sich mit den vom Hersteller des Geräts beigefügten Programmen in ASCII, TXT- oder DXF-Dateien in den Computer übertragen. Für die Weiterverarbeitung in CAD-Programmen bedarf es nun eines Transferprogramms, damit – besonders bei AutoCad – diese Daten erkannt und als Objekte behandelt werden können.

Es gibt einige Profi-Programme. Ich benutze seit Jahren BB-VermCad und bin, auch weil ich es gut kenne, damit zufrieden. Nur hat es, wie jedes Aufsatzprogramm den Nachteil, dass vorhandene Versionen nie kompatibel mit neueren Versionen von AutoCad sind, man also theoretisch mit jeder neueren Ausgabe von AutoCad auch eine neue Version von BB kaufen müsste; oder man behält die laufende Version - auch von AutoCad - zur Bearbeitung der Vermessungsdaten auf dem Rechner und lädt dann die erhaltenen Ergebnisse in die neue Version. Die Frage ist, ob man diese neuen Versionen braucht? Meine Antwort: leider ja, da viele Kollegen sich diesem Trend nicht ausschließen, und dann plötzlich

Ergebnisse im Austausch nicht mehr kompatibel sind, weil sie mit verschiedenen Versionen abgespeichert wurden (down-kompatibel ist fast immer möglich, up-kompatibel fast nie!).

AutoCad, MicroStation, ArchiCad sind nur drei Programme, die mir im Laufe meines Arbeitslebens als Vermesser begegnet sind. Von diesen ist AutoCad am verbreitetsten, und zusätzliche Programme (BB, TachyCad) werden auch nur für ACAD gemacht. Auch „handgeschriebene“ Programme beziehen sich fast nur auf ACAD, da AutoCad eine eigene Programmiersprache¹, die relativ leicht zu erlernen sein soll, beinhaltet. Es ist nicht nur eine Sache des guten Geschmacks sondern auch eine Antwort auf die Frage: welches Programm benutzt mein Kollege, und der Kompromiss ist AutoCad.

Das einzige Austauschformat zwischen unterschiedlichen Programmen - *.dxf - ist hier mit Vorsicht zu genießen, da es auch versionsabhängig ist. Häufig wird die gesamte *.dxf-Datei nicht von einem anderen Programm vollständig gelesen, besonders bei 3D-Dateien kann es hier zu Irritationen führen.

Es gilt also, einen Standard aufzubauen, der sowohl Geräte als auch Computerprogramme einschließt.

Netzmessungen

Eine dauerhafte Sicherung der Messungsrohdaten scheint nur für die Vermessung der Grundlagennetze sinnvoll. Dies gilt sowohl für terrestrische als auch für GPS-Messungen. Für jedes Projekt sollten die Festpunktkoordinaten und die Festpunktbeschreibungen inkl. der Einmessungsskizzen gespeichert werden.

Objektpunkte

Ob es sinnvoll ist, die Koordinaten aller aufgemessenen Punkte dauerhaft zu sichern ist fraglich, denn entweder werden bei der Aufmessung alle relevanten Informationen zu einem Punkt mit eingegeben (was sehr aufwendig ist) und abgespeichert, oder es muss, um die Messung nachvollziehen zu können eine eindeutige Skizze (Feldriss) vorhanden sein, die dann ebenfalls dauerhaft (digitalisiert) gespeichert werden müsste.

Wenn eine dauerhafte Sicherung erfolgen soll, sollte dies im ASCII-Datenformat (*.txt, *.dat, *.csv o.ä.) erfolgen, da die meisten CAD-Programme diese in irgendeiner Form erkennen. Häufig müssen die Daten mit Zusatzprogrammen (s.o.) CAD-gerecht aufbereitet werden. Es gibt in diesem Fall auch keine Empfehlung, da die Programme nur bedingt kompatibel sind. Wie schon erwähnt, ist auch das *.dxf-Format nur mit Vorsicht zu benutzen, EXCEL-Dateien müssen auch wieder in *.txt-Dateien gespeichert werden, usw.

Man erreicht einen Standard nur dann, wenn alle Beteiligten die gleichen Programme der gleichen Version benutzen.

Um Zeichendateien, bei AutoCad *.dwg auszutauschen, empfehle ich die Dateien in einer Version (2000, 2002) abzuspeichern, die ohne Schwierigkeiten und Verluste auch mit einer neueren Version zu öffnen ist. Die meisten 3D-Daten lassen sich so verlustfrei austauschen.

¹ AutoCad lisp (*.lsp)

Quellen

Bauer, M.: Vermessung und Ortung mit Satelliten. Wichmann Verlag Heidelberg
Schimke, A.: Kartenprojektionen und Koordinatentransformationen
Zeiske, K.: Vermessen leicht gemacht. Leica Publikation
Herrmann K.: Bautechnische Vermessung. Dümmlers Verlag Bonn
Seckel/Hell/Schnuchel: Vermessungskunde und Bauaufnahme für Architekten.
Herbert Wichmann Verlag Karlsruhe
GPS Basics, Einführung in die GPS Vermessung, Leica Publikation
Gebrauchsanweisungen für Geräte beinhalten häufig gute Ratschläge
<http://www.olanis.de/knowhow/mapprj/index.shtml>
www.epsg.org

4.7.1 Terrestrische Messungen

- 4.7.1.1 GPS/GNSS
- 4.7.1.2 Photogrammetrie
- 4.7.1.3 Tachymetrie
- 4.7.1.4 Terrestrisches Laserscanning
- 4.7.2 Fernerkundung
- 4.7.2.1 LIDAR-Geländescans
- 4.7.2.2 Luftbild
- 4.7.2.3 Luftbildphotogrammetrie
- 4.7.2.4 Satellitenmessungen

S. Reinhold

Einsatz von Hard- und Software in der Praxis

Auf allgemeiner Ebene sind momentan die unter GoogleEarth einsehbaren Satellitenbilder eine gute Alternative zu kommerziellen Satellitenbildern. Die bei GoogleEarth verwandten Bilder stammen aus verschiedenen Quellen und haben eine unterschiedliche Auflösung. Diese schwankt von 30-15m pro Pixel im Fall der auf Landsat-Aufnahmen basierenden Grundbilder bis zu einer Auflösung von etwa 1m pro Pixel bei Detailausschnitten. Diese Bilder stammen vom Satelliten Quickbird und werden laufend in GoogleEarth integriert. Es lohnt sich daher immer wieder die interessierende Region anzuschauen.

Eine Übersicht über die Quickbird-Aufnahmen sowie den Zeitpunkt der Aufnahme lässt sich unter Layers/DigitalGlobe Coverage im GoogleEarth Menü abrufen.

GoogleEarth hat den Nachteil, dass die Bilder nur in einer verhältnismäßig schlechten Auflösung abgespeichert werden können und sie nicht georeferenziert sind. Eine Lösung ist ein Upgrade auf GoogleEarthPlus. Dieses kostet 20\$ pro Jahr und erlaubt es, eine bessere Auflösung abzuspeichern und GPS-Daten sowie geographische Positionen können aus .CSV-Dateien importiert werden.

Für die Nutzung von georeferenzierten Satellitenbildern besteht die Möglichkeit, Bilder der Landsat Satelliten 4,5 und 7 im Internet frei zu laden. Die

Daten des Satelliten Landsat ETM+ stammen aus dem Jahr 2000. Diejenigen von Landsat TM aus den 1990'er Jahren und die Bilder von Landsat MMS aus dem Zeitraum von 1972-1978.

BILD Aus: Eurimage Products and Services Guide

Um Bilder zu laden steuert man auf der Homepage landsat.org unter dem link 'Search for imagery' die freien LandsatOrtho Daten an. Mit dem dort vor-gegebenen Path-Row Finder kann man die entsprechenden Angaben zur interessierenden Region über ein interaktives Kartenmodul ermitteln. Wichtig ist es dazu den Popblocker (Internetexplorer: Extra/Popupblocker; Firefox: Extras-Einstellungen-Inhalt/Pop-up-Fenster blockieren) zu deaktivieren. Wichtig ist auch im Suchmodus die Kästchen WRS I und WRS II anzukreuzen und refresh map zu aktivieren. Nur so lassen sich dann mit dem Informations-Tool die entsprechenden Flugbahndaten ermitteln. Eine alternative Suchmöglichkeit bietet sich unter: http://landsat.usgs.gov/tools_wrs-2_shapefile.php. Dort sind ESRI-shp files herunter zu laden, die ebenfalls Path/Row Informationen enthalten.

Hat man die Angaben lassen sich bei <http://www.landsat.org/ortho/> die entsprechenden Daten ansteuern und kopieren. Die gezippten Daten müssen dann entzipppt werden und man erhält verschiedene Datensätze im Format Geo-Tiff. Diese sind georeferenziert im System WGS 1984.

Die Auflösung der Landsat Bilder ist unterschiedlich und liegt bei 30m bzw. 15m per Pixel.

BILD Aus: Eurimage Products and Services Guide

Für detailliertere Satellitenbilder mit hoher Auflösung stehen momentan nur kommerzielle Anbieter zur Verfügung. Dort können georeferenzierte Bilder mit einer Auflösung bis unter 1m pro Pixel erworben werden. Die folgende Tabelle gibt einen Überblick über die vorhandenen Systeme und die Quellen, über die Bildausschnitte und Preisinformationen zu erhalten sind.

Fotografische Sensoren

Satelliten	Beschreibung	Internet-Quelle
CORONA	Satellitenaufnahmen aus den 1960er und frühen 1970er Jahren der amerikanischen Spionagesatelliten CORONA, LANYARD und ARGON. CORONA Bilder der Missionen KH4 und 6 haben eine Auflösung von 2-3m. Es empfiehlt sich die Angaben in den Missionsdokumentationen zu lesen. Und Bilder in 7 Micron scannen zu lassen. Nicht georeferenziert!	Allgemeine Angaben finden sich unter: http://edc.usgs.gov/products/satellite/declass1.html#description Bildauswahl unter: http://edcns17.cr.usgs.gov/ EarthExplorer/ dort finden sich die CORONA Bilder unter der Angabe „declassified images“. Preis (2007): 30\$ pro Filmstreifen (die DVD ist jedoch recht teuer) http://edcns17.cr.usgs.gov/helpdocs/prices.html#CORONA
KFA-1000	Der russische Spionagesatellit KFA-1000 hat eine Auflösung von 1.5-3m. Die Bilder stammen aus den 1990er Jahren. Nicht georeferenziert!	Übersichtskarten und Bildauswahl sind erhältlich über http://www.sovinformsputnik.com/

Digitale Sensoren

Satelliten	Beschreibung	Internet-Quelle
LANDSAT	Amerikanische Multispektral-Satelliten, die seit 1972 aktiv sind. Die LANDSATS 1-3 hatten einen Multispektral Sensor (MSS) mit einer Auflösung von 80m. Die LANDSATS 4 and 5 haben MSS und Thematic Mapper (TM) Sensoren mit einer Auflösung von 30 oder 15m.	Übersicht bei http://landsat.org Kommerzielle Anbieter sind u.a. http://www.eurimage.com/index.html oder http://www.digitalglobe.com/ Preise (2007) ab 250 EURO http://www.eurimage.com/products/docs/eurimage_price_list.pdf
SPOT	SPOT. Französische Satelliten mit Multispektral (XS) Sensoren und einer Auflösung von 20m bis 10m.	Bilder und Preisangaben bei http://www.spotimage.fr/html/___.php
IKONOS 2	Satellit mit hochauflösenden Kameras, die Graustufen- und Farbbilder aufnehmen. Jedes Bild bildet eine Fläche von mindestens 11 x 11 km mit einer Auflösung von bis zu 0,82m ab. Es können auch Flächen von 60 x 60 km in einem Überflug aufgenommen werden können.	Bilder und Preisangaben bei http://www.euspaceimaging.com/ Preis ca. 30\$ pro qkm
QuickBird	QuickBird 2 ist ein kommerzieller Satellit zur Erdbeobachtung. Er wird von DigitalGlobe betrieben. Er hat eine Auflösung von 0,6m. Die Detailbilder in GoogleEarth sind Quickbirdaufnahmen seit 2001.	Bilder und Preisangaben bei http://www.digitalglobe.com/ oder http://www.eurimage.com/index.html Preis 16-41 \$ pro qkm (mindestens 272 qkm)

Quellen

http://www.dainst.org/medien/de/Nasca-BMBF_Programm.pdf
 David L. Kennedy, Declassified satellite photographs and archaeology in the Middle East: case studies from Turkey. *Antiquity* 72, Nr. 277 1998, 553-561.
 Graham Philip/Daniel Donoghue/Anthony Beck/N. Galiatsatos, CORONA

- satellite photography: an archaeological application from the Middle East. *Antiquity* 76, Nr. 291 2002, 109-118.
- Jason Ur, CORONA satellite photography and ancient road networks: A Northern Mesopotamia case study. *Antiquity* 77, Nr. 295 2003, 102-105.
- Wouter Gheyle/Raf Trommelmans/Jean Bourgeois/Rudi Goosens/Ignace Bourgeois/Alain De Wulf/Tom Wilkens, Evaluation CORONA: A case study in the Altai Republic (South Siberia). *Antiquity* 78, Nr. 300 2004, 391-403.
- M. Altaweel, The use of ASTER satellite imagery in archaeological contexts. *Archaeological Prospection* 12, 2005, 151-166.
- K.N. Wilkinson/Anthony Beck/Graham Philip, Satellite imagery as a resource in the prospection for archaeological sites in central Syria. *Geoarchaeology* 21, 2003, 735-750.
- Anthony Beck/Graham Philip/Maamun Abdulkarim/Daniel Donoghue, Evaluation of CORONA and IKONOS high resolution satellite imagery for archaeological prospection in western Syria. *Antiquity* 81, Nr. 311 2007, 176-190.

4.8 Geodatenanalyse

4.8.1 Geocodierung und Geoparsing

4.8.2 Geomorphometrie

4.8.3 Georeferenzierung

K. Heine, U. Kapp

GeoReferenzierung, d.h. Zuordnung von Koordinaten zu Bildpunkten auf Fotos und Plänen (Karten), die in Digitaler Form vorliegen. Mit der GeoReferenzierung erreicht man gleichzeitig eine Entzerrung dieser Grundlagen. Vorbedingung ist ein Programm, mit dem man diese Arbeit durchführen kann. Jedes GIS (Geoinformationssystem) hat notwendigerweise ein Modul für GeoReferenzierung.

Einsatz von Hard- und Software in der Praxis

Die GeoReferenzierung von Topographischen Karten ist in der Regel einfach, da Koordinaten normalerweise in Form eines Rasters auf den Karten vorhanden sind. Es wird komplizierter, wenn man mit diesen Koordinaten nicht arbeiten möchte. Dann wird es erforderlich, entweder vor Ort Vergleichspunkte (Referenzpunkte) zu messen oder mit anderen Programmen die vorhandenen Koordinaten in das gewünschte System zu transformieren. Viele GIS-Programme erlauben auch das. Ich habe Erfahrungen mit dem einfachen FUGAWI, das für die Bearbeitung der GPS-Daten der Handgeräte vorhanden ist.

Eine andere Möglichkeit, Referenzpunkte zu bekommen, bildet im Moment GOOGLE EARTH. Besonders in den Bereichen mit hoher Auflösung bekommt man eine ausreichend genaue Informationen. Zu berücksichtigen ist natürlich der Maßstab, in dem man später arbeiten möchte.

Die Anzahl der Referenzpunkte richtet sich nach dem Inhalt des Images. Liegt eine flächenfüllende Karte vor, reichen mindestens 4 Punkte in den Ecken der Karte. Zu empfehlen sind Kontrollpunkte; bei einer Karte würde ich die doppelte Anzahl an Punkten wählen, um auch bei der Entzerrung sicher zu sein.

Bei Fotos, die kein Raster vorgegeben haben, muss man daher mehr Punkte wählen, die das Foto bis an die Ränder der Darstellung bearbeiten können oder beschneidet das Image auf die Größe, die benötigt wird. Die Punkte bezieht man aus Messungen vor Ort oder aus einer Karte oder anderen Medien (GOOGLE EARTH). Es müssen auch Punkte innerhalb des Images bestimmt werden, um die Kontrolle über das Bild zu erhalten. 4 Punkte sind da nicht ausreichend, ich empfehle die doppelte Anzahl. Das richtet sich nach der Geometrie des Fotos.

Wenn verfügbar, sollten digitale Orthophotos bzw. Luftbildkarten an Stelle von Luftbildern verwendet werden, da diese bereits auf ein digitales Gelände-modell entzerrt sind. Bei ebenem Gelände kann eine Entzerrung gemäß Tabelle 1 vorgenommen werden, ohne dass dabei größere Lagegenauigkeiten hervorgerufen werden. Durch eine Entzerrung von Luftbildern von unebenem Gelände mit polynomiauen Ansätzen höherer Ordnung können keine Unstetigkeiten im Gelände wie beispielsweise steile Felshänge o.ä. berücksichtigt werden. Hier ist eine Entzerrung auf ein digitales Geländemodell vorzunehmen (s. Tab. 1).

Natürlich mangelt es auch hier nicht an Programmen, die diese Arbeiten durchführen können. Jedes GIS Programm hat ein Modul für die Georeferenzierung von Rasterdaten. Die Ergebnisse sind untereinander austauschbar, da das gleiche Dateiformat benutzt werden kann. Man kann also ein „world-tiff“ oder jpg, in ein anderes GIS Programm exportieren.

AutoCad Map oder der AutoCad Aufsatz PhoToPlan bieten auch die Möglichkeit der Affinen Transformation oder sogar der Polynominalen Entzerrung. Leider sind die neu entstandenen Rasterdaten nur in diesen Programmen verwendbar. Beim Export dieser Rasterdaten in GIS Programme müssen sie wieder neu referenziert werden.

Auch bei Anwendung der Digitalen Bildentzerrung bei der Bauaufnahme oder bei Grabungsfächern oder Grabungsprofilen kann eine Georeferenzierung durchgeführt werden. Die Referenzpunkte müssen eingemessen werden, wobei darauf zu achten ist, dass die Digitale Bildentzerrung nur 2-D einsetzbar ist. Um Strukturen mit unterschiedlicher Höhe mit diesem Verfahren zu bearbeiten, ist es notwendig, die Ebenen separat zu definieren und zu entzerren. PhoToPlan erlaubt die Montage eines Bildverbands, solange genügend verbindende Passpunkte vorhanden sind.

Die Tabelle mit der Übersicht der unterschiedlichen Entzerrungs-und Referenzierungsmethoden entnehmen Sie bitte Seite 28 des IT-Leitfadens des DAIs (http://www.dainst.org/sites/default/files/medien/de/IT-Leitfaden_Teil2_Praxisratgeber_v1_0_0-ENTWURF.pdf?ft=all)

Quellen

Alle Handbücher der GIS Programme, AutoCad Map, PhoToPlan etc.

<http://www.giub.uni-bonn.de/gistutor/>

4.8.4 Oberflächen- (DOM) und Geländemodellierung (DGM)

K. Lambers, M. Reindel

Bei Geländemodellen ist zwischen primären und sekundären Geländemodellen zu unterscheiden:

- a) primäre Geländemodelle

Aus Messung entstandene Geländemodelle sind über die Vermessungsdaten zu speichern.

b) sekundäre Geländemodelle

Aus primären Geländemodellen abgeleitete Geländemodelle (z.B. erworbene Geländemodelle) sind als Rasterdaten im TIFF-Format abzuspeichern.

Eine kurze Einführung

Um Oberflächen maßstabsgerecht darstellen zu können, müssen sie vorher durch geeignete Vermessungen aufgenommen werden. Dies kann durch Handvermessung geschehen oder aber durch den Einsatz moderner Messinstrumente. Je nach Art und Größe des Untersuchungsobjektes kommen unterschiedliche Methoden und Techniken zur Anwendung. Die Dokumentation der Oberflächen aller dieser Objekte erfolgt prinzipiell nach den gleichen Methoden. Die folgenden Ausführungen konzentrieren sich auf die Dokumentation und Darstellung von Geländeoberflächen.

Als Messinstrumente kommen für mittlere und große Objekte Theodoliten bzw. Tachymeter (mit elektronischer Distanzmessung) zum Einsatz. Moderne Messverfahren bedienen sich auch der Photogrammetrie (Vermessung in stereoskopisch aufgenommenen Bildern) und neuerdings des Laserscannings oder LIDAR (engl. light detection and ranging, s. u.). Allen Aufnahmeverfahren ist gemeinsam, dass sie Lagekoordinaten der vermessenen Objekte in einem zuvor definierten Vermessungssystem liefern. Für eine planimetrische Darstellung (ohne Höhenangaben) reichen Messwerte in X- und Y-Richtung aus. Sie ermöglichen zweidimensionale Darstellungen (2D). Will man jedoch die Oberfläche eines Objektes oder von Gelände räumlich darstellen, benötigt man auch die Höheninformation, das heißt einen Z-Wert. Die Grundlage einer räumlichen Darstellung einer Geländeoberfläche ist somit eine Sammlung von Punkten mit X-, Y- und Höheninformation in einem Koordinatensystem.

Im Gegensatz zu einer echten dreidimensionalen Darstellung (3D), in der X-, Y- und Höhenkoordinaten zu einem Volumenmodell verarbeitet werden, werden in sogenannten 2,5D-Darstellungen 2D-Daten mit einer zusätzlichen Höheninformation versehen, die nicht als Koordinate, sondern als Attribut gespeichert wird. Dies bedeutet, dass jedem XY-Punkt nur ein Höhenwert Z zugeordnet werden kann, was die Modellierung von Senkrechten oder Überhängen ausschließt. Geoinformationssysteme, die ursprünglich für großflächige geographische Anwendungen entwickelt wurden, verarbeiten bis heute in der Regel nur 2,5D-Daten, während in CAD-Anwendungen, die für die Objektmodellierung entwickelt wurden, 3D-Informationen verwendet werden. Die Entwicklung geht jedoch in Richtung einer Konvergenz beider Systeme, so dass in Zukunft voll 3D-fähige GIS zum Standard werden dürften.

Vermessung eines Grabungsgeländes Die Aufnahme von Messdaten mit dem Ziel, Gelände zu modellieren, spielt in der archäologischen Praxis zum einen bei der Dokumentation von Grabungsorten vor dem Beginn oder während der Ausgrabungen und zum anderen bei der Durchführung von Regionalstudien mit Hilfe von Geoinformationssystemen eine Rolle. Grabungsgelände werden in der Regel durch tachymetrische Vermessung aufgenommen, während die Topographie größerer Gebiete durch erworbene digitalen Kartendaten, Fernerkundungsdaten oder von Luftbildern erarbeitet wird.

Der erster Schritt bei der Vermessung eines Grabungsgeländes ist die Anlage eines Messnetzes. Dieses wird zumeist genordet, oft aber auch an den zu erwartenden Grabungsbefunden ausgerichtet. In der Regel wird zunächst ein Ausgangspunkt und eine Grundlinie angelegt und von dort das Messnetz aufgebaut. In anderen Fällen wird von dem Ausgangspunkt ein Polygonzug angelegt, von dem aus weitere Geländepunkte eingemessen werden.

Das Messnetz sollte an ein bestehendes übergeordnetes Messnetz angebunden werden. Bezugspunkte können vermarkte Messpunkte eines Landesvermessungsnetzes oder in abgelegeneren Regionen Triangulationspunkte von Kartierungsprojekten oder ähnliches sein. Die Koordinaten der Hauptmesspunkte können auch durch präzise GPS-Messungen bestimmt werden. Häufig werden bei der Anlage von Grabungen willkürliche Messpunkte festgelegt, die durch spätere Messungen an die übergeordneten Messnetze angebunden werden (siehe hierzu auch Kapitel 2).

Ausgehend von den Basispunkten des Messnetzes werden mit dem Tachymeter Geländepunkte aufgemessen. Bei der Auswahl der Punkte ist es wichtig sich zu vergegenwärtigen, welche Art und welcher Maßstab der Darstellung des Geländes angestrebt wird. Grundsätzlich sollten diejenigen Punkte aufgenommen werden, an denen sich die Geländeneigung oder der Verlauf einer gedachten Höhenlinie (Linie, die sich aus Punkten gleicher Höhe zusammensetzt) ändert. Das heißt, je unregelmäßiger die Geländeoberfläche ist und je detaillierter die Geländeoberfläche wiedergegeben werden soll, umso mehr Punkte pro gegebener Fläche sind aufzunehmen.

Die Punkte sind so dicht zu setzen, dass die relevanten Geländeformen in der graphischen Darstellung im angestrebten Maßstab wiedergegeben werden. Es ist einleuchtend, dass ein etwa 30 cm breiter Mauerzug, der sich im Gelände durch eine leichte Erhebung abzeichnet, nicht durch Punkte abgebildet werden kann, die im Abstand von 1 m gemessen wurden. Vielmehr muss zumindest der Beginn der Geländewölbung, der Scheitelpunkt über der Mauer und der Endpunkt der Geländewölbung vermessen werden. Bruchkanten müssen gesondert vermessen werden. Sie können bei der Auswertung der Messdaten mit Computerprogrammen speziell behandelt werden.

Regionale Geländemodelle Ist das Untersuchungsgebiet größer als ein Grabungsgelände, werden dafür benötigte Geländemodelle üblicherweise nicht selbst erzeugt, sondern aus anderen Quellen erworben. Bezugsquellen für digitale Geländemodelle sind je nach Land staatliche Vermessungsämter, Universitäts- oder Forschungsinstitute für Geographie, Geodäsie, Kartographie oder Geophysik, Luft- und Raumfahrtagenturen oder das Militär.

Grundlage für die Erzeugung von Geländemodellen sind Fernerkundungsdaten, die entweder mit passiven Sensoren (Luft- und Satellitenbilder) oder mit aktiven Sensoren (Radar- oder Lidardaten) aufgenommen werden (siehe hierzu die Beiträge von Sabine Reinhold). Bilddaten werden mit photogrammetrischen Methoden ausgewertet. In überlappenden Bereichen benachbarter Bilder werden stereoskopisch homologe Punkte an der Erdoberfläche gemessen (engl. matching). Entweder werden ähnlich wie bei der terrestrischen Geländeversetzung gezielt Einzelpunkte und ggfs. Bruchkanten gemessen, oder es werden bei automatisierten Verfahren Punkte in gleichmässigen Abständen gemessen. Photogrammetrische Auswertungen von Luftbildern bilden bis heute in vielen Län-

dern die Grundlage für die Produktion und Nachführung von topographischen Karten und für die Generierung von Geländemodellen.

Radar- und Lidardaten liefern demgegenüber direkte Informationen über die Distanz der gemessenen Punkte zum Sensor. Ein auf Radar (engl. radio detection and ranging) beruhendes Geländemodell der Shuttle Radar Topography Mission (SRTM) ist praktisch weltweit frei verfügbar und in vielen Gegenden die einfachste Möglichkeit, digitale Geländemodelle zu beziehen. Die geringe Auflösung von 90 m sowie Lücken und große Höhenfehler in gebirgigem Gelände sind jedoch limitierende Faktoren für die Verwendbarkeit. Vermessungen mit flugzeuggestütztem LIDAR (engl. light detection and ranging), bei dem die Erdoberfläche in hoher Dichte durch einen Laserstrahl gescannt wird, werden in Europa immer mehr zu einem Standardverfahren der Landesvermessung, sind jedoch in anderen Ländern oft noch nicht verfügbar.

Zur korrekten Georeferenzierung der Fernerkundungsdaten dienen GPS-Messungen, oft in einer Kombination von Positionsmessungen an Bord der Sensorplattform (z.B. GPS an Bord eines Flugzeuges gekoppelt mit INS, engl. inertial navigation system) mit Einmessungen von Kontrollpunkten am Boden, die in den Daten erkennbar sein müssen. Die GPS-Messungen dienen der Überführung der gemessenen Punkte von einem lokalen in ein globales Koordinatensystem (Georeferenzierung).

Erworbenen Geländemodelle sind rechnerische Ableitungen von tatsächlich erhobenen Messdaten. Wie schon bei anderen Messdaten, sollten nach Möglichkeit auch die Rohdaten gespeichert werden. Beim Kauf von Standard-Produkten ist dies üblicherweise nicht möglich, wohl aber bei der Beauftragung von speziellen Geländemodellen, z.B. Lidar-Überfliegungen.

Modellierung Zur Modellierung einer durchgehenden Oberfläche auf der Grundlage der vermessenen Punkte müssen die zwischen den Messpunkten liegenden Geländepunkte durch rechnerische Verfahren verknüpft werden. Dazu werden zunächst die Einzelpunkte zu einer aus Dreiecken bestehenden Oberfläche vermascht. Diese liegt im Vektorformat vor (engl. TIN: triangulated irregular network). Durch Interpolation werden die Vektordaten ggf. in ein Rasterformat (z.B. Grid) mit einer festen Maschenweite überführt. Hierzu werden verschiedene mathematische Verfahren angewandt. Die Einzelheiten dieser Verfahren werden in den relevanten Computerprogrammen und Lehrbüchern erläutert, müssen jedoch vom Archäologen nicht im Detail nachvollzogen werden können. Wichtig ist jedoch, die Modellierungen mit den verschiedenen Verfahren zu testen, um entscheiden zu können, welche Methode die tatsächliche Geländeoberfläche am realistischsten darstellt. Die Maschenweite oder Zellengröße ist ein übliches Maß für die Auflösung eines Geländemodells. Während einige GIS-Programme (z.B. ArcGIS) auch TINs verarbeiten können, können viele andere nur mit Raster-Geländemodellen umgehen.

Je nach Platzierung der zu Grunde liegenden Messpunkte bilden Geländemodelle verschiedene Dinge ab. Als Oberbegriff dient die Bezeichnung Digitales Höhenmodell / DHM (engl. digital elevation model / DEM). Man unterscheidet zwei Typen von DHMs: 1. das Digitale Oberflächenmodell / DOM (engl. digital surface model / DSM), das die Erdoberfläche inklusive aller darauf befindlichen Objekte wie Häuser, Vegetation, etc. abbildet, und 2. das Digitale Geländemodell / DGM (engl. digital terrain model / DTM), das nur die Erd-

oberfläche abbildet. Bei der eigenen Vermessung des Grabungsgeländes wird man üblicherweise ein DGM erzeugen. Auch bei erworbenen Geländemodellen sind DGMs den DOMs vorzuziehen, da in archäologischen Untersuchungen üblicherweise die Geländegestalt ohne moderne Bebauung und Vegetation interessiert. Bei Geländemodellen mit geringer Auflösung wie dem SRTM-DHM sind die Unterschiede jedoch zu vernachlässigen.

Einsatz von Hard- und Software in der Praxis

Für die Verarbeitung und die Interpolation der Messpunkte stehen unterschiedliche Computer-Programme zur Verfügung, darunter auch speziell auf die Messgeräte angepasste Software der Hersteller von Vermessungsgeräten (Zeiss, Leica, Wild, Sokkia, Trimble, etc.). In der archäologischen Praxis wird zur Verarbeitung und Umzeichnung von echten 3D-Messdaten zumeist das Programm AutoCAD verwendet (<http://www.autodesk.de>). Zur Generierung von Höhenlinien und 3D-Modellen können Zusatzmodule oder erweiterte Versionen erworben werden. Zur Modellierung von 2,5D-Geländeoberflächen kann auch jedes GIS-Programm verwendet werden. Im Rahmen unserer Arbeiten wurden die Höhenlinien und Geländemodelle in der Regel mit dem Programm Surfer (<http://www.ssg-surfer.com/>) generiert. Surfer ist einfach zu handhaben und bietet eine Vielzahl von Möglichkeiten der Verarbeitung und Analyse archäologischer Daten. Unter anderem können auch Daten geophysikalischen Prospektions einfach eingelesen und über die Geländemessdaten projiziert werden. Surfer ermöglicht auch die schnelle und einfache Überprüfung der Messergebnisse nach der Übertragung der Daten auf den Computer, wenn der Tachymeter nicht ohnehin mit einem Bildschirm ausgestattet ist. Die Koordinatenlisten lassen sich nachbearbeiten, Bruchkanten einfügen und nicht benötigte Messpunkte ausblenden. Die Höhenlinienpläne können als DXF-Dateien in AutoCAD exportiert werden. Schattierte oder farblich gestaltete Geländemodelle lassen sich in verschiedenen Graphikformaten (tiff, jpeg, bmp, etc.) exportieren und als solche ebenfalls in AutoCAD einbinden.

Erworbenen Geländemodelle liegen üblicherweise in einem Rasterformat vor, in dem einer durch eine XY-Eckkoordinate definierten Zelle mit einer festgelegten Seitenlänge ein Höhenwert zugeordnet wird. Damit gleichen Raster-Geländemodelle im Prinzip Bilddaten, nur dass statt eines Farbwertes ein Höhenwert gespeichert wird. Deshalb können Geländemodelle z.B. auch als TIFF vorliegen. Ein anderes übliches Format ist ASCII; daneben gibt es proprietäre Formate wie z.B. ESRI Grid. Die Transformation von Raster-Geländemodellen von einem Format in ein anderes in einem GIS-Programm stellt üblicherweise kein unüberwindbares Problem dar, so dass hier kein Format empfohlen wird, zumal bei Standard-Produkten das Format oft bereits festgelegt ist.

Je nach gewähltem Ausgabemedium werden verschiedene Verfahren der Darstellung der Geländeoberflächen gewählt. Soll das Ergebnis auf Papier, also in 2D auf einem Plan als Arbeitsdokument oder für die Publikation ausgegeben werden, wird die Darstellung in Form von Höhenlinien, mit Schattierungen oder unterschiedlicher Farbgebung gewählt. AutoCAD-Dateien (*.dwg) lassen sich häufig nur mit Schwierigkeiten in andere vektorbasierte Programme (z.B. CorelDraw oder Adobe Illustrator) zur weiteren Bearbeitung exportieren. Für die Einbindung in Publikationen können AutoCAD-Pläne und -Zeichnungen jedoch als PDF-Dateien ausgegeben, in JPEG-Dateien umgewandelt und mit Bildbe-

arbeitungsprogrammen ergänzt oder verändert werden. Am Computer können die räumlichen Modelle dargestellt, bewegt und von unterschiedlichen Standpunkten aus betrachtet werden.

GIS-Programme bieten die Möglichkeit, die in Geländemodellen enthaltene Höheninformation in verschiedener Form in 2D darzustellen, z.B. als Höhenlinien, Grauwerte oder Farbabstufungen. Das Layout von Karten ist in den verschiedenen Programmen unterschiedlich einfach zu handhaben, jedoch sind die grundlegenden Funktionen wie die automatische Platzierung eines Koordinatenrahmens, eines Maßstabes etc. überall vorhanden, so dass Karten im GIS-Programm erzeugt und entweder direkt ausgedruckt oder in ein Standard-Graphikformat (Vektor oder Raster) exportiert werden können.

Quellen

- Archaeology Data Service 2007: Guides to Good Practice.
<http://ads.ahds.ac.uk/project/goodguides/g2gp.html>
- Bill, Ralf 1999: Grundlagen der Geo-Informationssysteme, Band 2: Analysen, Anwendungen und neue Entwicklungen. 2. Aufl. Heidelberg: Wichmann. Kapitel 2.5: Digitales Geländemodell (DGM).
- Conolly, James & Mark Lake 2006: Geographical Information Systems in Archaeology (Cambridge Manuals in Archaeology). Cambridge: Cambridge University Press. Kapitel 6: Building Surface Models.
- Howard, Phil 2007: Archaeological Surveying and Mapping: Recording and Depicting the Landscape. London: Routledge.
- Wheatley, David & Mark Gillings 2002: Spatial Technology and Archaeology: The Archaeological Applications of GIS. London: Taylor & Francis. Kapitel 5: Digital Elevation Models.

4.8.5 Visualisierung und Kartierung

4.9 Geophysik

4.9.1 Geoelektrik

4.9.2 Geomagnetik

4.9.3 Georadar

4.10 Materialaufnahme

4.10.1 3D-Scanning

(DFG Digitalisierung hat auch einen Abschnitt dazu)

4.10.2 Nahbereichsphotogrammetrie

4.10.3 RTI

4.11 Materialwissenschaftliche Archäometrie

4.11.1 Anorganische Materialien

4.11.1.1 Gesteine

- 4.11.1.2 Metalle
- 4.11.1.3 Silikatische Materialien
- 4.11.2 Methoden
 - 4.11.2.1 Bildgebende Verfahren
 - 4.11.2.2 Chemische Verfahren
 - 4.11.2.3 Isotopenuntersuchung
 - 4.11.2.4 Physikalische Verfahren
- 4.11.3 Organische Materialien
- 4.12 Numismatik
- 4.13 Oberflächenbegehung (Survey)
- 4.14 Textwissenschaften und Schriftzeugnisse
 - 4.14.1 Sprachen und Zeichensysteme
 - 4.14.1.1 Ägyptisch
 - 4.14.1.2 Akkadisch
 - 4.14.1.3 Aramäisch
 - 4.14.1.4 Griechisch
 - 4.14.1.5 Hebräisch
 - 4.14.1.6 Hethitisch
 - 4.14.1.7 Latein
 - 4.14.1.8 Sumerisch
 - 4.14.2 Antike Objekte mit Texten
 - 4.14.2.1 Gefäße
 - 4.14.2.2 Inschriften
 - 4.14.2.3 Manuskripte
 - 4.14.2.4 Papyri
 - 4.14.2.5 Siegel
 - 4.14.2.6 Tontafeln
 - 4.14.3 Literarische Schriftquellen
 - 4.14.4 Veröffentlichung und Archivierung
 - 4.14.4.1 Wissenschaftliche Editionen
 - 4.14.4.2 Schnittstellen zu Textsammlungen
 - 4.14.4.3 Kollaborative Arbeitsumgebungen
 - 4.14.4.4 Publikation
 - 4.14.4.5 Lizenzierung

A | Versionshistorie

- Version 0.9 (18.02.2014): Erste veröffentlichte Fassung

B | Autorenverzeichnis

- Reinhard Förtsch, DAI Berlin
- Peter Grunwald, ehemals DAI Berlin
- Katja Heine, BTU Cottbus
- Maurice Heinrich, DAI Berlin - IANUS
- Kerstin Hofmann, Topoi Berlin
- Sabine Jahn, DAI Berlin - IANUS
- Ulrich Kapp, ehemals DAI Berlin
- Rainer Komp, DAI Berlin
- Susanne Kurz, HKI Köln
- Karsten Lambers, Universität Bamberg
- Armin Müller, DAI Berlin
- Knut Rassmann, RGK Frankfurt
- Markus Reindel, KAAK Bonn
- Sabine Reinhold, DAI Berlin
- Felix Schäfer, DAI Berlin - IANUS
- Anne Sieverling, DAI Berlin - IANUS
- Manfred Thaller, HKI Köln
- Martina Trognitz, DAI Berlin - IANUS
- Ulrike Wulf-Rheidt, DAI Berlin

C | Glossar

Adobe RGB ist ein häufig verwendetes RGB-Farbraum, der 1998 von Adobe veröffentlicht wurde.

AIFF (Audio Interchange File Format) ist ein Dateiformat zum Speichern von Audiodaten. Es wurde von der Firma Apple entwickelt und wird als Standard-Audioformat auf dem Macintosh eingesetzt. Siehe auch: <http://www.digitalpreservation.gov/formats/fdd/fdd000005.shtml>

AMP Apache-Server, MySQL oder PostgreSQL Datenbank, PHP, Perl oder Python-Skriptsprache ist ein Akronym für den kombinierten Einsatz von Programmen, um dynamische Webseiten zur Verfügung zu stellen. Die einzelnen Komponenten des AMP-Systems können durch ähnliche Komponenten ersetzt werden.

ASCII (American Standard Code for Information Interchange) ist eine 7-Bit-Zeichenkodierung und bildet die US-Variante von ISO 646 sowie die Grundlage für spätere mehrbitige Zeichensätze und -kodierungen. Die Zeichen umfassen das lateinische Alphabet in Groß- und Kleinschreibung, die zehn arabischen Ziffern sowie einige Satz- und Steuerzeichen.

Auflösung gibt die Punktdichte für ein physikalisches Wiedergabemedium an. Sie wird üblicherweise in Punkten (dots per inch; dpi), Pixeln (pixel per inch; ppi) oder Linien (lines per inch; lpi) pro Zoll (inch) angegeben.

AutoCAD ist Teil der CAD-Produktpalette von Autodesk zum Erstellen von 2D- und 3D-Zeichnungen mit einem PC.

Baseline-TIFF ist eine Untermenge gültiger TIFF-Formate, die jedes TIFF-fähige Programm verarbeiten können sollte. Aktuell ist die Version 6.0.

Bildpunkt siehe Pixel.

Bit ist die kleinste digitale Informationseinheit und kann entweder den Wert 0 oder 1 haben. Der Name ist aus *binary digit* zusammengesetzt.

Bitstream ist eine Folge von Bits, die einen Informationsfluss repräsentieren. Es handelt sich um ein serielles Signal.

BLOB (Binary Large Object) ist ein großes binäres und damit für die Datenbank nicht weiter strukturiertes Objekt, beziehungsweise Felddaten (z.B. Bilddateien).

BOM (Byte Order Mark) als Byte Order Mark (dt. "Bytereihenfolge-Markierung") wird das Unicode-Zeichen an Position U+FEFF (zero width no-break space) bezeichnet, wenn es verwendet wird, um die Byte-Reihenfolge einer in UTF-16 oder UTF-32 kodierten Unicode Zeichenkette anzugeben und/oder um den entsprechenden Text als in UTF-8, UTF-16 oder UTF-32 kodiert zu markieren.

CAD (Computer Aided Design) Rechnerunterstützte Konstruktion.

CD (Compact Disc) ist ein scheibenförmiges, optisches Speichermedium.

CMYK ist ein subtraktives Farbmodell. Es bildet die technische Grundlage des Vierfarbendrucks. Die Abkürzung steht für die Farben Cyan, Magenta, Gelb (Yellow) und den Schwarzanteil für die Farbtiefe (Key). CMYK-Farträume enthalten weniger Farben, als RGB-Farträume.

Codec Kunstwort aus engl. coder und decoder, ein Verfahren bzw. Programm, das Daten oder Signale digital kodiert und dekodiert.

CSV (Comma Separated Values) ein Dateiformat, bei dem einzelne Felder durch ein bestimmtes Trennzeichen z.B. durch ein "," oder ein ";" von einander getrennt werden.

DAT (Data File) ein Dateiformat mit sehr unterschiedliche Verwendung, meist als Container für binäre Daten.

dBASE-Format dBASE war das erste weit-genutzte Datenbankverwaltungssystem für Mikrocomputer. Die Basisidee des dBASE-Systems ist, die Tabellen einer Datenbank in speziell strukturierten Files zu halten.

DBF (Data Base File) Datenbank im dBASE-Format.

DNG (Digital Negative) ein offenes Format, das von Adobe speziell für die Speicherung und Langzeitarchivierung von Kamerarohdaten (RAW) entwickelt wurde. Es werden die Metadaten-Standards Exif, IPTC-NAA und XMP unterstützt.

DVD (Digital Versatile Disc) die DVD ist ein digitales Speichermedium, das einer CD ähnelt, aber über eine deutlich höhere Speicherkapazität verfügt.

DWG (Drawing File) ein AutoCAD Dateiformat für Zeichnungen, das kontinuierlich an die Anforderungen der jeweiligen AutoCAD-Versionen angepasst und erweitert wird. Die eingeschränkte Kompatibilität des DWG-Dateiformates zu älteren AutoCAD-Versionen kann durch die Verwendung des DXF-Dateiformates und den Einsatz von externen Konverterprogrammen teilweise umgangen werden.

DXF (Drawing Exchange File) Die DXF-Schnittstelle ist eine proprietäre Schnittstelle des Herstellers Autodesk und unterliegt keinem neutralen Normungsausschuss, die Dokumentation für DXF ist aber frei verfügbar. Sie ist ein in ASCII-Zeichen lesbares Abbild der binär abgespeicherten DWG.

ERD (Entity Relationship Diagram) die grafische Darstellung von Entitätsarten und Beziehungstypen wird Entity-Relationship-Diagram (ERD) oder ER-Modell genannt. Das ER-Modell kann bei der Erstellung von Datenbanken genutzt werden. Hierbei wird mit Hilfe von ER-Modell zunächst die Konzeption der Datenbank vorgenommen, auf deren Grundlage dann die Implementierung der Datenbank erfolgt.

ESRI-Shape Das Dateiformat Shapefile (oft Shapedaten oder Shapes genannt) ist ein von ESRI ursprünglich für ArcView entwickeltes Format für Geodaten. Ein Shapefile ist keine einzelne Datei, es besteht aus mindestens drei Dateien:

- .shp dient zur Speicherung der Geometriedaten
- .shx dient als Index der Geometrie zur Verknüpfung der Sachdaten (auch Attributdaten genannt)
- .dbf Sachdaten im dBASE-Format

Exif (Exchangeable Image File Format) (offizielle Abkürzung ist Exif, nicht EXIF) ist ein Standard der Japan Electronic and Information Technology Industries Association (JEITA) für die Speicherung von Metadaten.

Farbmodell ist ein mathematisches Modell, das üblicherweise mit Hilfe von Zahlentupeln beschreibt wie Farben dargestellt werden können.

Farbraum ist die dreidimensionale Abbildung eines Farbmodells.

Farbtiefe gibt die Anzahl der Bits an, die den Farbwert eines Pixels speichern. Ein Bit kann dabei 2^1 , also zwei Farbwerte (z.B. Schwarz und Weiß) speichern. Die Anzahl der darstellbaren Farbwerte steigt mit der Anzahl der Bits exponentiell. So können mit 8 Bits bereits 2^8 also 256 Farbwerte und mit 24 Bits schon $2^{24} = 16.777.216$ Farbwerte dargestellt werden.

Generationsverlust bezeichnet die Abnahme der Qualität von einer Kopie zur nächsten. Gerade bei verlustbehafteten Formaten, wie beispielsweise JPEG entstehen beim Speichern Fehler, die sich mit jeder weiteren Kopie der Kopie fortpflanzen und durch neue ergänzt werden. Vorbeugen kann man diesem Phänomen, indem man möglichst verlustfreie Formate verwendet.

Geo-Tiff ist ein georeferenziertes TIFF. Die Besonderheit gegenüber dem normalen TIFF-Format liegt darin, dass spezielle Daten über die Georeferenz zusätzlich zu den sichtbaren Rasterdaten in die Bilddatei eingebettet werden. Dazu zählen Koordinaten zur Georeferenzierung des Bildausschnitts sowie zur verwendeten Kartenprojektion: Die Datei enthält spezifische Angaben über das Koordinatenreferenzsystem.

GIF (Graphics Interchange Format) ist ein proprietäres Dateiformat zur Speicherung von Bilddaten, das von Compuserve entwickelt wurde. Dieses Format ist im Internet besonders verbreitet und bietet eine verlustfreie Komprimierung und nur eine Farbtiefe von 8 Bit, also 256 Farben, an. Metadaten können nur eingeschränkt in diesem Dateiformat gespeichert werden. Es wird empfohlen stattdessen PNG oder TIFF zu verwenden.

GIS (Geoinformationssystem) ein rechnergestütztes Informationssystem, mit dem raumbezogene Daten digital erfasst und redigiert, gespeichert und reorganisiert, modelliert und analysiert sowie alphanumerisch und grafisch präsentiert werden können.

Header bezeichnet in der IT den Dateikopf, also die Daten am Anfang eines Datenblocks, in dem üblicherweise Metadaten gespeichert werden. Beispielsweise werden Metadaten für Bilder mit Hilfe des Exif-Formats in den Header der Bilddatei geschrieben.

ICC (International Color Consortium) es wurde 1993 von acht Industrieunternehmen gegründet um eine Vereinheitlichung der Farbmanagementsysteme für alle Betriebssysteme und Softwarepakete zu erreichen. Weitgehend bekanntes Ergebnis der Bemühungen des ICC ist ein Standard zur Beschreibung von Farbprofilen.

IIM (Information Interchange Model) Ein Standard zur Speicherung von Metadaten in Bilddateien, der 1990 vom International Press Telecommunications Council und der Newspaper Association of America (NAA) entwickelt wurde und ein Vorläufer des IPTC-NAA Standards ist. Die letzte Version, 4.1, stammt von 1997.

IPTC-NAA (kurz auch nur IPTC) ist ein Standard zur Speicherung von Metadaten in Bilddateien. Er wurde vom International Press Telecommunications Council (IPTC) zusammen mit der Newspaper Association of America (NAA) entwickelt. Vorläufer dieses Standards ist der IIM-Standard.

ISO (International Organization for Standardization) eine internationale Vereinigung von Normungsorganisationen. Sie erarbeitet internationale Normen in allen Bereichen mit Ausnahme der Elektrik und der Elektronik, für die die Internationale elektrotechnische Kommission (IEC) zuständig ist, und mit Ausnahme der Telekommunikation, für die die Internationale Fernmeldeunion (ITU) zuständig ist.

IT (Informationstechnologie) ein Oberbegriff für die Informations- und Datenverarbeitung sowie für die dafür benötigte Hard- und Software. Häufig wird auch die englisch ausgesprochene Abkürzung IT verwendet.

JPEG (Joint Photographic Experts Group) ist ein Dateiformat zur Speicherung von Bilddaten, das verlustbehaftete Komprimierung verwendet und eine Farbtiefe von 32 Bit anbietet. Es wird in der Norm ISO/IEC 10918-1 bzw. CCITT Recommendation T.81 beschrieben und eignet sich *nicht* für die Langzeitarchivierung. Metadaten können im Exif- oder IPTC-NAA-Format gespeichert werden.

Komprimierung (auch Kompression) ist die Reduzierung der Dateigröße mit Hilfe verschiedener Algorithmen. Es gibt verlustfreie und die verlustbehaftete Komprimierungsmethoden.

Konvertierung ist die Überführung eines Dateiformates in anderes Format. Konvertierung kann verlustbehaftet sein.

LZW (Lempel-Ziv-Welch-Algorithmus) ist ein Algorithmus zur verlustfreien Komprimierung von Bilddateien. Bis 2004 war diese Methode nur eingeschränkt verwendbar, da Patente darauf bestanden. Diese Patente sind inzwischen ausgelaufen, weshalb LZW-Komprimierung frei verwendet

werden kann. Allerdings wurde die Verwendung in der Langzeitarchivierung noch nicht ausreichend erprobt.

Metadaten sind Informationen über eine Datei oder ein Dokument. Sie umfassen sowohl technische (Dateiname, Dateigröße etc.) als auch inhaltliche Angaben, wie z.B. Schlagworte. Bei einem Foto beinhalten Metadaten beispielsweise Informationen über den Fotografen, die verwendete Ausrüstung, den Aufnahmeort etc.

Motion JPEG (MJPEG) ist ein Video-Codec, bei dem jedes Einzelbild separat als JPEG-Bild komprimiert wird.

MPEG (Moving Picture Experts Group) (engl. "Expertengruppe für bewegte Bilder") ist eine Gruppe von Experten, die sich mit der Standardisierung von Videokompression und den dazugehörigen Bereichen, wie Audiodatenkompression oder Containerformaten, beschäftigt. Umgangssprachlich wird mit "MPEG" meistens nicht die Expertengruppe, sondern ein spezieller MPEG-Standard bezeichnet.

OAIS (Open Archival Information System) Offenes Archiv-Informationssystem (ISO-Standard 14721:2003). Der Grund für die Entwicklung dieses Modells bestand in der Einsicht, dass elektronisch archivierte Dokumente nach längerer Zeit aus vielfältigen Gründen nicht mehr lesbar sein könnten. Das Referenzmodell beschreibt ein Archiv als Organisation, in dem Menschen und Systeme zusammenwirken, um einer definierten Nutzerschaft Archivgut verfügbar zu machen. Die Implementierung eines OAIS-konformen Archivs ist dabei jedoch nicht festgelegt. "Offen" bedeutet, dass die Entwicklung des OAIS sich in offenen Foren abspielt. Dies bezieht sich nicht auf den uneingeschränkten Zugang zu einem Archiv.

OCR (Optical Character recognition) ist die Bezeichnung für den automatisierten Prozess, bei dem eingescannte Bilder von geschriebenem Text (entweder gedruckt oder handgeschrieben) in einzelne Buchstabenzeichen umgewandelt werden.

ODF (Open Document Format) ein offener Standard für Dateiformate von Bürodokumenten wie Texten, Tabellendokumenten, Präsentationen, Zeichnungen, Bildern und Diagrammen. Er wurde ursprünglich von Sun entwickelt, durch die Organization for the Advancement of Structured Information Standards (OASIS) als Standard spezifiziert und 2006 als internationale Norm ISO/IEC 26300 veröffentlicht.

PCM (Puls-Code-Modulation) ein Verfahren, um ein analoges Signal in ein digitales Signal bzw. Binärcode (Bitstream) umzusetzen. Es wird für Audio- und Video-Signale verwendet.

PDF (Portable Document Format) ein plattformübergreifendes Dateiformat für Dokumente, das von der Firma Adobe Systems entwickelt und 1993 veröffentlicht wurde.

PDF/A ist eine Normreihe der International Organization for Standardization (ISO) zur Verwendung des Portable Document Format (PDF) für die Langzeitarchivierung elektronischer Dokumente. Einzige verabschiedete Norm, mit Bezug auf die PDF Version 1.4, ist PDF/A-1. Veröffentlicht als ISO 19005-1:2005, legt PDF/A-1 Anforderungen an ein norm-konformes PDF fest und regelt die Verwendung von PDF/A unter anderem hinsichtlich der Bildschirm- und Druckausgabe.

Pixel ist ein Bildpunkt einer Rastergrafik und das kleinste Element darin, das kontrolliert werden kann.

PNG (Portable Network Graphics) ist ein Dateiformat zur Speicherung von Bilddaten. Es bietet eine verlustfreie Komprimierung, hat eine Farbtiefe von 32 Bit und ermöglicht die Speicherung von Transparenzen. Das Format ist primär für die Verwendung im Internet gedacht, weshalb auch nur das RGB-Farbmodell unterstützt wird. Exif-Daten können nicht gespeichert werden. Das Format eignet sich nicht für digitale Fotos.

Rastergrafik (auch Pixelgrafik) ist ein digitales Bild, das mittels rasterförmig angeordneter Pixel beschrieben wird. Jedem Pixel ist dabei ein Farbwert zugeordnet. Rastergrafiken haben eine fixe Größe und Auflösung und sind daher nicht skalierbar. Rastergrafiken können sein: Digitale Fotografien jeder Art, Satellitenbilder, digitalisierte Bilder (Scans), Screenshots sowie digitale Originalbilder und -grafiken.

RAW ist ein jeweils kamera-, modell- und herstellerspezifisches Dateiformat von Digitalkameras, bei dem die Kamera die Daten nach der Digitalisierung weitgehend ohne Bearbeitung auf das Speichermedium schreibt. Die Schreibweise RAW hat sich analog zur Schreibweise Raw eingebürgert.

RGB ist ein additives Farbmodell, in dem die Farben durch mischen der drei Grundfarben Rot, Grün und Blau dargestellt werden. Übliche RGB-Farträume sind sRGB und Adobe RGB.

SHP eine zur Speicherung der Geometriedaten. Es ist Bestandteil des Dateiformats ESRI-Shape.

SHX dient als Index der Geometrie zur Verknüpfung der Sachdaten (auch Attributdaten genannt) eines ESRI-Shapefiles.

Skalieren bedeutet z.B. ein digitales Bild oder 3D-Objekt zu vergrößern oder zu verkleinern.

SQL (Structured Query Language) eine Datenbanksprache zur Definition, Abfrage und Manipulation von Daten in relationalen Datenbanken. SQL ist von ISO standardisiert und wird von fast allen gängigen Datenbanksystemen unterstützt.

SQL-DDL (SQL-Data Definition Language) eine Computersprache, die verwendet wird, um Datenstrukturen und verwandte Elemente zu beschreiben, zu ändern oder zu entfernen. Als Datenbanksprache ist DDL die Datenbeschreibungssprache einer Datenbank. In SQL liegt sie in Form englischer Befehlsklauseln vor (z. B. CREATE TABLE PROJECT (PROJNO DECIMAL(6,0) NOT NULL PRIMARY KEY, ...)).

sRGB (Standard-RGB) ist ein häufig verwendeteter RGB-Farbraum.

TEI Ein offener und interoperabler Standard, der von dem Text Encoding Initiative (TEI) Consortium entwickelt und gepflegt wird. Er eignet sich vor allem für die Codierung von schriftlich fixierten Informationen und wird zur Zeit vor allem im XML-Format ausgedrückt.

TIFF (Tagged Image File Format) ein Dateiformat zur Speicherung von Bilddaten. TIFF bietet verschiedene Speicheroptionen an, wie die Verwendung von LZW-Komprimierung, mehrere Seiten und eingebettete Metadaten. Der kleinste gemeinsame Nenner aller Speicheroptionen bildet das unkomprimierte Baseline-TIFF.

True Color ist eine Bezeichnung für Bilder, die einen natürlichen Eindruck beim Betrachter erwecken. Man spricht auch von Echtfarben. Dabei hat jedes Pixel 256 mögliche Werte (also 8 Bit) für jede der Farbkomponenten. True Color RGB-Bilder weisen daher eine Farbtiefe von 24 (3×8) und CMYK-Bilder von 32 (4×8) Bit auf.

TXT eine Dateinamenserweiterung reiner Textdateien (eng. plain-text-file) unter den Betriebssystemen MS-DOS sowie Microsoft Windows.

U3D ein Dateiformat für 3D-Daten. Das Format wurde von der European Computer Manufacturers Association (ECMA) 2005 als ECMA-363 standardisiert. Das Ziel ist ein universeller Standard für dreidimensionale Daten aller Art, der einen herstellerübergreifenden Austausch ermöglicht.

Unicode ein internationaler Standard, in dem langfristig für jedes sinntragende Schriftzeichen oder Textelement aller bekannten Schriftkulturen und Zeichensysteme ein digitaler Code festgelegt wird. Siehe auch: www.w3.org/International/articles/definitions-characters/#unicode

UTF-8/UTF-16 8/16 Bit Unicode Transformation Format, eine Methode, Unicode-Zeichen auf Folgen von Bytes abzubilden.

Verwaistes Werk (engl. *orphan work*) ist ein Werk an das keine Metadaten mehr geknüpft sind. Beispielsweise lässt ein Bild ohne eingebettete, bzw. verknüpfte Metadaten keinerlei Rückschlüsse auf Urheber und Inhalt zu.

VRML (Virtual Reality Modelling Language) eine Beschreibungssprache für 3D-Szenen, deren Geometrien, Ausleuchtungen, Animationen und Interaktionsmöglichkeiten.

WAVE ein Containerformat zur digitalen Speicherung von Audiodaten. Enthalten sind meist sog. PCM-Rohdaten, die Abtastwerte des Audiosignals unkomprimiert digital darstellen

X3D eine 3D-Modellierungssprache, die in der Syntax wahlweise auf XML (XML-Encoding, Datei-Endung .x3d) oder auf VRML (Classic-Encoding, Datei-Endung .x3dv) aufbauen kann. Weiterhin gibt es einen weit gediehenen ISO-Entwurf, um X3D-Daten in einer Binärdatei zu speichern (Binary-Encoding, Datei-Endung .x3db).

XML (Extensible Markup Language) ist eine Auszeichnungssprache zur Darstellung hierarchisch strukturierter Daten in Form von Textdaten. XML wird u. a. für den Austausch von Daten zwischen Computersystemen eingesetzt, speziell über das Internet.

XMP (Extensible Metadata Platform) ist ein Standard, um Metadaten in digitale Medien einzubetten. Er wurde von Adobe im Jahr 2001 veröffentlicht und erstmals in den Acrobat Reader 5 integriert. Der Standard steht mit Spezifikationen unter einer Open-Source-Lizenz zur Verfügung.

XSL-FO (Extensible Stylesheet Language - Formatting Objects) ist eine XML-Anwendung, die beschreibt, wie Text, Bilder, Linien und andere grafische Elemente auf einer Seite angeordnet werden. Mit Hilfe von XSL-FO ist es möglich, qualitativ hochwertige Druckerzeugnisse entweder auf Papier oder auf dem Bildschirm zu erzeugen.